Incertitude et modèles probabilistes

INTELLIGENCE ARTIFICIELLE - IV

- Quantification de l'incertitude
- Raisonnement probabiliste
- Prise de décision

Plan du cours

I. Introduction
II. Résolution de problèmes
III. Bases de connaissances et logique
IV. Incertitude et modèles probabilistes
V. Théorie des jeux
VI. Apprentissage
VII. Traitement du langage naturel
VIII. Présentation projets

Sommaire

- Quantification de l'incertitude
  - Incertitude
  - Probabilités
  - Syntaxe et sémantique
  - Inférence
  - Indépendance et règle de Bayes
- Raisonnement probabiliste
  - Raisonnement probabiliste temporel
  - TP: Inférence avec des modèles probabilistes simples et temporels
- Théorie de la décision
  - Prise de décision simple
  - Prise de décision complexe

Incertitude

- A_t = partir pour l'aéroport t minutes avant le vol.
  Est-ce que A_t me permettra d'avoir mon vol?
- Problèmes
  1. Observabilité partielle (état de la route, plans des autres etc.)
  2. Capteurs bruités (Bison Futé)
  3. Incertitude sur les résultats des actions (pneu crevé, etc.)
  4. Complexité de la modélisation et la prévision du trafic
- Une approche purement logique
  1. Risque d'être incorrecte (A_{25} devrait suffire …)
  2. Conduira à des conclusions trop faibles pour la prise de décision
     1. A_{25} suffira s'il n'y a pas d'accident sur le pont et il ne pleut pas et mes pneus ne crèvent pas etc. = problème de la **qualification logique**
     2. A_{1500} conduira raisonnablement au but, mais il me faudra dormir à l'aéroport

Méthodes face à l'incertitude

- Logique *par défaut* ou *non monotone*
  - On suppose que ma voiture n'a pas de pneu crevé
  - On suppose que A_{25} fonctionne à moins d'une indication contradictoire
- Problèmes:
  - Quelles sont les suppositions raisonnables?
  - Comment gérer la contradiction?
- Règles avec facteurs vague
  - $A_{25} \mid\!\rightarrow_{0.3}$ devrait suffir
  - *Arroseur* $\mid\!\rightarrow_{0.99}$ *Herbe Mouillée*
  - *Herbe Mouillée* $\mid\!\rightarrow_{0.7}$ *Pluie*
- Problèmes: combinaisons (e.g, l'arroseur cause la pluie ?)
- Probabilités:
  - Représente le degré de croyance de l'agent
    - ➔ Etant donné les observations disponibles, A_{25} devrait me permettre d'avoir mon avion avec la probabilité 0.04

Probabilité

- Les assertions probabilistes résument les effets de:
  - La paresse: on n'énumère pas toutes les exceptions, qualifications etc.
  - L'ignorance théorique et pratique: Il nous manque des faits pertinents, les conditions initiales etc.
- Probabilités subjectives:
  - Elles concernent les propositions de l'état de connaissance de l'agent.
    - $P(A_{25} \mid \text{pas d'incident rapporté}) = 0.06$
  - Ce ne sont pas des assertions sur le monde
  - Les probabilités des propositions changent avec de nouvelles observations.
    - $P(A_{25} \mid \text{pas d'incident rapporté, 05h00}) = 0.15$

Prendre des décisions dans l'incertitude

- Supposons que je crois :

  $P(A_{25}$ j'arrive à temps | ...) = 0.04

  $P(A_{90}$ j'arrive à temps | ...) = 0.70

  $P(A_{120}$ j'arrive à temps | ...) = 0.95

  $P(A_{1440}$ j'arrive à temps | ...) = 0.9999
- Quelles actions choisir
  - Dépend des préférences entre rater le vol et attendre
  - La théorie de l'utilité peut représenter et inférer les préférences
  - théorie de la décision = probabilités + théorie de l'utilité

Syntaxe

- Elément de base: La variable aléatoire
  - Des mondes possibles leur donnent des assignations (cf logique propositionnelle)
- Domaines:
  - Variables aléatoires Booléennes:
    - E.g. *Carie* (est-ce que j'ai une carie?)
  - Variables discrètes:
    - E.g. Le *Temps* est un parmi <ensoleillé, nuageux, pluvieux, neigeux>
  - valeurs des domaines exhaustives et mutuellement exclusives
- Propositions:
  - Proposition élémentaire construites par assignation
    - E.g. *Temps* = ensoleillé, *Carie* = faux ($\neg$ *Carie*)
  - Proposition complexe formée par élémentaires + connecteurs logiques
    - E.g. *Temps* = ensoleillé $\vee$ *Carie* = faux
- Evènement atomique: spécification complète de l'état incertain
  - Ex pour 2 variables aléatoires:
    Carie = *false* $\wedge$ *MalDeDent* = *true*
  - Mutuellement exclusifs et exhaustifs

Axiomes des probabilités

- Pour toutes propositions A, B,
  - $0 \leq P(A) \leq 1$
  - $P(vrai) = 1$ and $P(faux) = 0$
  - $P(A \vee B) = P(A) + P(B) - P(A \wedge B)$

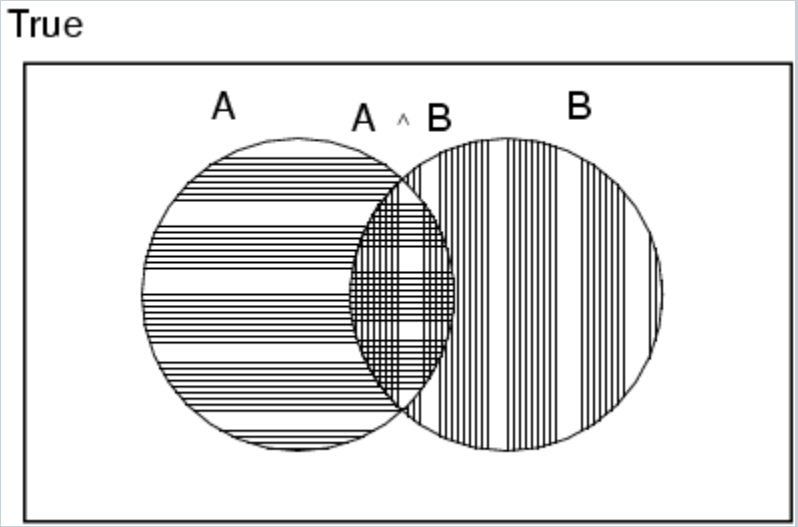

Probabilités a priori

- Probabilités inconditionnelles ou a priori de propositions
  - E.g. P(Carie = vrai) et P(Temps =ensoleillé) = 0.72
    - = état de croyance a priori en l'absence d'observation
- La distribution de probabilité donne les valeurs pour toutes les assignations:
  - P(Temps) = <0.72,0.1,0.08,0.1> (normalisées, i.e. la somme vaut 1)
- Distribution de probabilités conjointe
  - Pour des variables aléatoires, la probabilité de chacun de leurs évènements atomiques
  - P(Temps, Carie) = une matrice 4 x 2

Temps =	Soleil	Pluie	Nuages	Neige
Carie = true	0.144	0.02	0.016	0.02
Carie = false	0.576	0.08	0.064	0.08

  - Chaque question sur un domaine peut être répondue par la distribution conjointe.

Probabilités des variables continues

- On exprime la distribution comme fonction paramétrée:
  - P(X =x) = U[18; 26](x)
    - = densité uniforme entre 18 et 26
  - P est une densité qui intègre à 1
  - P(X =20,5) = 0,125 signifie:
    - $\lim_{dx \to 0} P(20.5) \leq X \leq 20.5 = dx)/dx = 0.125$

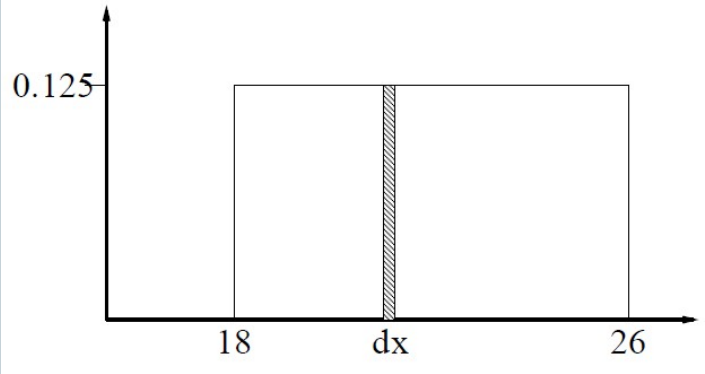

- Distribution gaussienne/normale
  - $P(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-(x-\mu)^2/2\sigma^2}$
  - Théorème central limite:
    - Somme de variables indépendantes
    - Tend vers une distribution normale

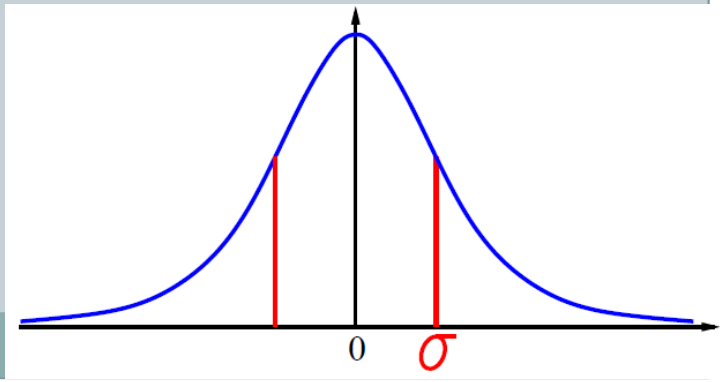

Probabilités conditionnelles

- Probabilités conditionnelles ou a posteriori
  - E.g. *P(Carie | MalDeDent)* = 0.8
  - i.e. « sachant uniquement» Mal De Dent
- Notation pour distributions conditionnelles:
  - *P(Carie | MalDeDent)* =vecteur à 2 elts de vecteurs à 2 elts
- Si l'on sait plus
  - *P(Carie | MalDeDent, Carie)* = 1
- Des observations peuvent être non pertinentes
  - Permettent la simplification
  - *P(Carie | MalDeDent, ensoleillé) = P(Carie | MalDeDent)* = 0.8
- Règle du produit
  - $P(a \wedge b) = P(a \mid b)\, P(b) = P(b \mid a)\, P(a)$ soit $P(a \mid b) = P(a \wedge b) / P(b)$ si $P(b) > 0$
  - *P(Temps , Carie) = P(Temps| Carie) P(Carie) produit terme à terme, pas matriciel*
- Règle de chainage = dérivation successive

$$
\begin{aligned}
\mathbf{P}(X_1, \ldots, X_n) &= \mathbf{P}(X_1,\ldots,X_{n-1})\, \mathbf{P}(X_n \mid X_1,\ldots,X_{n-1}) \\
&= \mathbf{P}(X_1)\, \mathbf{P}(X_2 \mid X_1) \ldots \mathbf{P}(X_{n-1} \mid X_1,\ldots,X_{n-2})\, \mathbf{P}(X_n \mid X_1,\ldots,X_{n-1}) \\
&= \ldots \\
&= \pi_{i=1}{}^{\wedge}n\, \mathbf{P}(X_i \mid X_1, \ldots, X_{i-1})
\end{aligned}
$$

Inférence par énumération

- Probabilités conjointe:

	toothache		*¬ toothache*	
	catch	*¬ catch*	*catch*	*¬ catch*
cavity	.108	.012	.072	.008
¬ cavity	.016	.064	.144	.576

  - Proposition φ -> sommer les évts atomiques où elle est vraie
  - $P(\varphi) = \Sigma_{\omega:\omega \models \varphi} P(\omega)$
  - $P(MalDeDents) = 0.108 + 0.012 + 0.016 + 0.064 = 0.2$
- Conditionnelles

$P(\neg Carie \mid MalDeDents)$
$= P(\neg Carie \wedge MalDeDents) / P(MalDeDents)$
$= (0.016+0.064) / (0.108 + 0.012 + 0.016 + 0.064)$
$= 0.4$

	toothache		*¬ toothache*	
	catch	*¬ catch*	*catch*	*¬ catch*
cavity	.108	.012	.072	.008
¬ cavity	.016	.064	.144	.576

Normalisation

- Dénominateur = constante de normalisation α
  - $\mathbf{P}(Carie \mid MalDeDents) = \alpha\, \mathbf{P}(Carie, MalDeDents)$, $\alpha = 1/\, \mathbf{P}(MalDeDents)$
    $= \alpha\, [\mathbf{P}(Carie, MalDeDents, Croche) + \mathbf{P}(Carie, MalDeDents, \neg Croche)]$
    $= \alpha\, [\langle 0.108, 0.016\rangle + \langle 0.012, 0.064\rangle]$
    $= \alpha\, \langle 0.12, 0.08\rangle = \langle 0.6, 0.4\rangle$
- Idée générale: calculer la distribution
  - sur la variable de requête Y
  - en fixant les variables d'observations E
  - en sommant sur les variables cachées H
- Distribution a posteriori conjointe
  - $\mathbf{P}(\mathbf{Y} \mid \mathbf{E} = \mathbf{e}) = \alpha \mathbf{P}(\mathbf{Y}, \mathbf{E} = \mathbf{e}) = \alpha \Sigma_{\mathbf{h}} \mathbf{P}(\mathbf{Y}, \mathbf{E} = \mathbf{e}, \mathbf{H} = \mathbf{h})$
- Problèmes:
  - Complexité au pire en $O(d^n)$ où d est la plus grande arité (nb d'arguments)
  - Complexité en espace en $O(d^n)$ pour stocker la distribution conjointe
  - Comment trouver les nombres pour $O(d^n)$ entrées?

	toothache		*¬ toothache*	
	catch	*¬ catch*	*catch*	*¬ catch*
cavity	.108	.012	.072	.008
¬ cavity	.016	.064	.144	.576

Indépendance

- A et B sont indépendants si et seulement si
  - $P(A|B) = P(A)$ ou $P(B|A) = P(B)$ ou $P(A, B) = P(A)\,P(B)$

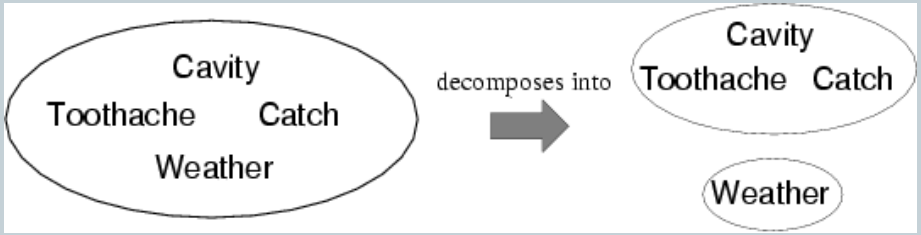

  - P(MalDeDent, Croche, Carie, Temps)
    = P(MalDeDent, Croche, Carie) P(Temps)
  - Pour n lancés de pièces indépendants : $O(2^n) \rightarrow O(n)$
- Puissant mais rare
  - Ex du dentiste: des centaines de variables dépendantes

Indépendance conditionnelle

- Croche est conditionnellement indépendant de Mal De Dents:
  - (1) P(Croche | MalDeDent, Carie) = P(Croche | Carie)
  - (2) $\mathbf{P}(Croche \mid MalDeDent, \neg Carie) = \mathbf{P}(Croche \mid \neg Carie)$
  - $\mathbf{P}(Croche \mid MalDeDent, Carie) = \mathbf{P}(Croche \mid Carie)$
  - $\mathbf{P}(MalDeDent \mid Croche, Carie) = \mathbf{P}(MalDeDent \mid Carie)$
  - $\mathbf{P}(MalDeDent, Croche \mid Carie) = \mathbf{P}(MalDeDent \mid Carie) * \mathbf{P}(Croche \mid Carie)$
- Utilisation de la règle de chaînage:
  - P(MalDeDent, Croche, Carie)
    = P(MalDeDent | Carie) P(Croche | Carie) P(Carie)
- Réduction de la complexité:
  - Peut réduire depuis la distribution conjointe de $O(2^n)$ à $O(n)$
  - Notre connaissance la plus basique et robuste en environnement incertain.

Règle de Bayes

- Règle du produit:
  - $P(a \wedge b) = P(a \mid b)\, P(b) = P(b \mid a)\, P(a)$
- ➔ règle de Bayes
  - $P(a \mid b) = P(b \mid a)\, P(a) / P(b)$
- Sous forme de distribution:
  - $P(Y|X) = P(X|Y)\, P(Y) / P(X) = \alpha P(X|Y)\, P(Y)$
- Utile pour déterminer les probabilités de diagnostic depuis les probabilités causales.
  - $P(\text{Cause} \mid \text{Effet}) = P(\text{Effet} \mid \text{Cause})\, P(\text{Cause}) / P(\text{Effet})$
  - Ex: méningite, nuque douloureuse:
    - $P(m|s) = P(s|m)\, P(m) / P(s) = 0.8 \times 0.0001 / 0.1 = 0.0008$
    - La probabilité a postériori est encore très faible

Bayes et indépendance conditionnelle

- Exemple:
  $\mathbf{P}(Carie \mid MalDeDents \wedge croche)$
  $= \alpha \mathbf{P}(MalDeDents \wedge croche \mid Carie)\ \mathbf{P}(Carie)$
  $= \alpha \mathbf{P}(MalDeDent \mid Carie)\ \mathbf{P}(Croche \mid Carie)\ \mathbf{P}(Carie)$
- C'est un exemple de modèle Bayesien naïf
  - $\mathbf{P}(\text{Cause}, \text{Effet}_1, \ldots, \text{Effet}_n) = \mathbf{P}(\text{Cause})\ \pi_i \mathbf{P}(\text{Effet}_i \mid \text{Cause})$

- Le nombre de paramètres est linéaire en n

Résumé

- Les probabilités sont un formalisme rigoureux pour la connaissance incertaine
- La distribution conjointe de probabilité spécifie la probabilité de chaque évènement atomique
  - Les questions peuvent être répondues en sommant sur les évènements atomiques
- Pour des domaines non triviaux, on doit trouver un moyen de réduire la taille conjointe
  - L'indépendance et l'indépendance conditionnelle fournissent de bons outils

Questions?

Sommaire

- Quantification de l'incertitude
- Raisonnement probabiliste
  - Réseaux Bayésiens
  - Domaines experts simples
- Raisonnement probabiliste temporel
- Prise de décision simple
- Prise de décision complexe
- TP: Inférence avec des modèles probabilistes simples et temporels

Réseaux Bayesiens

- Une notation simple, graphique
  - pour les assertions d''indépendance conditionnelle,
  - et pour la spécification compacte d'une distribution conjointe complète.
- Syntaxe:
  - Un ensemble de nœuds, un par variable
  - Un graphe dirigé acyclique (lien ≈ "influences directes")
  - Une distribution conditionnelle pour chaque nœud, étant donné ces parents:

$$\mathbf{P}\,(X_i \mid \text{Parents}\,(X_i))$$

- Dans la cas le plus simple, une distribution conditionnelle est représentée par:
  - une table de probabilités conditionnelles (CPT)
  - donnant la distribution en X_i pour chaque combinaison de valeur parente

Example

- La topologie du réseau encode les assertions d'indépendance conditionnelle:

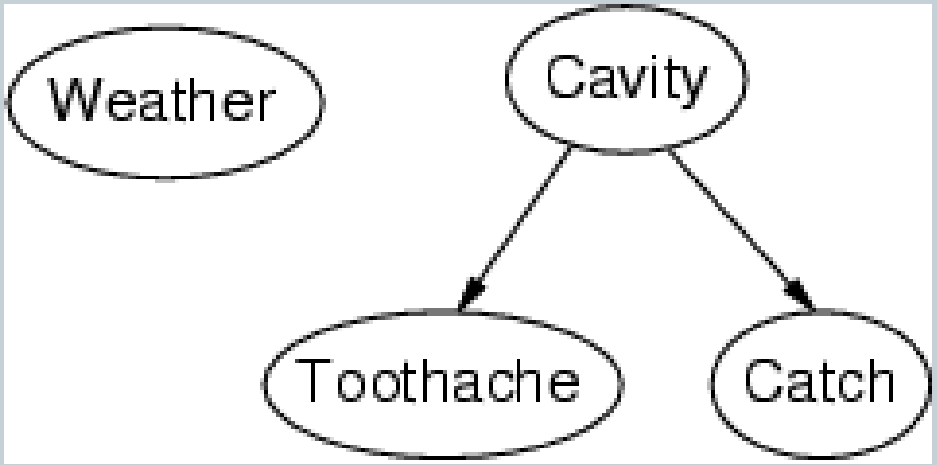

- *Weather* est indépendant des autres variables
- *Toothache* et *Catch* sont conditionnellement indépendants, étant donné *Cavity*

Exemple

- Mise en situation:
  - *« Au travail, mon voisin John m'appelle pour me prévenir que mon alarme sonne, mais ma voisine Marie n'appelle pas. Parfois elle est déclanchée par de petits tremblements de terre. Y a-t'il un voleur? »*
- Variables: *Burglary*, *Earthquake*, *Alarm*, *JohnCalls*, *MaryCalls*

- La topologie de réseau reflate la connaissance "causale" :
  - A burglar can set the alarm off
  - An earthquake can set the alarm off
  - The alarm can cause Mary to call
  - The alarm can cause John to call

Example (suite)

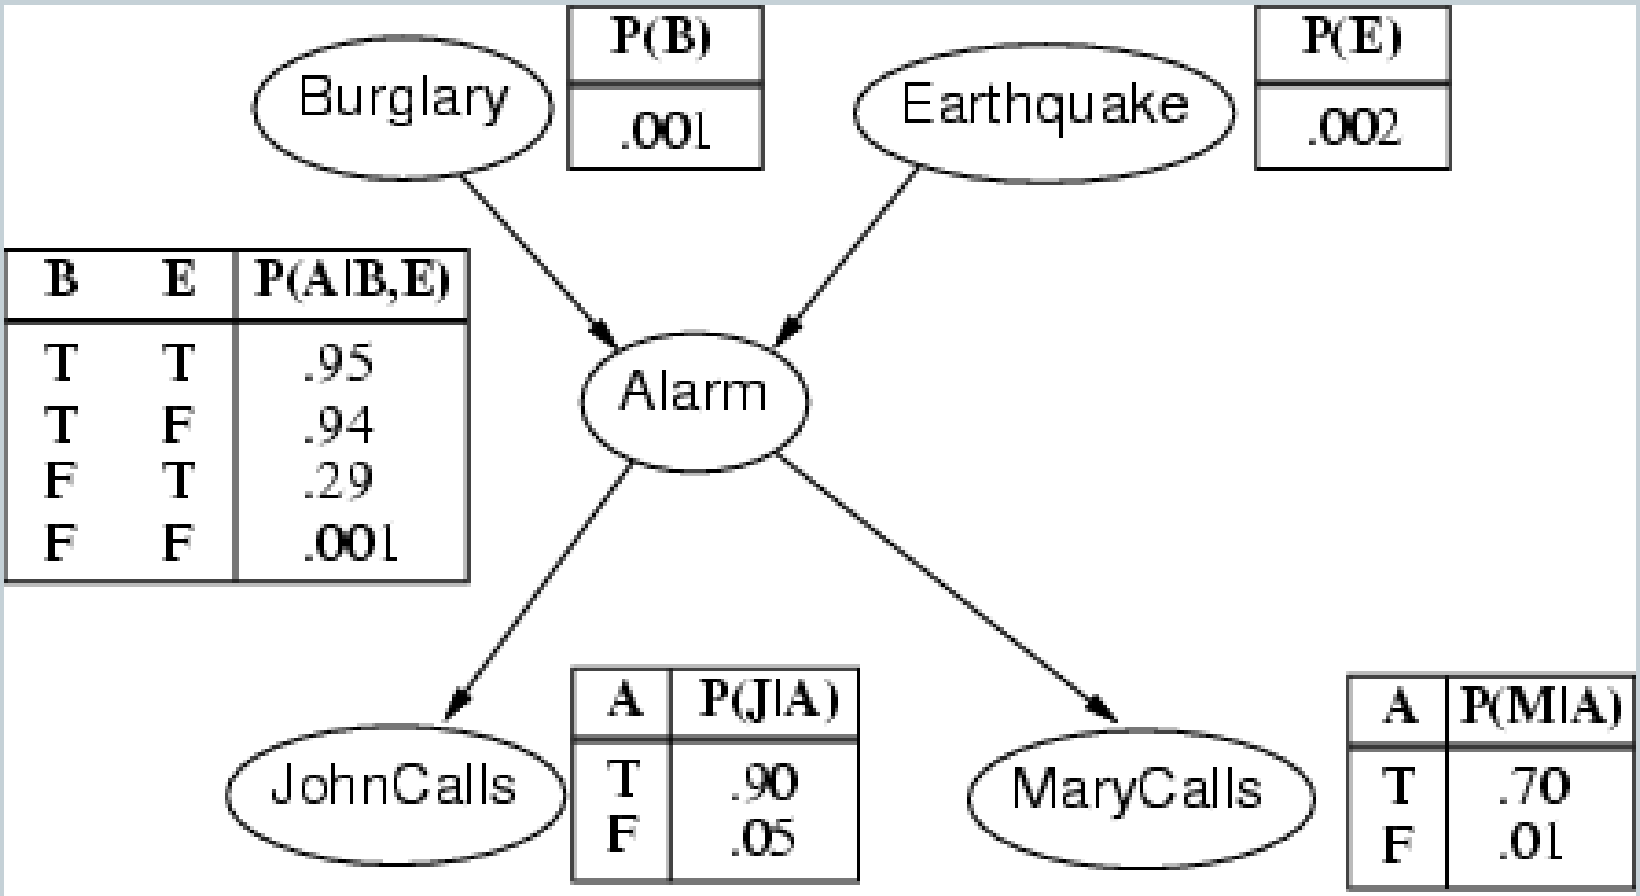

Compacité

- Un CPT pour les booléens X_i avec k Booleéns parents a 2^k lignes pour les combinaisons de valeurs parents

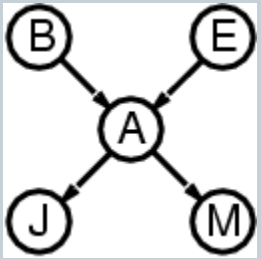

- Chaque ligne nécessite un nombre p pour $X_i = true$ (le nombre pour $X_i = false$ est juste $1-p$)

- Si chaque variable n'a pas plus de k parents, le réseau complet nécessite $O(n \cdot 2^k)$ nombres

- I.e., croit linéairement en n, vs. $O(2^n)$ *pour la distribution conjointe complète*

- Pour le réseau burglary, 1 + 1 + 4 + 2 + 2 = 10 nombres (vs. $2^5-1 = 31$)

Sémantiques

La distribution conjointe complète est définie par la produit des distributions conditionnelles locales:

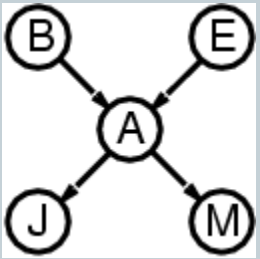

$$\boldsymbol{P}(X_1, \ldots, X_n) = \prod_{i=1}^{n} \boldsymbol{P}(X_i \mid Parents(X_i))$$

e.g., $\boldsymbol{P}(j \wedge m \wedge a \wedge \neg b \wedge \neg e)$

$$= \boldsymbol{P}(j \mid a)\, \boldsymbol{P}(m \mid a)\, \boldsymbol{P}(a \mid \neg b, \neg e)\, \boldsymbol{P}(\neg b)\, \boldsymbol{P}(\neg e)$$

Construction de réseaux Bayésiens

- 1. On choisit un ordre de variables $X_1, \ldots, X_n$
- 2. De $i = 1$ à n
  - On ajoute X_i au réseau
  - On sélectionne les parents de $X_1, \ldots, X_{i-1}$ tells que

$$\boldsymbol{P}(X_i \mid Parents(X_i)) = \boldsymbol{P}(X_i \mid X_1, \ldots X_{i-1})$$

Ce choix de parents garantit:

$$\boldsymbol{P}(X_1, \ldots, X_n) = \pi_{i=1}^{n} \boldsymbol{P}(X_i \mid X_1, \ldots, X_{i-1})$$

(règle de chaine)

$$= \pi_{i=1}^{n} \boldsymbol{P}(X_i \mid Parents(X_i))$$

(par construction)

Exemple

- Supposons qu'on choisisse l'ordre M, J, A, B, E

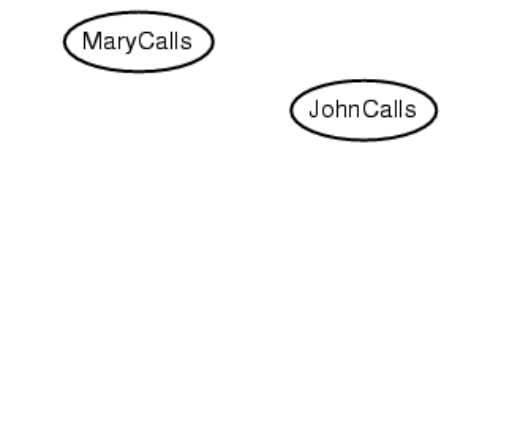

$\mathbf{P}(J \mid M) = \mathbf{P}(J)?$

Exemple

- Supposons qu'on choisisse l'ordre M, J, A, B, E

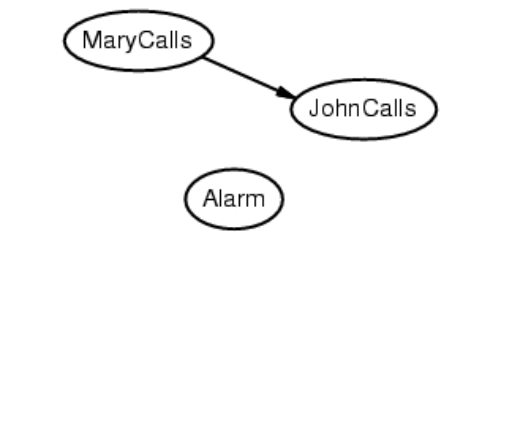

$\mathbf{P}(J \mid M) = \mathbf{P}(J)$?

Non

$\mathbf{P}(A \mid J, M) = \mathbf{P}(A \mid J)$? $\mathbf{P}(A \mid J, M) = \mathbf{P}(A)$?

Exemple

- Supposons qu'on choisisse l'ordre M, J, A, B, E

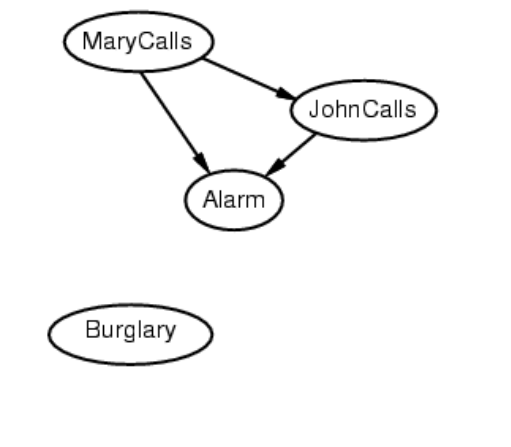

$\mathbf{P}(J \mid M) = \mathbf{P}(J)$?

Non

$\mathbf{P}(A \mid J, M) = \mathbf{P}(A \mid J)$? $\mathbf{P}(A \mid J, M) = \mathbf{P}(A)$? **Non**

$\mathbf{P}(B \mid A, J, M) = \mathbf{P}(B \mid A)$?

$\mathbf{P}(B \mid A, J, M) = \mathbf{P}(B)$?

Exemple

- Supposons qu'on choisisse l'ordre M, J, A, B, E

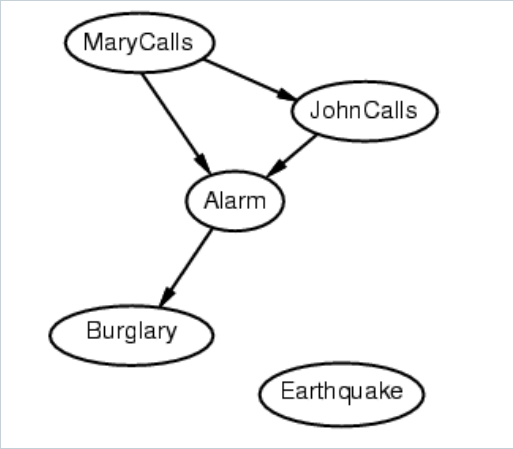

$\boldsymbol{P}(J \mid M) = \boldsymbol{P}(J)$?
No
$\boldsymbol{P}(A \mid J, M) = \boldsymbol{P}(A \mid J)$? $\boldsymbol{P}(A \mid J, M) = \boldsymbol{P}(A)$? **No**
$\boldsymbol{P}(B \mid A, J, M) = \boldsymbol{P}(B \mid A)$? **Yes**
$\boldsymbol{P}(B \mid A, J, M) = \boldsymbol{P}(B)$? **No**
$\boldsymbol{P}(E \mid B, A, J, M) = \boldsymbol{P}(E \mid A)$?
$\boldsymbol{P}(E \mid B, A, J, M) = \boldsymbol{P}(E \mid A, B)$?

Exemple

- Supposons que nous choisissons l'ordre M, J, A, B, E

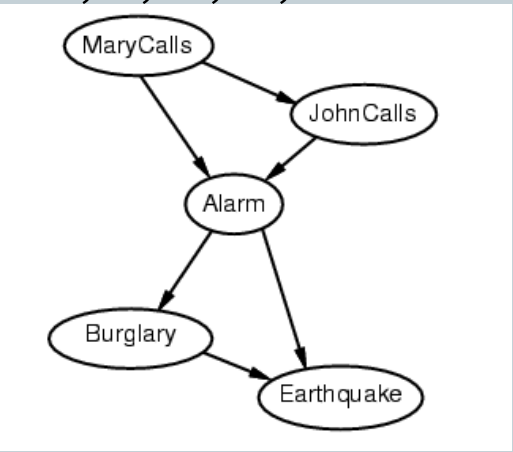

$\boldsymbol{P}(J \mid M) = \boldsymbol{P}(J)$?
No
$\boldsymbol{P}(A \mid J, M) = \boldsymbol{P}(A \mid J)$? $\boldsymbol{P}(A \mid J, M) = \boldsymbol{P}(A)$? **No**
$\boldsymbol{P}(B \mid A, J, M) = \boldsymbol{P}(B \mid A)$? **Yes**
$\boldsymbol{P}(B \mid A, J, M) = \boldsymbol{P}(B)$? **No**
$\boldsymbol{P}(E \mid B, A, J, M) = \boldsymbol{P}(E \mid A)$? **No**
$\boldsymbol{P}(E \mid B, A, J, M) = \boldsymbol{P}(E \mid A, B)$? **Yes**

Example contd.

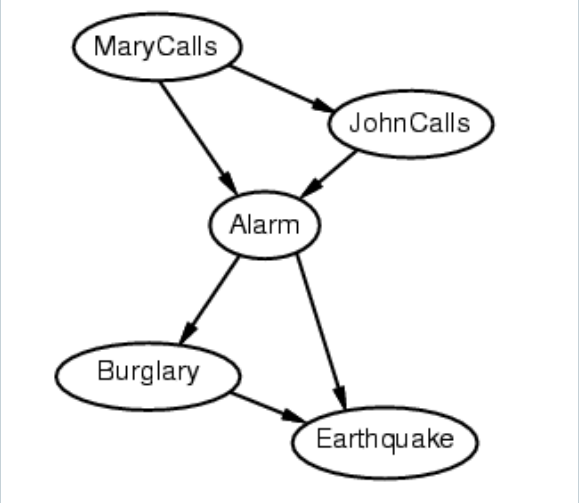

- Décider de l'indépendance conditionnelle est difficile dans les directions non causales
- (Les modèles causaux et d'indépendance conditionnelle semble cablés pour les humains!)
- Le réseau est moins compacte : 1 + 2 + 4 + 2 + 4 = 13 nombres nécessaires

Représentation efficace

- Relations d'**indépendance conditionnelle**
  - Indépendante conditionnelle aux non-descendants, étant donné les parents (a)
  - **Couverture de Markov**: Indépendance au reste du réseau (b)
    - Etant données parents, enfants et parents des enfants

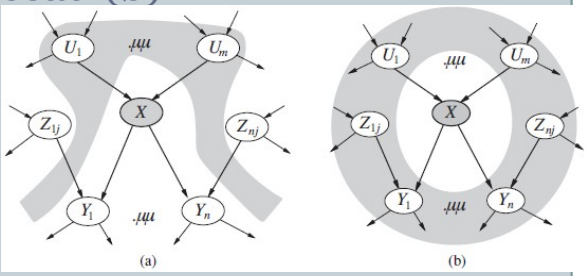

- **Distribution canonique**
  - Tables de probabilités conditionnelles fastidieux
    - O(2^k) nombres dans le cas pessimiste
  - ➔ Schéma standard plus simple
    - Ex simple: Nœuds **déterministes**: Enfants spécifiés par parents
      - Ex: Canadien vs US & Mexico → Nord Américain (disjonction)
      - Ex: Concessionnaires → Meilleur prix (Min)
      - Ex: débits entrant et sortant → Niveau d'un lac (différence)
  - Relation « **OU-bruité** »
    - +**Incertitude causale** Parents/Enfants → Relation **inhibée** par un **bruit**
      - Couverture des clauses de la disjonction → ajout d'un **nœud de fuite**
      - Hypothèse d'indépendance causale des bruits
      - Formulation générale:

$$P(x_i \mid parents(X_i)) = 1 - \prod_{\{j:X_j = true\}} q_j$$

  - Ex: Fièvre vs Maladies → 3 chiffres suffisent

Cold	*Flu*	*Malaria*	*P(Fever)*	*P(¬Fever)*
F	F	F	0.0	1.0
F	F	T	0.9	**0.1**
F	T	F	0.8	**0.2**
F	T	T	0.98	$0.02 = 0.2 \times 0.1$
T	F	F	0.4	**0.6**
T	F	T	0.94	$0.06 = 0.6 \times 0.1$
T	T	F	0.88	$0.12 = 0.6 \times 0.2$
T	T	T	0.988	$0.012 = 0.6 \times 0.2 \times 0.1$

Variables **continues**

- Concerne de nombreux problèmes (hauteur, masse, devise, température etc.)
- 1ère possibilité: Discrétisation → intervalles fixes
  - Mais parfois peu précis
- Meilleur: définition d'une **distribution de probabilités**
  - **Paramétrique**: ex: Gaussienne ← moyenne et variance
  - **Non paramétrique**: Définition implicite par l'exemple
- Réseau bayésien hybride
  - Paramètres discrets + continus
  - Variables continues: Probabilité **linéaire Gaussienne**
    - Ex: Coût ← Q récolte (h) + subventions
      - 2 distributions sommées

$$P(c \mid h, subsidy) = N(a_t h + b_t, \sigma_t^2)(c) = \frac{1}{\sigma_t \sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{c-(a_t h + b_t)}{\sigma_t}\right)^2}$$

$$P(c \mid h, \neg subsidy) = N(a_f h + b_f, \sigma_f^2)(c) = \frac{1}{\sigma_f \sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{c-(a_f h + b_f)}{\sigma_f}\right)^2}$$

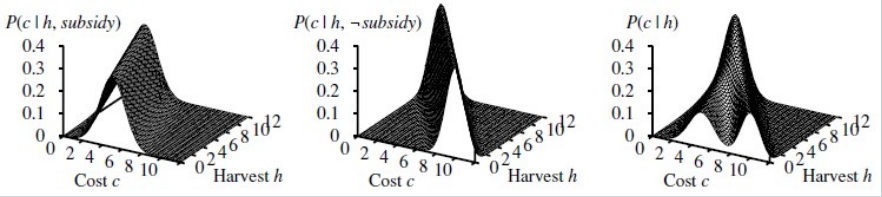

  - Somme de distributions linéaires gaussienne
    - distribution conjointe = Distribution gaussienne multivariée
    - Distribution a posteriori = **distribution gaussienne conditionnelle**
  - Variables discrètes avec parents continus
    - **Seuil doux** : Ex: acheter / coût
    - Possibilité = intégrale de la distribution normale
      - = **Distribution Probit**
    - Alternative = fonction sigmoïde = **distribution logit**

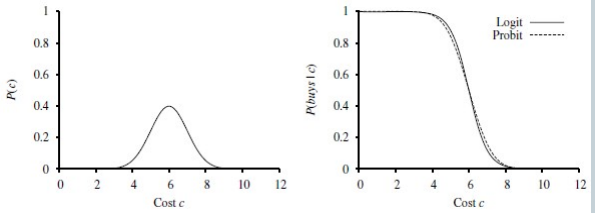

- **Distribution Apriori conjuguée**
  - Quelle distribution utiliser?
    - Posterieur = même famille de distribution
  - Exemples:
    - Gaussienne: moyenne → Gaussienne, précision → Gamma
    - https://en.wikipedia.org/wiki/Conjugate_prior

$$p(\theta \mid x) = \frac{p(x \mid \theta)\, p(\theta)}{p(x)} = \frac{p(x \mid \theta)\, p(\theta)}{\int p(x \mid \theta')\, p(\theta')\, d\theta'}$$

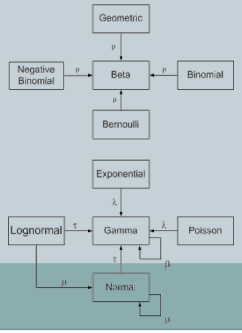

Inférence exacte dans les réseaux Bayésiens

- Objectif = distribution a posteriori d'une variable de requête
  - Requête X, Observation E, Variables cachées Y → $P(X|e)$?
- Inférence par énumération
  - ← $P(X|e) = \alpha \sum_y P(X,e,y)$
- Elimination des variables
  - Objectif = simplifier la sommation
  - Ex cambriolage:
    - → Multiplication termes à termes de droite à gauche
  - Ordre des variables important: minimise la taille du facteur produit
  - + élimination de toute variable pas ancêtre d'un X ou d'un E

$$\mathbf{P}(B \mid j,m) = \alpha \underbrace{\mathbf{P}(B)}_{\mathbf{f}_1(B)} \sum_e \underbrace{P(e)}_{\mathbf{f}_2(E)} \sum_a \underbrace{\mathbf{P}(a \mid B,e)}_{\mathbf{f}_3(A,B,E)} \underbrace{P(j \mid a)}_{\mathbf{f}_4(A)} \underbrace{P(m \mid a)}_{\mathbf{f}_5(A)}$$

- Complexité de l'inférence exacte
  - Dépend de la topologie:
    - ex: **polyarbre**: linéaire vs taille
    - **Multiplement connectés**: au pire exponentiel (#P-difficile>NP-complet)
      - Cf techniques CSPs (largeur d'arbre)
- Algorithmes de groupement (clustering)
  - Requêtes sur toutes les variables → O(n²)
  - Objectif = simplification en O(n)
    - → groupement des nœuds
    - → polyarbres de « méganoeuds »

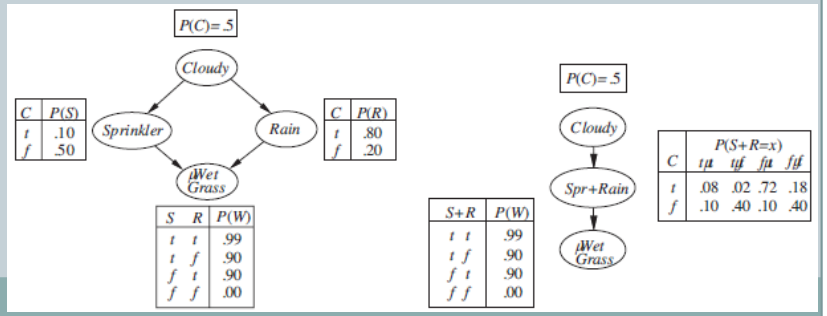

Inférence approchée dans les RB

- Inférence exacte impraticable dans grands réseaux
  - → Recours à **l'échantillonnage** (méthodes de **Monte-Carlo**)
- Echantillonnage direct
  - Echantillonnage **a priori**
    - Pas d'observation e → on suit l'ordre topologique
    - $P(x_1,\ldots x_m) \approx N_{ps}(x_1,\ldots x_m)/N$
  - Echantillonnage **par rejet**
    - Elimination des échantillons non conformes à l'observation *e*
    - Pb: écart type proportionnel à $1/\sqrt{n}$ avec n échantillons utilisés
      - Si e rare, peu d'échantillons utilisés
- Pondération par **vraisemblance** (Likelihood-Weighting)
  - Evite le problème de représentativité
    - Ne génère que des exemples conformes à l'observation (E est fixé)
  - Nécessite de pondérer les observations par vraisemblance
    - Poids de l'échantillon: $w(\mathbf{z},\mathbf{e}) = \prod_{i=1}^{m} P(e_i \mid parents(E_i))$
  - Retourne des estimations consistantes
    - Mais performances diminuent ave nombre de ***e*** (faibles vraisemblances)
- Simulation de chaînes de Markov Monte-Carlo
  - Modification d'un état courant (cf Recuit, Walksat etc. = **MCMC**)
  - Ex: **Echantillonnage de Gibbs**
    - Parcours de l'espace des états en utilisant la **couverture de Markov**
    - Fonctionne grâce aux probabilités de transition **ergotique** = **chaîne de Markov** $\pi(\mathbf{x})q(\mathbf{x} \rightarrow \mathbf{x}') = \pi(\mathbf{x}')q(\mathbf{x}' \rightarrow \mathbf{x})$
- Autres méthodes
  - Méthodes variationnelles
    - Version réduite du problème, décrite par un paramètre λ à optimiser → borne inf et sup. Cf Introduction
  - Propagation bouclée
    - Propagation de message dans des réseaux Bayésiens = Turbocodes: correction d'erreur Cf Wikipedia

Modèles relationnels du premier ordre

- Modèles bayésiens = propositionnel
- FOL → relations entre objets
  - Ex: évaluations livres: pb de partialité
  - → Impartial(c), Indulgent(c), Mérite(l) prédicats du premier ordre
- Mondes possibles
  - Assignations de variables → mondes possibles
  - Sémantique de base de données (limite la taille du problème)
- Modèles probabilistes relationnels
  - Syntaxe de FOL → Variables aléatoires = assignations possibles
  - Distributions et dépendances (Tables de Pr Cond.)
  - Indépendance contextuelle
    - = branchement ex: si Impartial(c), si Fan(c, Auteur(l))
  - Inférence: ex dépliement ➔ Assemblage complet
    - → grand réseau + variables inconnues
      → nombreux nœuds parents: ex auteur?
    - Mais si sémantique de DB:
      - mise en cache + indépendance contextuelle + techniques MCMC efficaces
      - = propositionnalisation → améliorée en FOL par lifting → De même lifting ici

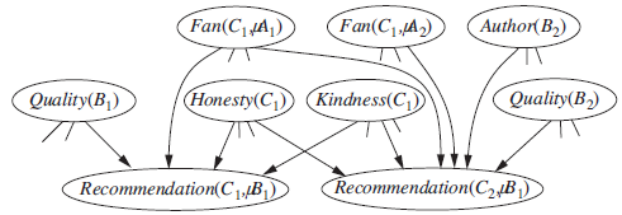

- Modèles relativistes en univers ouvert
  - Sémantique standard → incertitude d'existence et d'identité des objets (e.g. IDs: Sibyl attacks)
  - → MPUOs
  - Ex: NbClient: Si honête, exactement 1, sinon distribution LogNormal[6,9,2,3]

Résumé réseaux bayésiens

- Les réseaux Bayésiens fournissent une représentation naturelle pour les indépendance conditionnelles (induites par causalité)
- Topologie + CPTs = représentation compacte d'une distribution jointe
  - Généralement facile à construire pour un expert d'un domaine
- Représentation efficace/compacte:
  - Distributions canonique, distributions paramétriques (Gaussiennes etc.)
- Inférence = calcul de variables de requêtes
  - Exacte: énumération, élimination, clustering
    - → Efficace dans les polyarbres
  - Approximée:
    - Echantillonage a priori, par rejet, par vraissemblence
    - Méthodes de Monte-Carlo(Gibbs)
- Modèles relationnels
  - Combinaison avec FOL = Modèles probabilistes relationnels (MPR)
  - + Incertitude d'existence et d'identité = MP en Univers Ouvert

Questions?

Sommaire

- Quantification de l'incertitude
- Raisonnement probabiliste
- Raisonnement probabiliste temporel
  - Chaînes de Markov
  - Modèles de Markov Cachés
  - Réseaux Bayésiens dynamiques
  - Filtrage particulaire
- Prise de décision simple
- Prise de décision complexe
- TP: Inférence avec des modèles probabilistes simples et temporels

Raisonner dans le temps ou l'espace

- Souvent, nous souhaitons raisonner à propos d'une séquence d'observations
  - Reconnaissance de la parole
  - Localisation d'un robot
  - Attention d'un utilisateur
  - Monitoring médical
  - Suivi radar
- Besoin d'introduire le temps (ou l'espace) dans nos modèles

Modèles de Markov

- Un modèle (ou une chaîne) de Markov est:
  - Un réseau bayésien possédant une structure de chaîne

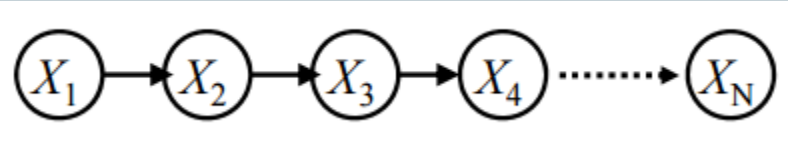

- A Markov model comprend:
  - Des variables aléatoires X_t pour chaque temps t (l'état)
  - Paramètres: Appelés probabilités de transitions ou dynamiques, ils spécifient comment le système évolue dans le temps (ainsi que les probabilités initiales)

$$P(X_1) \text{ and } P(X_t \mid X_{t-1})$$

Distribution de probabilités

- 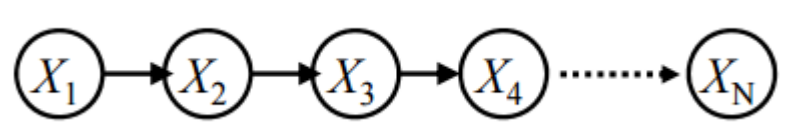

- Une chaîne de Markov définit une distribution de probabilités conjointes:

$$P(X_n) = P(X_1) \prod_{t=2}^{N} P(X_t \mid X_{t-1})$$

- Un problème d'inférence commun: calculer les probabilités marginales $P(X_t)$ pour chaque temps t

Indépendance conditionnelle

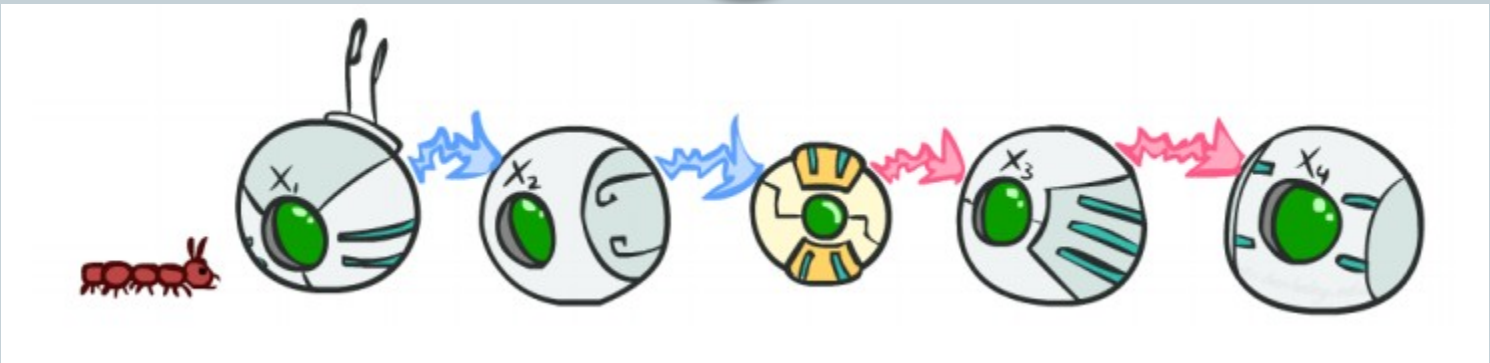

- Indépendance conditionnelle basique:
  - Passé et future indépendants conditionnellement au présent
  - Chaque étape dépend uniquement de la précédente
- On l'appelle la propriété de Markov (du premier ordre)
  - On note que la chaine est simplement un Réseau bayésien (extensible) : On peut toujours utiliser le raisonnement des RB classiques si on tronque la chaine à une longueur donnée.

Exemple: Chaîne de Markov

- Météo:
  - Etats: X = {rain, sun}
  - Transitions:

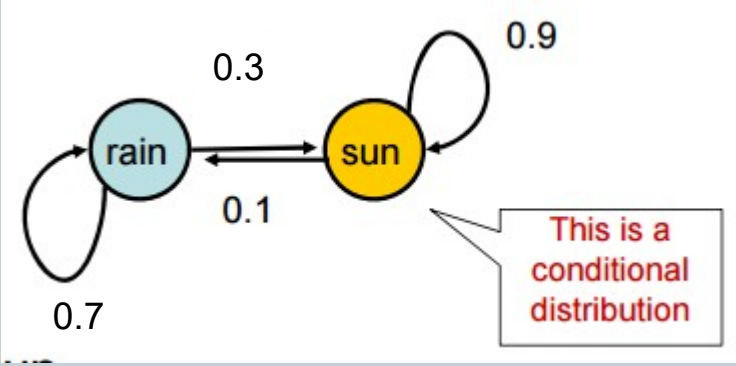

  - Distribution initiale: 1.0 sun
  - Quelle est la distribution de probabilité après une étape?

$$P(X_2 = sun) =$$
$$P(X_2 = sun \mid X_1 = sun)\, P(X_1 = sun) +$$
$$P(X_2 = sun \mid X_1 = rain)\, P(X_1 = rain)$$

Inférence sur chaînes de Markov

- Question: Probabilité d'être à un état x au temps t?
- Réponse lente:
  - Enumérer toutes les séquences de longueur t qui finissent en s
  - Ajouter leur probabilités p
- $P(X_t = sun) = \sum_{x_1 \ldots x_{t-1}} P(x_1, \ldots, x_{t-1}, sun)$

$$P(X_1 = sun)P(X_2 = sun|X_1 = sun)P(X_3 = sun|X_2 = sun)P(X_4 = sun|X_3 = sun)$$

$$P(X_1 = sun)P(X_2 = rain|X_1 = sun)P(X_3 = sun|X_2 = rain)P(X_4 = sun|X_3 = sun)$$

$$\vdots$$

Distribution conjointe de modèle de Markov

- Distribution conjointe:
  $P(X_1, X_2, X_3, X_4) = P(X_1)P(X_2 | X_1)P(X_3 | X_2)P(X_4 | X_3)$

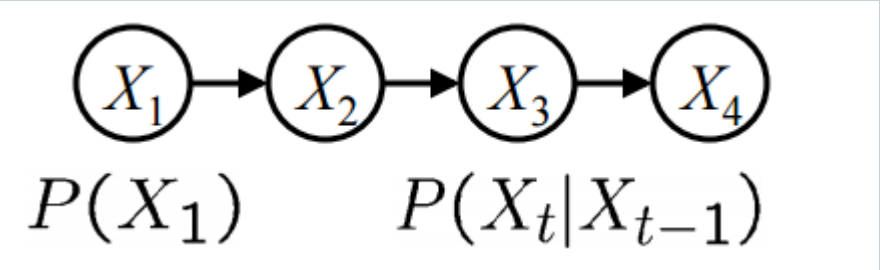

- Plus généralement:
  $P(X_1, X_2,\ldots,X_T) =$
  $P(X_1)P(X_2 | X_1)P(X_3 | X_2)\ldots P(X_T | X_{T-1}) =$
  $P(X_1) \prod_{t=2}^{T} P(X_t|X_{t-1})$

Récapitulatif modèles de Markov

- La distribution conjointe peut être écrite comme:
  - $P(X_1, X_2,\ldots,X_T) = P(X_1) \prod_{t=2}^{T} P(X_t|X_{t-1})$
- Indépendance conditionnelle supposée:
  - Le futur est indépendant du passé étant donné le présent
- Hypothèse additionnelle explicite:
  - $P(X_t|X_{t-1})$ est le même pour tout t

Algorithme Mini-Forward

- Question: Quel est P(X) à une date t?
  - Nous n'avons pas à énumérer chaque séquence

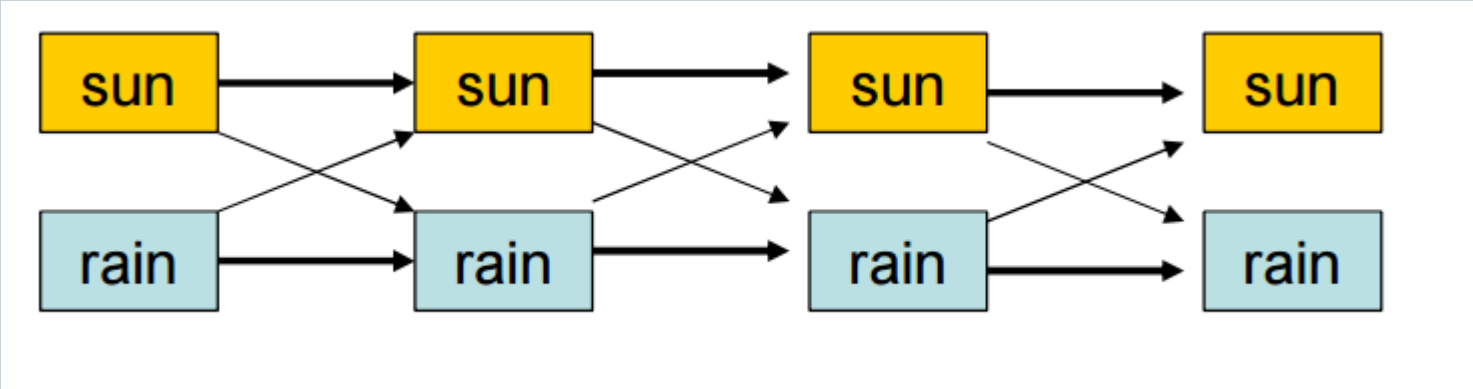

- $P(x_1) = known$
- $P(x_t) = \sum_{x_{t-1}} P(x_{t-1}, x_t) = \sum_{x_{t-1}} P(x_t \mid x_{t-1})\, P(x_{t-1})$

Exemple d'exécution Mini-Forward

- Depuis une observation initial d'ensoleillement:

$$\begin{array}{c}\langle 1.0 \\ 0.0 \rangle \\ P(X_1)\end{array} \quad \begin{array}{c}\langle 0.9 \\ 0.1 \rangle \\ P(X_2)\end{array} \quad \begin{array}{c}\langle 0.84 \\ 0.16 \rangle \\ P(X_3)\end{array} \quad \begin{array}{c}\langle 0.804 \\ 0.196 \rangle \\ P(X_4)\end{array} \rightarrow \begin{array}{c}\langle 0.75 \\ 0.25 \rangle \\ P(X_\infty)\end{array}$$

- Depuis une observation initial de pluie:

$$\begin{array}{c}\langle 0.0 \\ 1.0 \rangle \\ P(X_1)\end{array} \quad \begin{array}{c}\langle 0.3 \\ 0.7 \rangle \\ P(X_2)\end{array} \quad \begin{array}{c}\langle 0.48 \\ 0.52 \rangle \\ P(X_3)\end{array} \quad \begin{array}{c}\langle 0.588 \\ 0.412 \rangle \\ P(X_4)\end{array} \rightarrow \begin{array}{c}\langle 0.75 \\ 0.25 \rangle \\ P(X_\infty)\end{array}$$

- Depuis une autre distribution initiale $P(X_1)$:

$$\begin{array}{c}\langle p \\ 1-p \rangle \\ P(X_1)\end{array} \quad \ldots \quad \rightarrow \begin{array}{c}\langle 0.75 \\ 0.25 \rangle \\ P(X_\infty)\end{array}$$

Distributions stationnaires

- Pour la plupart des chaînes:
  - L'influence de la distribution initiale s'amenuise au court du temps.
  - La distribution finale est indépendante de la distribution initiale.
- Distribution stationnaire:
  - La distribution finale est appelée distribution stationnaire P_∞de la chaîne
  - Elle satisfait:

$$P_\infty(X) = P_{\infty+1}(X) = \sum_x P(X|x)P_\infty(x)$$

Exemple: distribution stationnaire

- Question: Quel est P(X) au temps t = infini?

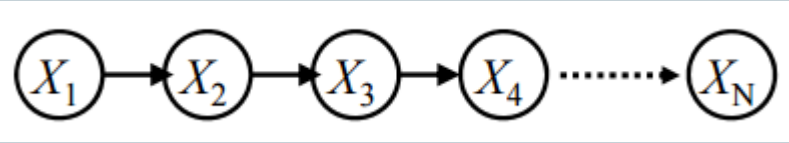

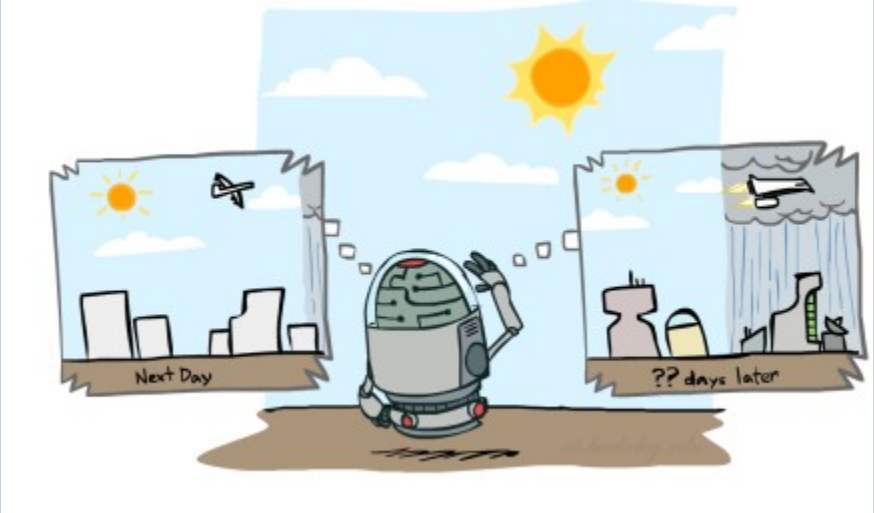

X_{t-1}	X_t	$P(X_t \mid X_{t-1})$
sun	sun	0.9
sun	rain	0.1
rain	sun	0.3
rain	rain	0.7

Application : Analyse des liens web

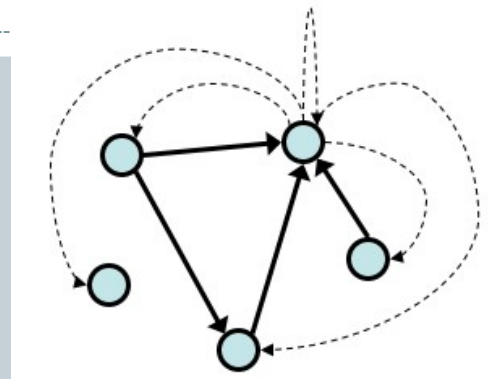

- PageRank sur un graphe du web
  - Chaque page est un état
  - Distribution initiale: uniforme sur les pages
  - Transitions:
    - Avec la prob. c, saut uniforme vers une page Aléatoire (lignes pointillées)
    - Avec prob. 1-c, suivre un lien sortant aléatoire (lignes pleines)
- Distribution stationnaire:
  - On passera plus de temps sur les pages hautement accessibles
    - E.g. Plein de façon d'arriver sur la page de téléchargement d'Acrobat Reader
  - Relativement robuste au spam de liens
- Google 1.0
  - Renvoyait la liste de pages contenant vos mots clés par ordre décroisant de page rank, maintenant tous les moteurs de recherche utilisent l'analyse de lien avec d'autres facteurs (le page rank devient en fait de moins en moins important)

Hidden Markov Models

- Markov chains not so useful for most agents
  - Eventually you don't know anything anymore
  - Need observations to update your beliefs
- Hidden Markov models (HMMs)
  - Underlying Markov chain over states S
  - You observe outputs (effects) at each time step
  - As a Bayes' net:

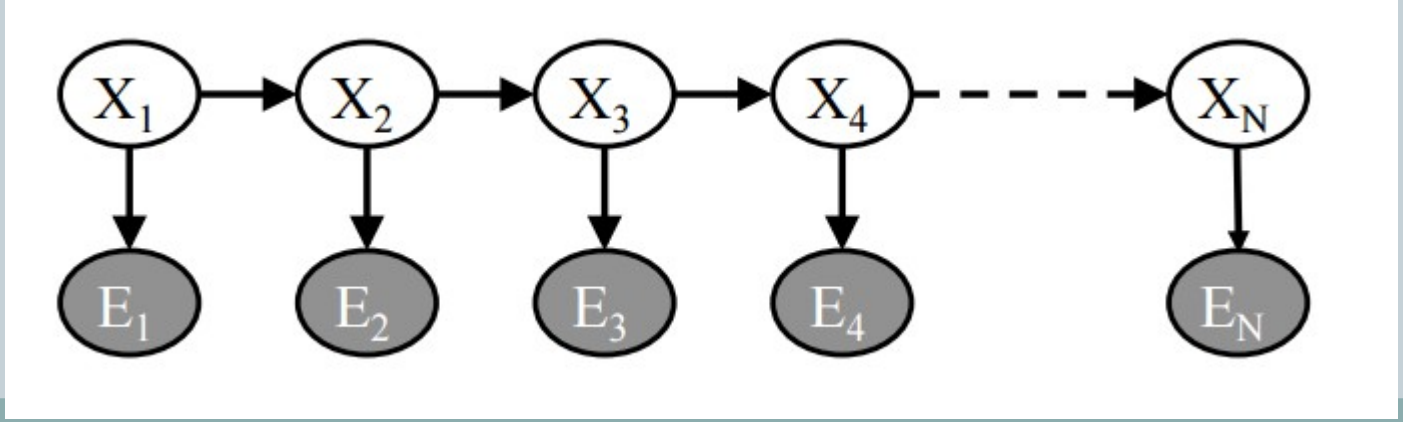

Example

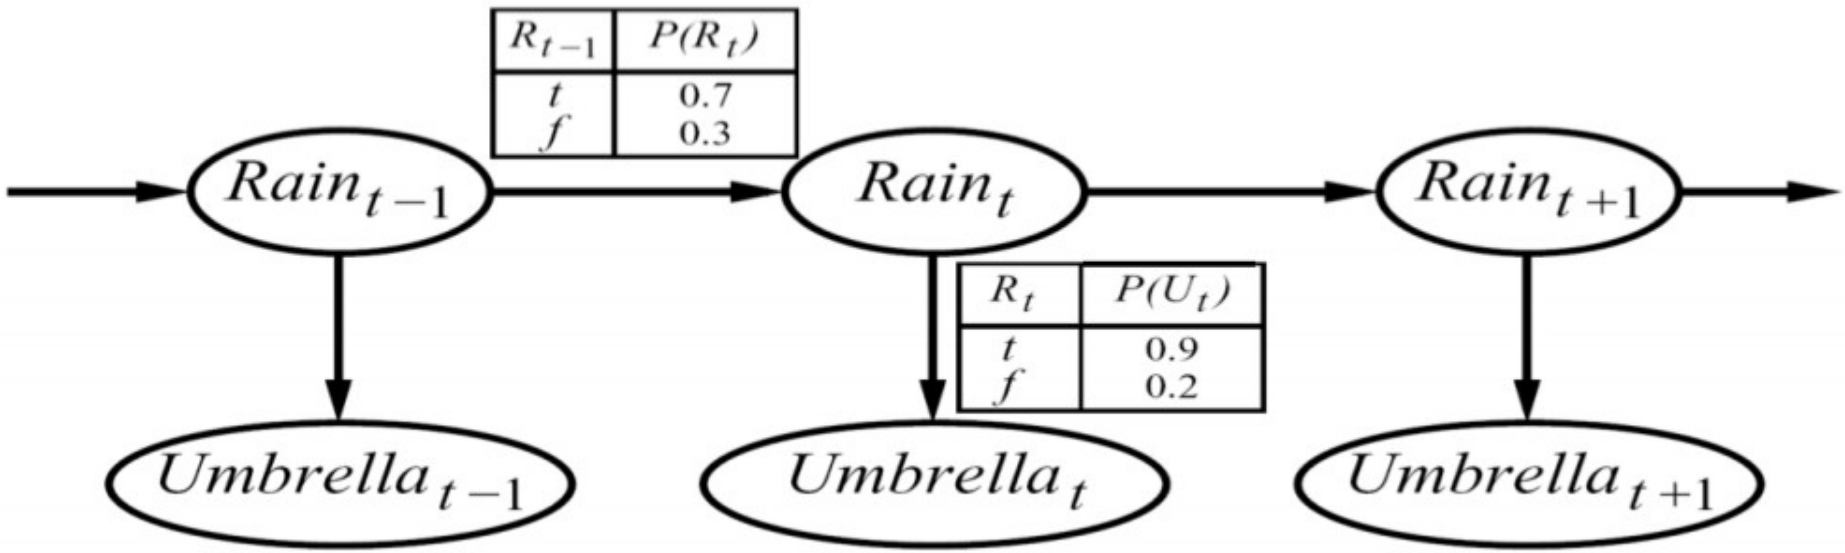

- An HMM is defined by:
  - Initial distribution: $P(X_1)$
  - Transitions: $P(X_t \mid X_{t-1})$
  - Emissions: $P(E \mid X)$

Hidden Markov Models

- 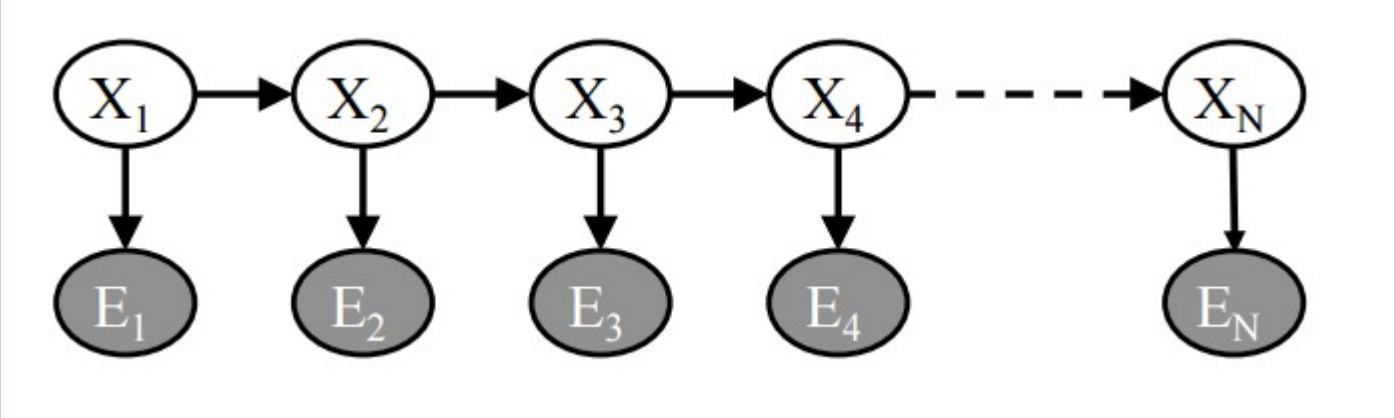

- Defines a joint probability distribution:

$$P(X_1, \dots, X_n, E_1, \dots, E_n) =$$
$$P(X_{1:n}, E_{1:n}) =$$
$$P(X_1)P(E_1 | X_1) \prod_{t=2}^{N} P(X_t | X_{t-1})P(E_t | X_t)$$

HMM Computations

- Given
  - parameters
  - evidence $E_{1:n} = e_{1:n}$
- Inference problems include:
  - Filtering, find $P(X_t | e_{1:t})$ for all t
  - Smoothing, find $P(X_t | e_{1:n})$ for all t
  - Most probable explanation, find $x^*_{1:n} = \text{argmax}_{x1:n} P(x_{1:n} | e_{1:n})$

Real HMM Examples

- Speech recognition HMMs:
  - Observations are acoustic signals (continuous valued)
  - States are specific positions in specific words (so, tens of thousands)

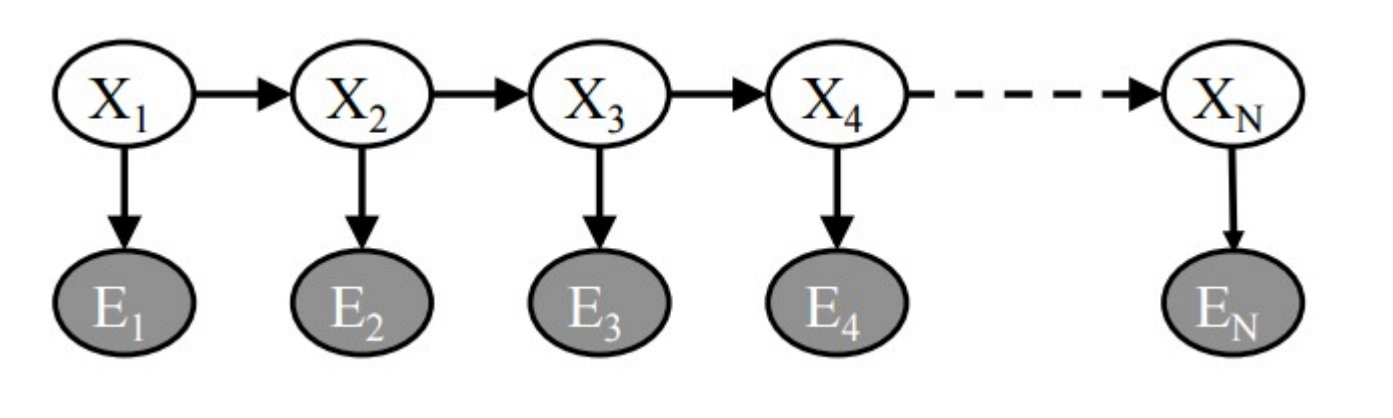

Real HMM Examples

- Machine translation HMMs:
  - Observations are words (tens of thousands)
  - States are translation options

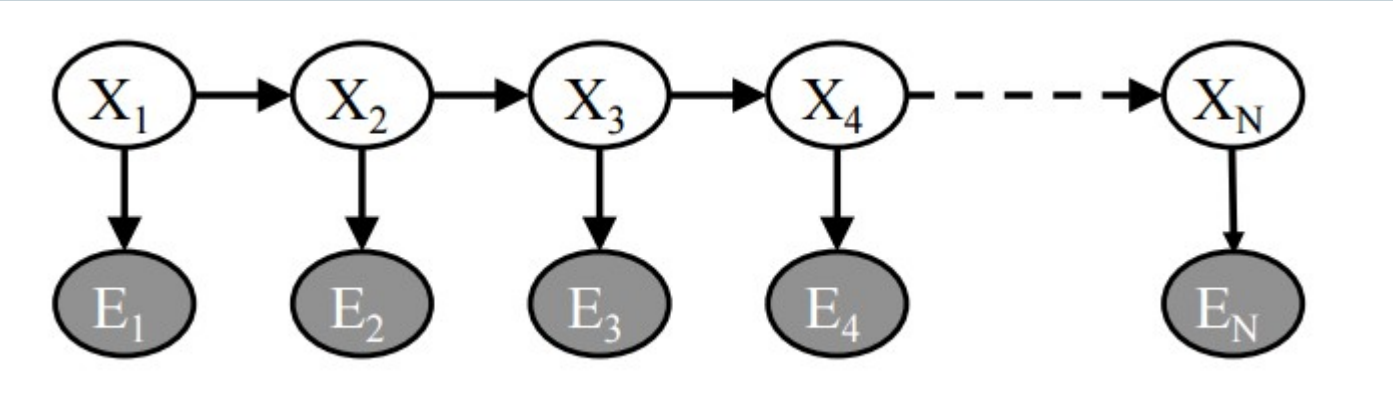

Real HMM Examples

- Robot tracking:
  - Observations are range readings (continuous)
  - States are positions on a map (continuous)

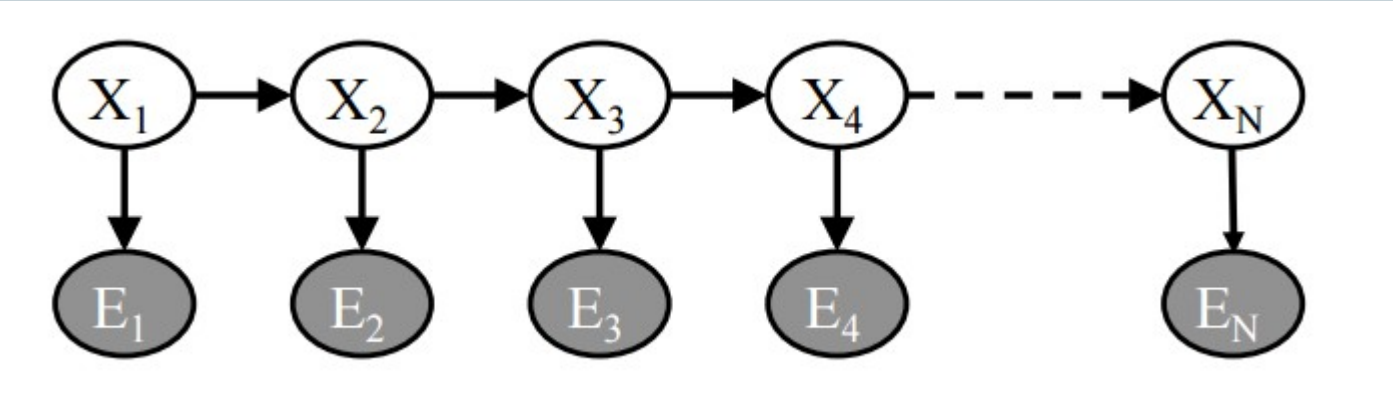

Conditional Independence

- HMMs have two important independence properties:
  - Markov hidden process, future depends on past via the present

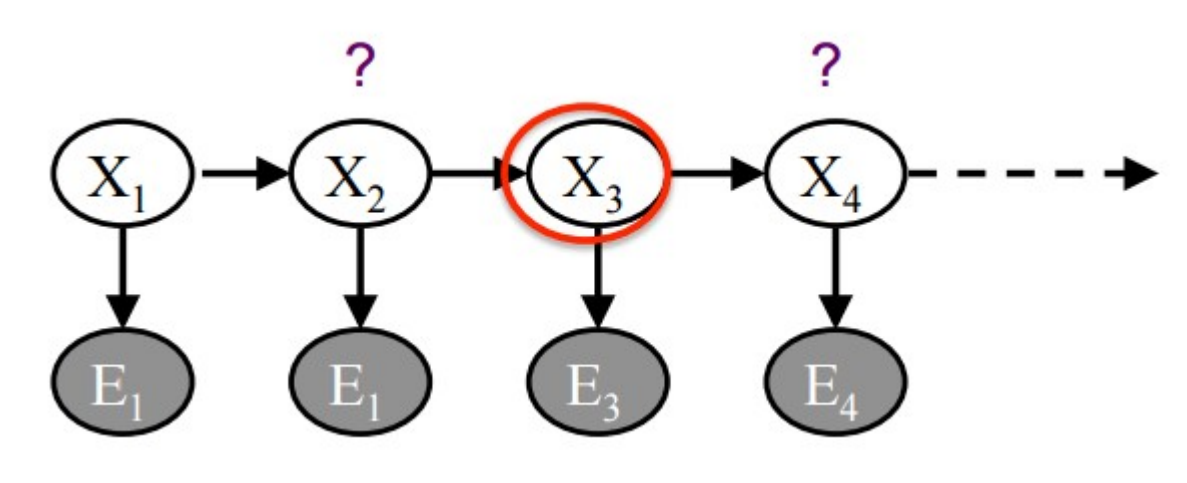

Conditional Independence

- HMMs have two important independence properties:
  - Markov hidden process, future depends on past via the present
  - Current observation independent of all else given current state

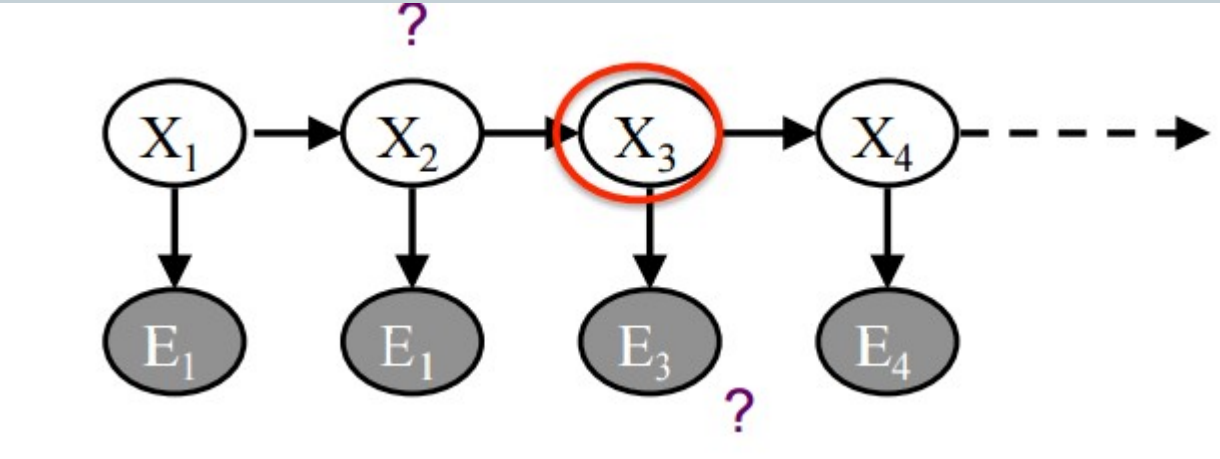

Conditional Independence

- HMMs have two important independence properties:
  - Markov hidden process, future depends on past via the present
  - Current observation independent of all else given current state

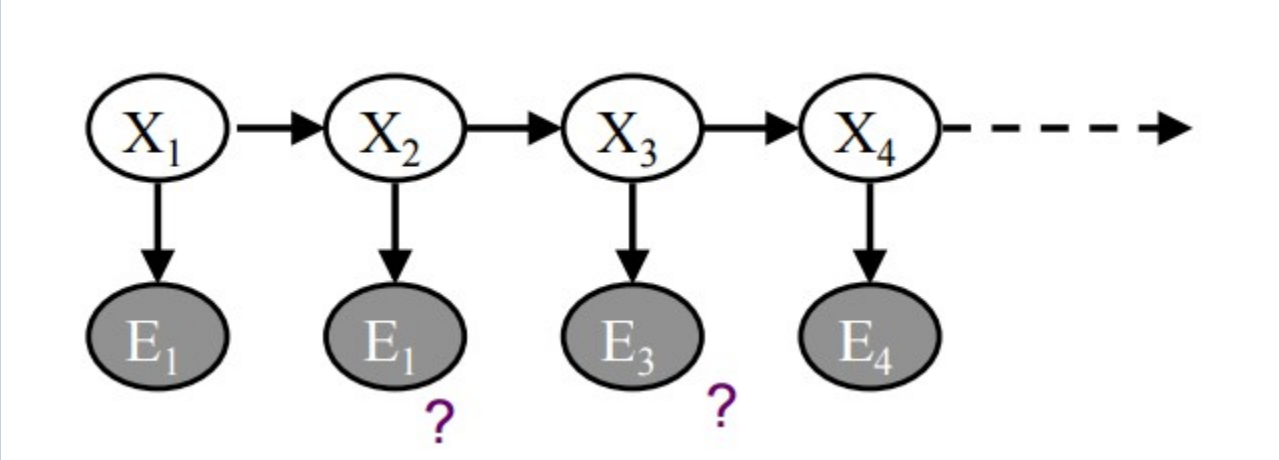

- Quiz: does this mean that observations are independent given no evidence?

HMM Notation

- A hidden Markov model (HMM) is a triple (π,A,B) where:
  - $\Pi = (\pi_i)$: $initial\ probabilities$
  - $\mathrm{A} = (a_i)$: $state\ transition\ matrix, P\left(x_{i_t} \mid x_{j_{t-1}}\right)$
  - $\mathrm{B} = (b_i)$: $confusion\ matrix, P(y_i \mid x_i)$

HMM Problem 1

- Evaluation
  Consider the problem where we have a number of HMMs (that is, a set of (π,A,B) triples) describing different systems, and a sequence of observations. We may want to know which HMM most probably generated the given sequence.
- Solution: Forward Algorithm

HMM Problem 2

- Decoding: Finding the most probable sequence of hidden states given some observations
- Find the hidden states that generated the observed output.
  - In many cases we are interested in the hidden states of the model since they represent something of value that is not directly observable
- Solution:
  - Backward Algorithm
  - or Viterbi Algorithm

HMM Problem 3

- Learning: *Generating a HMM from a sequence of observations*
- *Solution: Forward-Backward Algorithm*

```
function FORWARD-BACKWARD(ev, prior) returns a vector of probability distributions
  inputs: ev, a vector of evidence values for steps 1, ..., t
          prior, the prior distribution on the initial state, P(X_0)
  local variables: fv, a vector of forward messages for steps 0, ..., t
                   b, a representation of the backward message, initially all 1s
                   sv, a vector of smoothed estimates for steps 1, ..., t

  fv[0] ← prior
  for i = 1 to t do
     fv[i] ← FORWARD(fv[i − 1], ev[i])
  for i = t downto 1 do
     sv[i] ← NORMALIZE(fv[i] × b)
     b ← BACKWARD(b, ev[i])
  return sv
```

Exhaustive Search Solution

- Sequence of observations for seaweed state:
  - Dry
  - Damp
  - Soggy

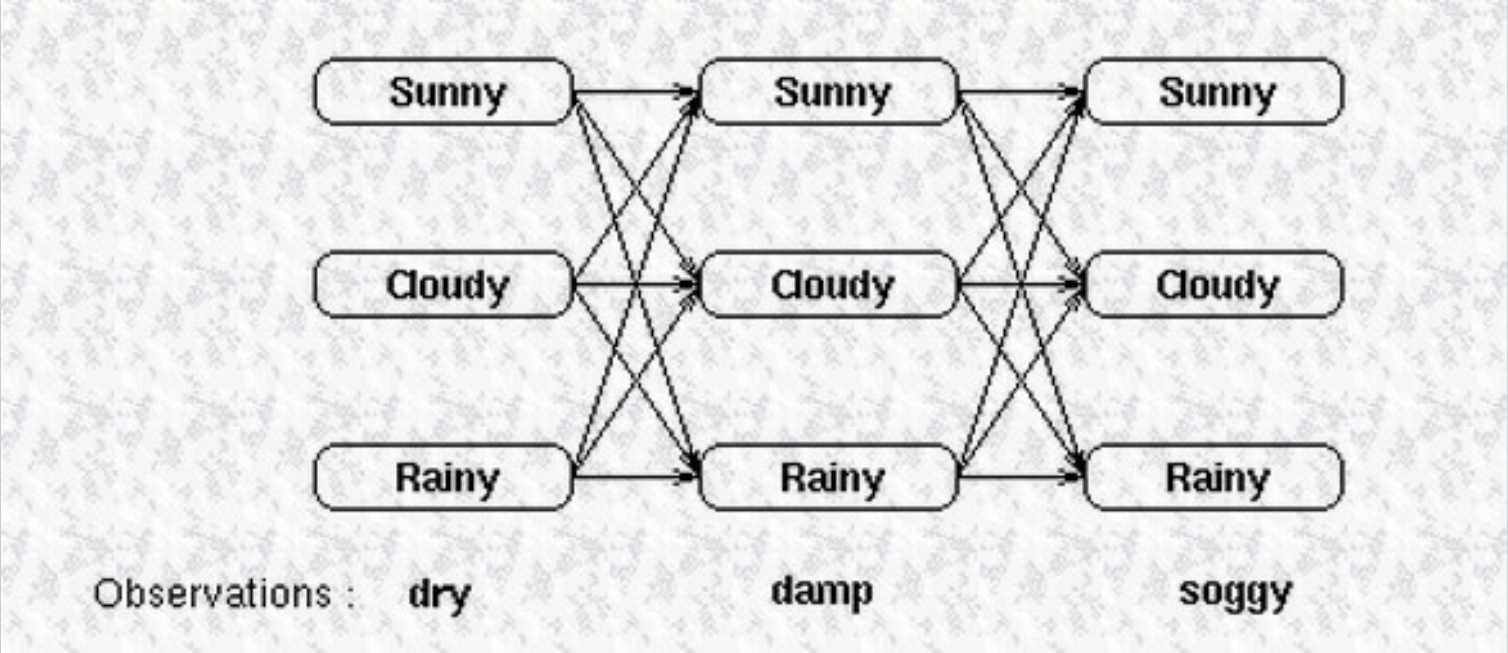

Exhaustive Search Solution

- Pr(dry,damp,soggy | HMM) =
  Pr(dry,damp,soggy | sunny,sunny,sunny) +
  Pr(dry,damp,soggy | sunny,sunny ,cloudy) +
  Pr(dry,damp,soggy | sunny,sunny ,rainy) + ...
  Pr(dry,damp,soggy | rainy,rainy ,rainy)

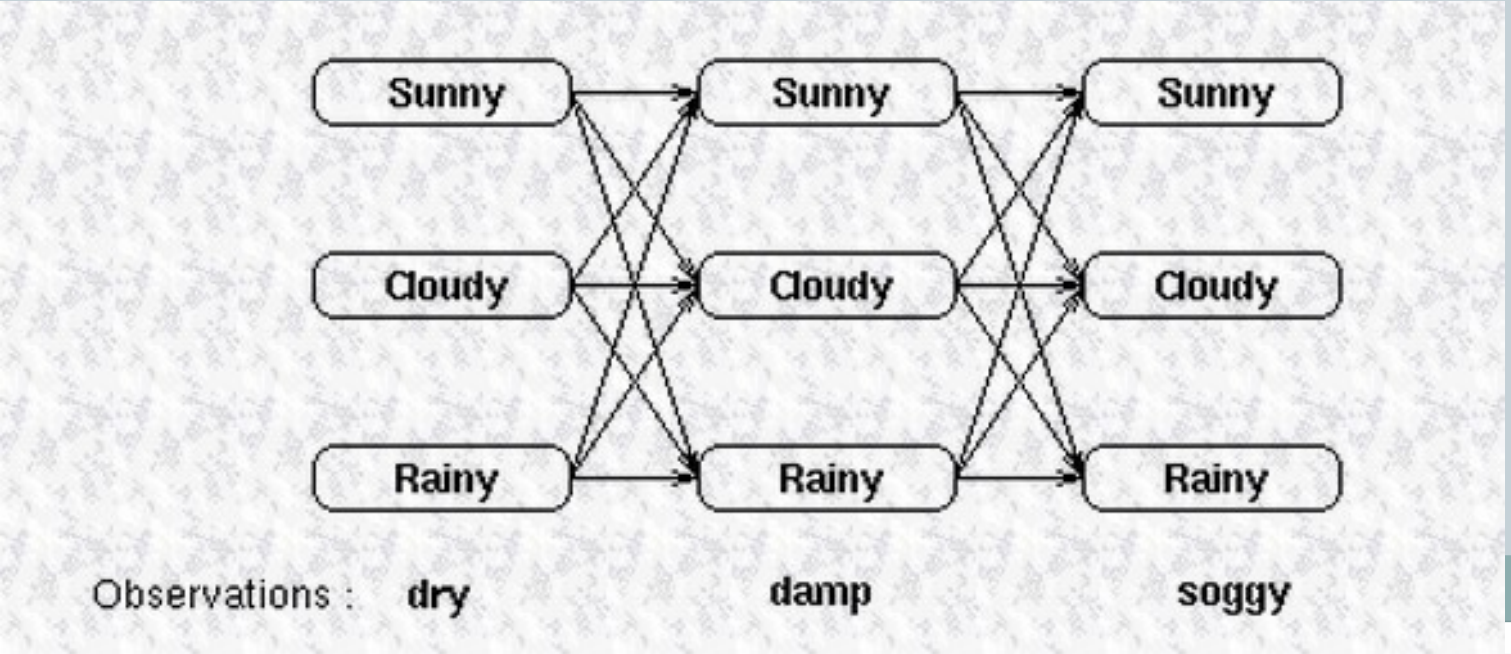

A better solution: dynamic programming

- We can calculate the probability of reaching an intermediate state in the trellis as the sum of all possible paths to that state.

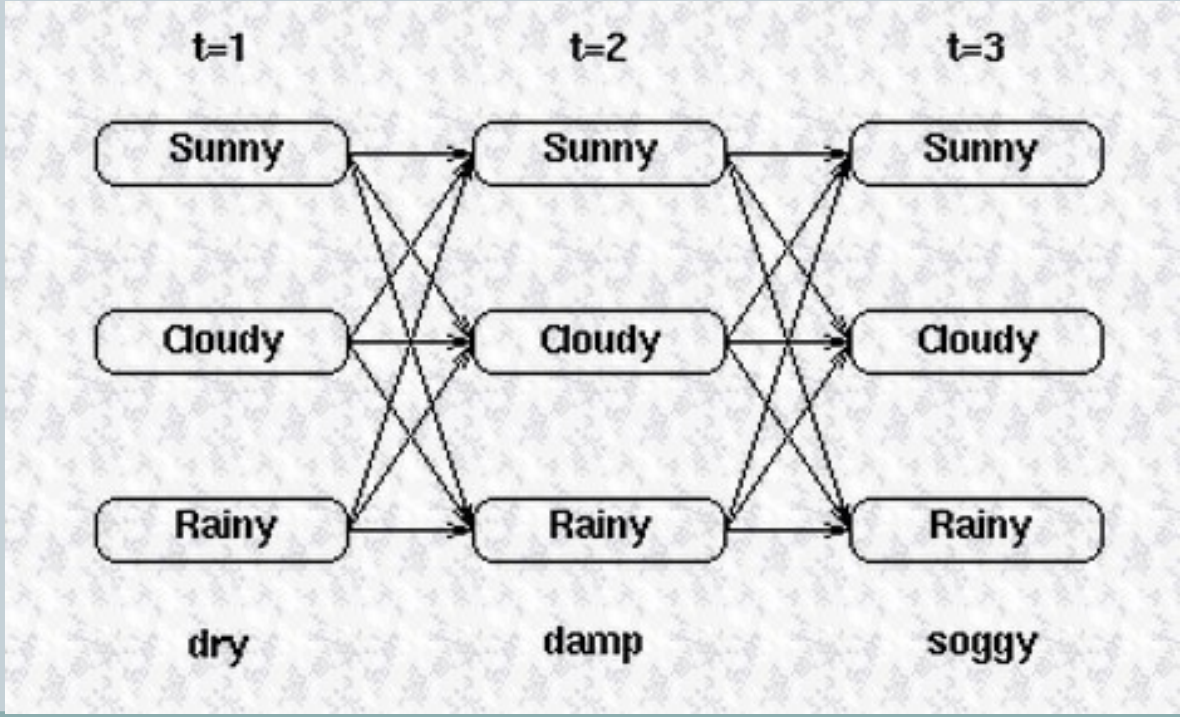

A better solution: dynamic programming

- $\alpha_t(j) = \Pr(\text{observation} \mid \text{hidden state is } j) \times \Pr(\text{all paths to state } j \text{ at time } t)$

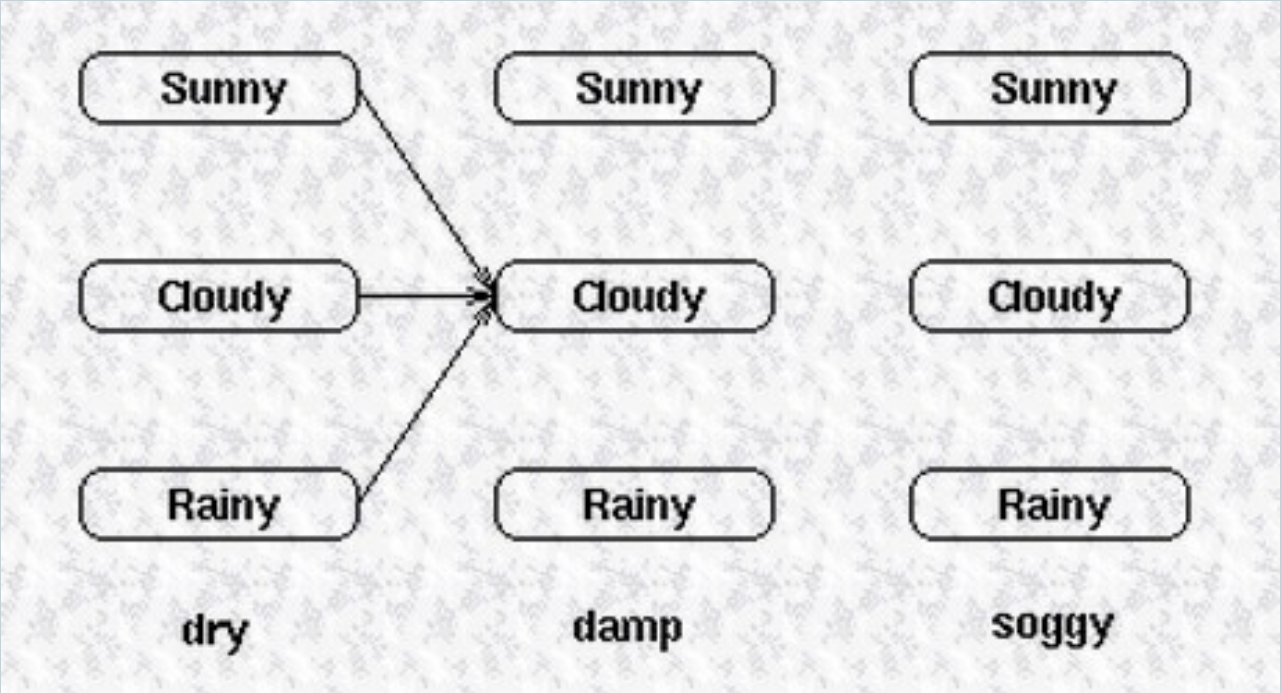

A better solution: dynamic programming

- the sum of these final partial probabilities is the sum of all possible paths through the trellis
- α_t (j)= Pr(observation | hidden state is j) x Pr(all paths to state j at time t)
- $\alpha_1 = \pi(j) b_{jk_1}$

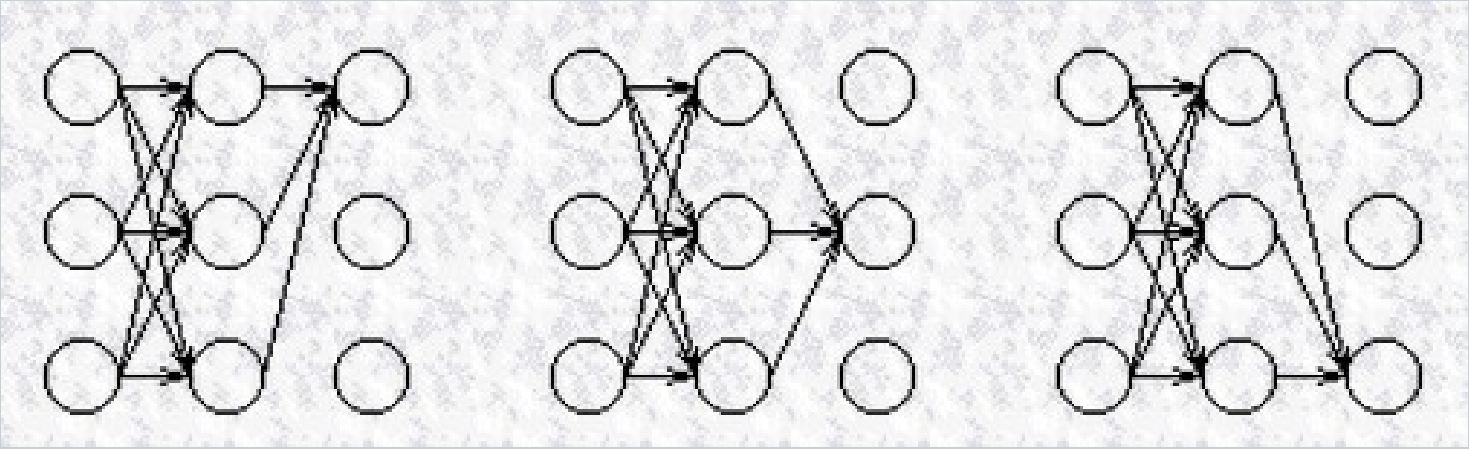

A better solution: dynamic programming

- α_t (j)= Pr(observation | hidden state is j) x Pr(all paths to state j at time t)
- $\alpha_{t+1}(j) = b_{jk_{t+1}} \sum_{i=1}^{n} \alpha_t(i)\, a_{ij}$
- Exhaustive search: $O(T^m)$
- Dynamic programming: O(T)

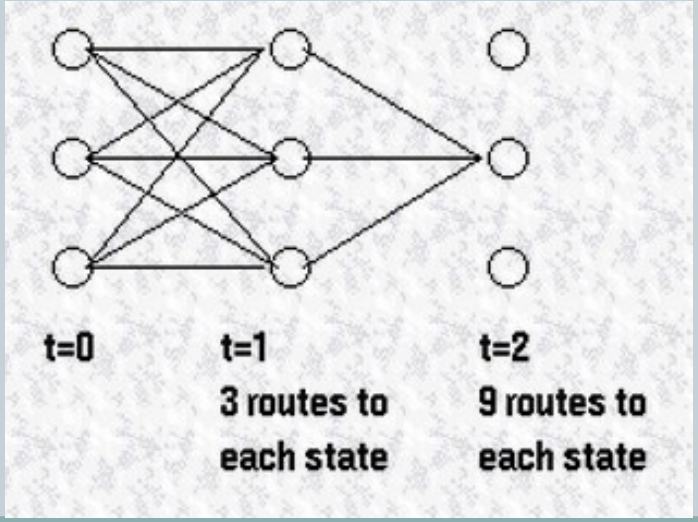

Filtres de Kalman

- Introduction
  - Observation de variables continues bruitées dans le temps
    - = radar, planètes, vision
  - Ex: Oiseau: X = 6 Variables $(X_t, Yt, Zt)et\ (\dot{X}_t, \dot{Y}_t, \dot{Z}_t)$
    - → modèles de transition et de capteur (X, Z)
    - → densités conditionnelles→ linéaires gaussiennes
      - → Distribution gaussienne multivariée
        - → Définie par moyenne μ et matrice de covariance Σ

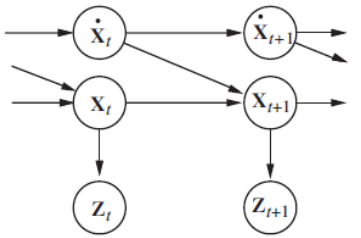

- Mise à jour des distributions gaussiennes
  - Distribution gaussiennes fermée par opérations bayésiennes
  - → Filtrage possible car $\mathbf{P}(\mathbf{X}_{t+1} \mid \mathbf{e}_{1:t}) = \int_{\mathbf{x}_t} \mathbf{P}(\mathbf{X}_{t+1} \mid \mathbf{x}_t) P(\mathbf{x}_t \mid \mathbf{e}_{1:t})\, d\mathbf{x}_t$ est gaussienne
    - et $\mathbf{P}(\mathbf{X}_{t+1} \mid \mathbf{e}_{1:t+1}) = \alpha\, \mathbf{P}(\mathbf{e}_{t+1} \mid \mathbf{X}_{t+1}) \mathbf{P}(\mathbf{X}_{t+1} \mid \mathbf{e}_{1:t})$ est gaussienne
- Exemple unidimensionnel
  - Indice de confiance x_t avec dist. a priori $P(x_0) = \alpha\, e^{-\frac{1}{2}\left(\frac{(x_0-\mu_0)^2}{\sigma_0^2}\right)}$, modèle de transition $P(x_{t+1} \mid x_t) = \alpha\, e^{-\frac{1}{2}\left(\frac{(x_{t+1}-x_t)^2}{\sigma_x^2}\right)}$
  - Et modèle de capteur = sondages $P(z_t \mid x_t) = \alpha\, e^{-\frac{1}{2}\left(\frac{(z_t-x_t)^2}{\sigma_z^2}\right)}$
  - ➔Application de Forward sur une gaussienne ➔ $\mu_{t+1} = \frac{(\sigma_t^2 + \sigma_x^2) z_{t+1} + \sigma_z^2 \mu_t}{\sigma_t^2 + \sigma_x^2 + \sigma_z^2}$ and $\sigma_{t+1}^2 = \frac{(\sigma_t^2 + \sigma_x^2)\sigma_z^2}{\sigma_t^2 + \sigma_x^2 + \sigma_z^2}$
- Cas général
  - Formule générale pour une gaussienne multivariée $N(\boldsymbol{\mu}, \boldsymbol{\Sigma})(\mathbf{x}) = \alpha\, e^{-\frac{1}{2}\left((\mathbf{x}-\boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x}-\boldsymbol{\mu})\right)}$
  - Matrice de gain de Kalman K_{t+1} utile pour le calcul de μ_{t+1} et Σ_{t+1}
  - Lissage également possible → trajectoire + régulière sauf aux extrémités
- Applications
  - Vaste gamme, ex: poursuite radar, trajectoires de particules, météo, économies etc.
  - Hypothèses linéaires fortes → Filtres de Kalman étendus = non linéaires
    - Ex: oiseau devant obstacle
    - →filtres commutés exécutés en parallèle et pondérés par vraisemblance

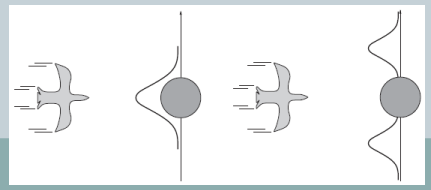

Réseaux bayésiens dynamiques

- Généralisation HMM, Kalman etc.
  - Modèle probabiliste temporel
    - Variables X_t d'état et E_t d'observations, dans des coupes arbitraires
    - Cf transformation HMM ←→RBD (vecteur multidimensionnel)
  - Modèle (beaucoup) plus parcimonieux
- Construction d'un RBD
  - Distribution a priori , modèle de transition, de capteur
  - Ex: Robot: jauge de batterie
    - → Modèle de défaillance temporaire
    - → Modèle de défaillance persistante → « Jauge cassée »

$$P(BMeter_t = 0 \mid Battery_t = 5) = 0.03$$

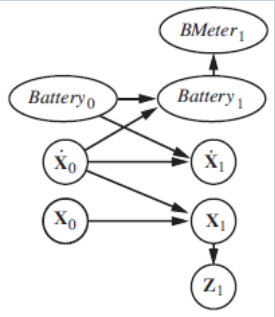

- Inférence exacte
  - Possibilité: dépliement de suffisamment de coupes
    - Puis élimination, clustering
    - Utilité du fonctionnement récursif (sommations partielles)
      - mais résultat pas factorisable
    - ➔ Souvent, méthodes approximatives uniquement
- Inférence approchée
  - Pondération par vraisemblance et méthodes MCMC adaptables
  - Ex: Filtrage particulaire: on rejette les échantillons trop faibles et on duplique les a

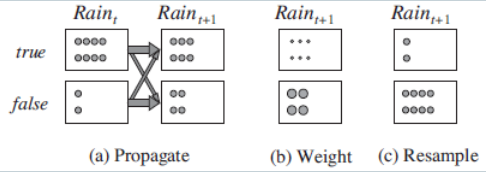

- Suivre de nombreux objet (jusqu'ici: une trajectoire)
  - Incertitude d'identité → pb d'association des données → Méthodes approximatives
  - Ex: plus proche voisin, max. de la probabilité des observations, filtrage particulaire, MCMC

Résumé raisonnement temporel

- Variables aléatoires temporelles
  - Propriété de Markov, stationnarité
- Modèles de transition, de capteur
- Inférence
  - Filtrage (forward), prédiction, lissage (backward), explication vraissemblance
- Familles de modèles temporels
  - Modèles de Markov cachés, filtres de Kalman, Réseaux bayésiens dynamiques
- Inférence exacte souvent difficile mais méthodes approchées efficaces
  - Filtrage particulaire
  - + Problème de l'association des données

Questions?

Programmation probabiliste

- Principales librairies
  - Infer.Net (c# / .Net)
  - Pyro (Python / Pytorch)
  - Tensorflow Probability (Python /Tensorflow)
  - PyMC (Python / Aesara, Jax)
  - Stan (C++ /Wrappers)
- Tutoriels Infer.Net
  - Prise en main (en français)
  - Tutoriels (en anglais)
  - Guide utilisateur

Sommaire

- Quantification de l'incertitude
- Raisonnement probabiliste
- Raisonnement probabiliste temporel
- Prise de décision simple
  - Théorie de l'utilité
  - Réseaux de décision
  - Systèmes experts
- Prise de décision complexe
- Théorie des jeux
- TP: Inférence avec des modèles probabilistes simples et temporels

Agent fondé sur l'utilité

- Alternatives ?
- Niveau de succès
  - Quantitatif
- Fonction U
  - Etat → R
- Arbitrages
  - Chance de succès
  - Important
  - Urgent
  - …

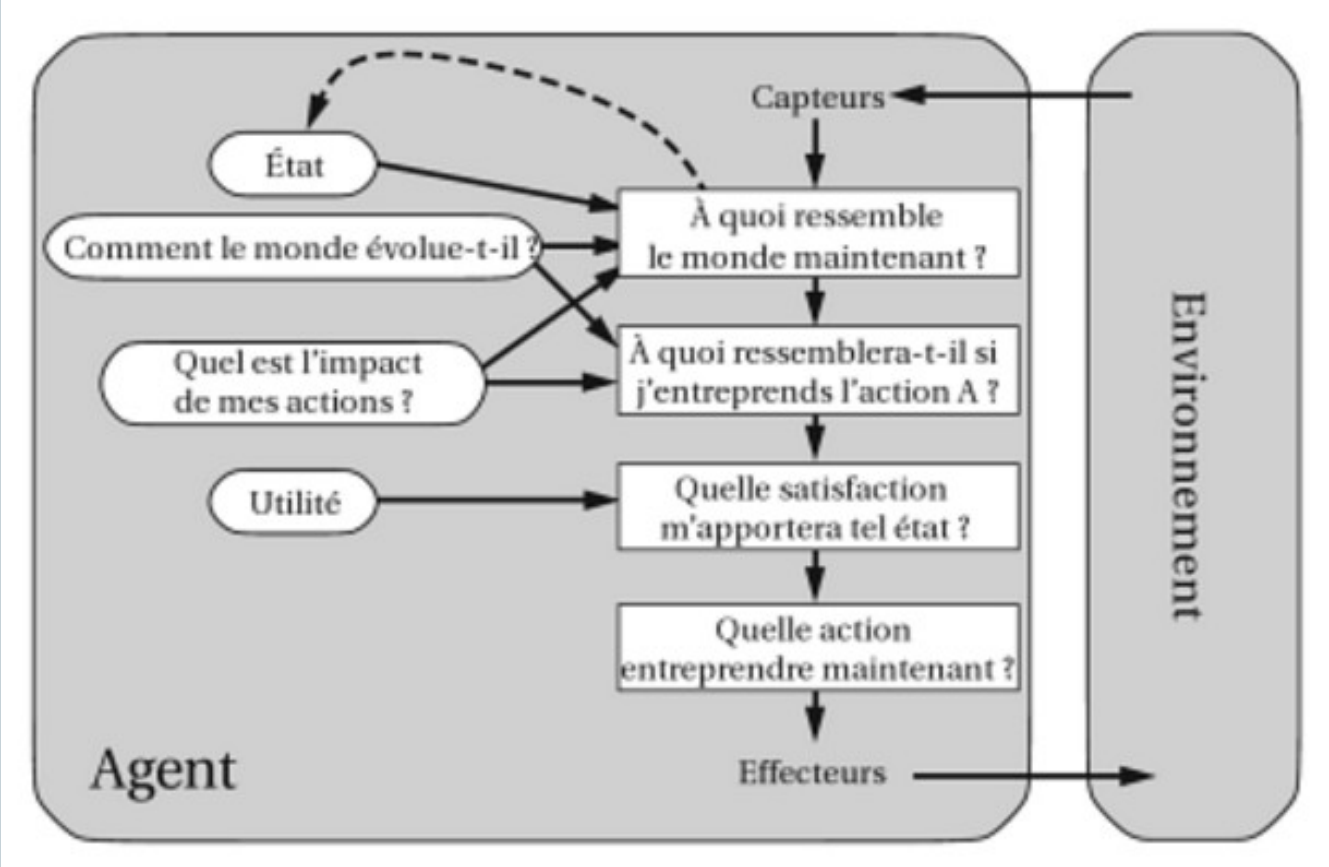

Prise de décision

- Théorie des probabilités
  - Ce qu'un agent devrait croire en s'appuyant sur l'observation
- Théorie de l'utilité
  - Ce que l'agent veut
- ➔ Théorie de la décision synthétise les deux
  - Ce que l'agent devrait faire.
  - Considérer toutes les actions possibles
  - viser le meilleur résultat: maximiser l'utilité espérée

$$EU(a|\mathbf{e}) = \sum_{s'} P(\textsc{Result}(a) = s' \mid a, \mathbf{e})\, U(s')$$

$$action = \operatorname*{argmax}_a EU(a|\mathbf{e})$$

- ➔ Agent rationnel
  - Préférence entre les loteries: L = [p1, S1; p2, S2; . . . pn, Sn]
  - Axiomes simples d'utilité
- Prise de décision simple
  - Problèmes épisodiques

Théorie de l'utilité

- Contraintes de préférences rationnelles
  - $A \succ B$ L'agent préfère A à B
  - $A \sim B$ L'agent est indifférent entre A et B
  - $A \succsim B$ L'agent préfère A à B ou est indifférent
- Préférences raisonnables
  - Ordonnancement Monotonie $A \succ B \Rightarrow (p > q \Leftrightarrow [p, A;\ 1-p, B] \succ [q, A;\ 1-q, B])$
  - Transitivité Décomposabilité $[p, A;\ 1-p, [q, B;\ 1-q, C]] \sim [p, A;\ (1-p)q, B;\ (1-p)(1-q), C]$
  - Continuité $A \succ B \succ C \Rightarrow \exists p\ [p, A;\ 1-p, C] \sim B$
  - Substituabilité $A \sim B \Rightarrow [p, A;\ 1-p, C] \sim [p, B; 1-p, C]$
- Préférences → Utilité
  - $U(A) > U(B) \Leftrightarrow A \succ B$ $U([p_1, S_1; \ldots; p_n, S_n]) = \sum_i p_i U(S_i)$
  - Pas d'échelle absolue ($U'(S) = aU(S) + b$) → normalisation
    - U pire / meilleur ➔ $u_\perp = 0\ et\ u_\top = 1$
      - Calibrage autres utilités
        - → composition avec p et q ajustés jusqu'à indifférence
      - Sécurité: Micromorts vs QALY

Fonctions d'utilité

- Utilité de l'argent = fonction monotone, logarithmique
  - Evitement (+) ou recherche (-) du risque
  - Différence avec valeur espérée = prime d'assurance
  - Utilité espérée
    - Estimations EU (a/e)
    - trop optimiste (erreurs positives) = malédiction de l'optimiseur
    - Modèle de l'erreur d'estimation P(EU)
  - Humain pas rationnel
    - Effet de certitude, Régression fallacieuse, évitement d'ambiguïté, effet de cadrage d'ancrage

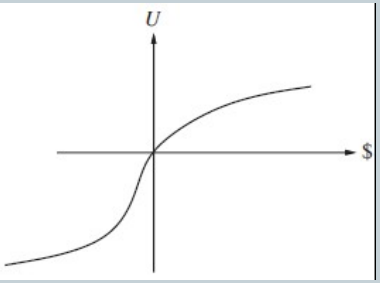

- Multi Attribut
  - Ex: politiques publiques → Vecteur d'assignation
  - Dominance stricte ou stochastique
    - → distributions cumulées

$$\forall x \int_{-\infty}^{x} p_1(x')\,dx' \leq \int_{-\infty}^{x} p_2(x')\,dx'$$

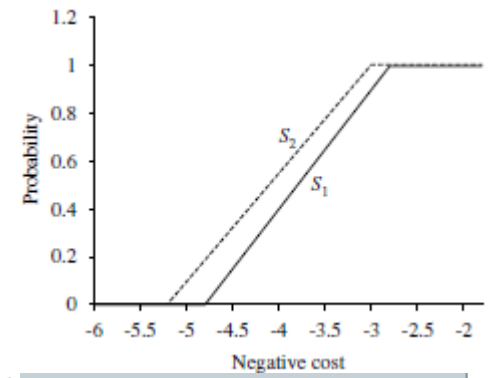

  - Décomposition en $U(x_1, \dots x_n) = F[f_1(x_1), \dots, f_n(x_n)]$
    - Indépendance préférentielle ($<x_1, x_2, x_3>$ vs $<x'_1, x'_2, x_3>$) ou préférentielle mutuelle ({Noise, Cost ,Deaths})
      - Théorème: fonction de valeur additive

$$V(x_1, \dots, x_n) = \sum_i V_i(x_i)$$

    - Avec des loteries: Indépendance des utilités
      - Théorème: Fonction d'utilité multiplicative

$$U = k_1U_1 + k_2U_2 + k_3U_3 + k_1k_2U_1U_2 + k_2k_3U_2U_3 + k_3k_1U_3U_1 + k_1k_2k_3U_1U_2U_3 .$$

Réseaux de décision

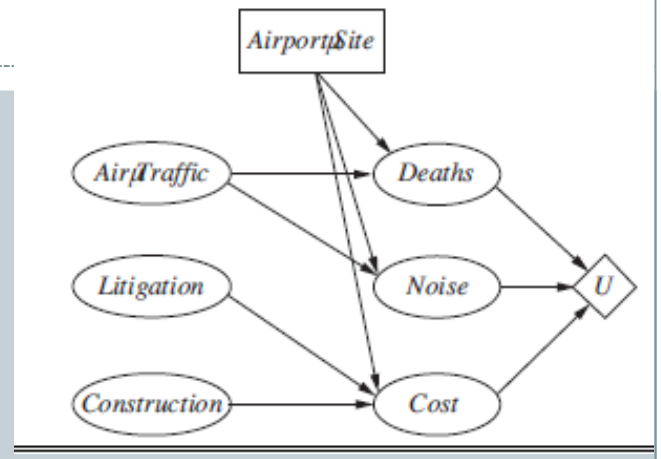

- Diagramme d'influence
  - Construction
    - Nœuds de hasard
    - Nœuds de décision
    - Nœuds d'utilité
  - Simplification
    - Action-Utilité = Q-fonction
- Valeur de l'information
  - Quelles questions poser?
    - Ex: Diagnostique médical
  - Etat de croyance, + profit espéré
    - Ex: Droits de forage
  - Valeur de l'information parfaite (VPI)
    - = Moyenne des U espérées sachant observations
    - VPI≥ 0 & VPI(Ej) + VPI(Ek) ≠ VPI(Ej,Ek) = VPI(Ej) + VPI(Ek/Ej) = VPI(Ek) + VPI(Ej/Ek)
  - Agent-Collecte-Information
    - Si VIP (Ej) > Coût (Ej) → Requète (Ej)
      - Mais algorithme Myope (1 indice)
    - Alternative: considérer plusieurs/plan
      - Souvent humain plutôt que max VIP (examens)
      - Cas particulier: chasse aux trésors
        - Similaire droits de forage: C(x), P(x) indépendants
        - Ordre idéal: i<j => P(i)/ C(i) > P(j)/C(j)

$$\frac{1}{n} \times \frac{(n-1)C}{n} + \frac{n-1}{n} \times \frac{C}{n(n-1)} = C/n$$

$$VPI_{\mathbf{e}}(E_j) = \left(\sum_k P(E_j = e_{jk}|\mathbf{e})\ EU(\alpha_{e_{jk}}|\mathbf{e}, E_j = e_{jk}) \right) - EU(\alpha|\mathbf{e})$$

```
function INFORMATION-GATHERING-AGENT(percept) returns an action
  persistent: D, a decision network

  integrate percept into D
  j ← the value that maximizes VPI(E_j) / Cost(E_j)
  if VPI(E_j) > Cost(E_j)
     return REQUEST(E_j)
  else return the best action from D
```

Système expert

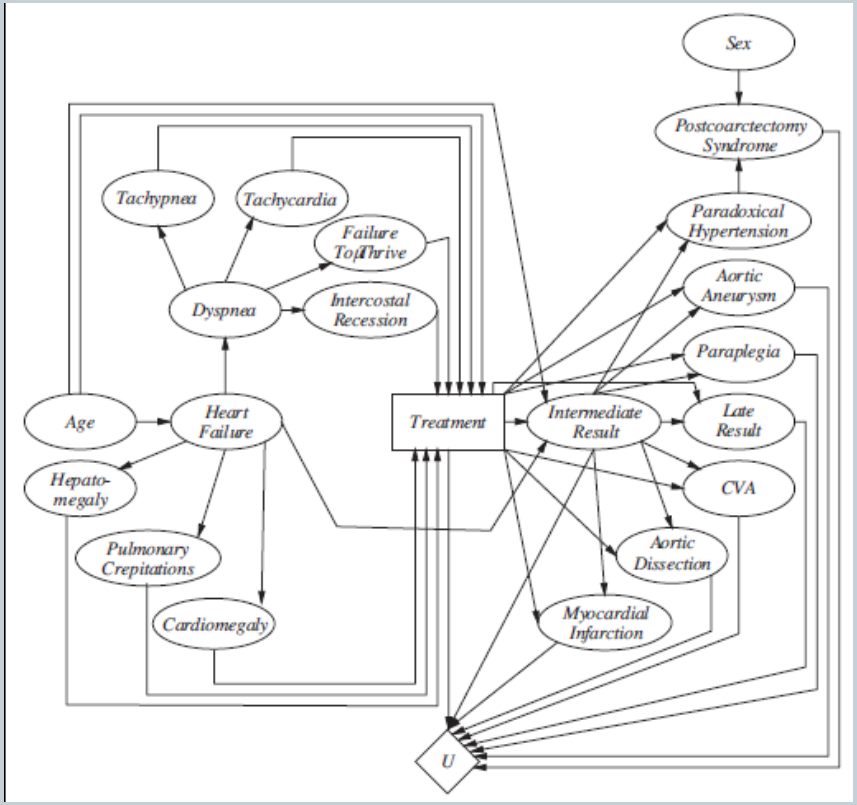

- Développés très tôt
  - Années 50-80
    - Règles → logique → réseaux de décision
  - Militaire, médical, finance
    - Preneur de décision (trader)
    - analyste (quant) → actions
- Conception
  - Modèle causal
    - Simplification (qualitatif)
  - Assignation des probabilités
    - Depuis DB / Experts
  - Assignation des utilités
    - Echelle [0,1], multi attribut
  - Vérification et raffinage
    - Étalon métier (experts)
  - Analyse de sensibilité
    - à de petites modifications
      - ← Probabilités du modèle incertaines
    - → Décision robuste ou « minimax »
      - $a^* = \underset{a}{\operatorname{argmax}}\, min_\theta\, EU(a;\theta)$
    - →ou Hyper-paramétrisation Bayésienne de θ
      - ← Si décision robuste trop conservative
- Préférences inconnues
  - 2 possibilités
  - Préférences incertaines
    - Fonction d'utilité probabiliste
    - → Création d'une variable aléatoire dédié
  - Préférences à affiner
    - Possibilité d'intervention humaine
    - Similaire à VIP
      - Ex: Off-switch game + extensions Bayésiennes

Questions?

Sommaire

- Quantification de l'incertitude
- Raisonnement probabiliste
- Raisonnement probabiliste temporel
- Prise de décision simple
- Prise de décision complexe
  - Politiques, Processus de décision de Markov
  - Théorie de jeux
  - Design de mécanismes
  - Jeux différentiels
- TP: Inférence avec des modèles probabilistes simples et temporels

Prise de décision complexe

- Problèmes de décision séquentiels
  - Planification = cas particulier
  - Entièrement observables
- Processus de décision de Markov (MD
  - Etats s, Actions(s)
  - Modèle de transition P(s'|s,a)
  - Récompense R(s)
    - Ex: +1;-1 (terminal) ; -0,04 (vitesse)
- Solution = **Politique optimale** (π^*)
  - Fournit l'utilité espérée maximale
    - $EU_h([s0, s1, \ldots, sn])$
  - Horizon fini → π^* non-stationnaire
  - Préférences Stationnaires → récompenses
    - Additives: $U_h([s0, s1, s2, \ldots]) = R(s0) + R(s1) + R(s2) + \ldots$
      - Besoin d'une politique appropriée (garantie de finir)
    - Ou escomptées : $U_h([s0, s1, s2, \ldots]) = R(s0) + \gamma R(s1) + \gamma^2 R(s2)$
      - → U bornée, Empirique, monétaire, uncertitude, stationarité
      - Sinon, récompense moyenne

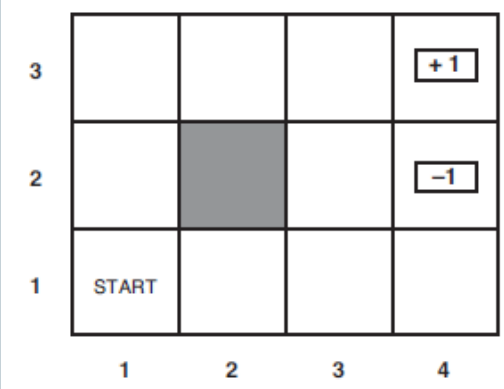

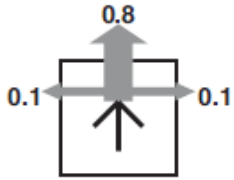

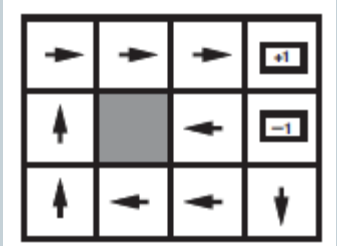

$-0.0221 < R(s) \leq 0$

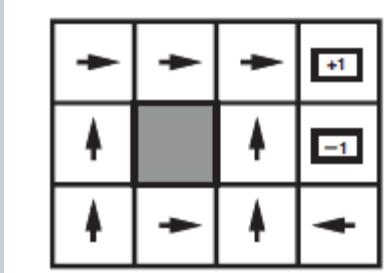

$-0.4278 < R(s) \leq -0.0850$

$$U_h([s_0, s_1, s_2, \ldots]) = \sum_{t=0}^{\infty} \gamma^t R(s_t) \leq \sum_{t=0}^{\infty} \gamma^t R_{\max} = R_{\max}/(1-\gamma)$$

Evaluation des politiques

- Utilité espérée en appliquant **π** depuis l'état s
  - $U^{\pi}(s) = E[\sum_{t=0}^{\infty} \gamma^t R(S_t)]$
- Politique optimale
  - $\pi_s^* = \underset{\pi}{argmax}\, U^{\pi}(s)$
  - π^* indépendant de l'état (escompte)
- Utilité d'un état
  - $U(s) = U^{\pi^*}(s)$
- Maximisation de l'utilité espérée
  - Relation Utilité d'un état vs successeurs
    - = Equation de Bellman
  - Fonction Action-utilité (Q-fonction)
- Algorithmes pour la déterminer
  - Approches itérative (programmation dynamique)
  - Programmation linéaire, méthodes approximatives
- Façonnage de récompenses
  - Comme pour U, R'(s,a,s') = mR(s,a,s')+b ne change pas π^*
  - Shaping theorem: utilisation d'un potentiel
    - Ne change pas π^*
    - Dressage/éducation: guidage = π gloutonne avec potentiel U
- Représentation des MDPs
  - Réseaux de décision dynamiques = RDD + RBD

3	0.812	0.868	0.918	+1
2	0.762		0.660	−1
1	0.705	0.655	0.611	0.388
	1	2	3	4

$$\pi^*(s) = \underset{a \in A(s)}{\operatorname{argmax}} \sum_{s'} P(s' \mid s,a)[R(s,a,s') + \gamma U(s')]$$

$$U(s) = \max_{a \in A(s)} \sum_{s'} P(s' \mid s,a)[R(s,a,s') + \gamma U(s')]$$

$$\begin{aligned} Q(s,a) &= \sum_{s'} P(s' \mid s,a)[R(s,a,s') + \gamma U(s')] \\ &= \sum_{s'} P(s' \mid s,a)[R(s,a,s') + \gamma \max_{a'} Q(s',a')] \end{aligned}$$

$$R'(s,a,s') = R(s,a,s') + \gamma\Phi(s') - \Phi(s)$$

Méthodes itératives

- Itération de la valeur
  - On démarre de U_0 arbitraire
  - Mise à jour de Bellman

$$U_{i+1}(s) \leftarrow \max_{a \in A(s)} \sum_{s'} P(s' \mid s,a)[R(s,a,s') + \gamma U_i(s')]$$

  - Convergence par contraction de facteur γ
    - ||BUi –U|| ≤ γ ||Ui – U|| (error dans l'estimation)
      - Dépend peu de l'erreur cible (+), mais beaucoup de γ (- prêt de 1 → myope)
  - Perte de politique
    - politique d'utilité espérée maximale (MEU) ||Uπi – U|| → 0
    - π converge souvent avant U
- Itération de la politique
  - On démarre de π_0 arbitraire
  - Exécute alternativement 2 étapes:
    - Evaluation de la politique
      - calcule Ui =U^{π}_{i} pour les espaces simples
      - Sinon MAJ de Bellmann simplifiée
    - Amélioration de la politique
      - calcule π_{i+1} Itération de politique modifiée
    - On répète Bellmann simplifiée k fois (itération de valeur simplifiée)

$$U_i(s) = \sum_{s'} P(s' \mid s, \pi_i(s))[R(s, \pi_i(s), s') + \gamma U_i(s')]$$

$$U_{i+1}(s) \leftarrow \sum_{s'} P(s' \mid s, \pi_i(s))[R(s, \pi_i(s), s') + \gamma U_i(s')]$$

- Version asynchrone
  - Liberté de choisir les état à mettre à jour →Utile avec de bonnes heuristiques
  - Ex: Reinforce

Autres méthodes

- Programmation linéaire
  - Bellman → sommes et max → problème d'optimisation
  - Minimisation U(s) avec $U(s) \geq \sum_{s'} P(s' \mid s,a)[R(s,a,s') + \gamma U(s')]$
  - Mais souvent complexité mauvaise (nombreux états/actions)
- Algorithmes itératifs en ligne
  - Méthodes offline souvent impraticables (cf. jeux)
  - Ex: Expectiminimax: Arbre minimax + nœuds de chance
    - Profondeur bornée (via γ) ainsi que branchement (via sampling)
  - →Programmation dynamique en temps réel (RTDP)
    - (décomposition en sous problèmes ➔ Graphe = sous-MPD)
  - Grands espaces → méthodes de Monte-Carlo
- Problèmes de bandits manchots
  - Machines à sous à n bras aux probabilités de gains distinctes (MAP ≈MDP)
  - → Compromis Exploration/Exploitation
    - Ex: traitements covid-19
  - Coefficient de Gittins
    - une seule machine à sous: Comparaison avec récompense stationnaire λ
      - → stopping time T
    - Calcul: Cas simple: utilisation d'un Restart MDP (indifférence à T)
    - Approximations (MPD tronqué)

$$\lambda = \max_{T>0} \frac{E\left(\sum_{t=0}^{T-1} \gamma^t R_t\right)}{E\left(\sum_{t=0}^{T-1} \gamma^t\right)}$$

PDMPOs / POMDPs

- Partiellement observables
  - Modèles de capteurs (HMM)
  - Cf. exploration et planification non déterministe
    - → Etats de croyance (distribution)
    - → MAJ = Filtrage (cf Kalman)

$$b'(s') = \alpha\, P(e \mid s') \sum_{s} P(s' \mid s, a) b(s)$$

  - Itération de la valeur pour PDMPOs
    - = Plan conditionnel
    - Divise l'espace de croyance en régions
- Agents en ligne
  - Modèles de transition / capteur
  - Nœuds de décision et d'utilité
- ➔ Réseau de décision dynamique
  - Mise à jour de l'état de croyance≈ *Expectiminimax*
  - Approximations: Filtrage particulaire + Monte Carlo playouts
    - Monte Carlo planning = POMCP

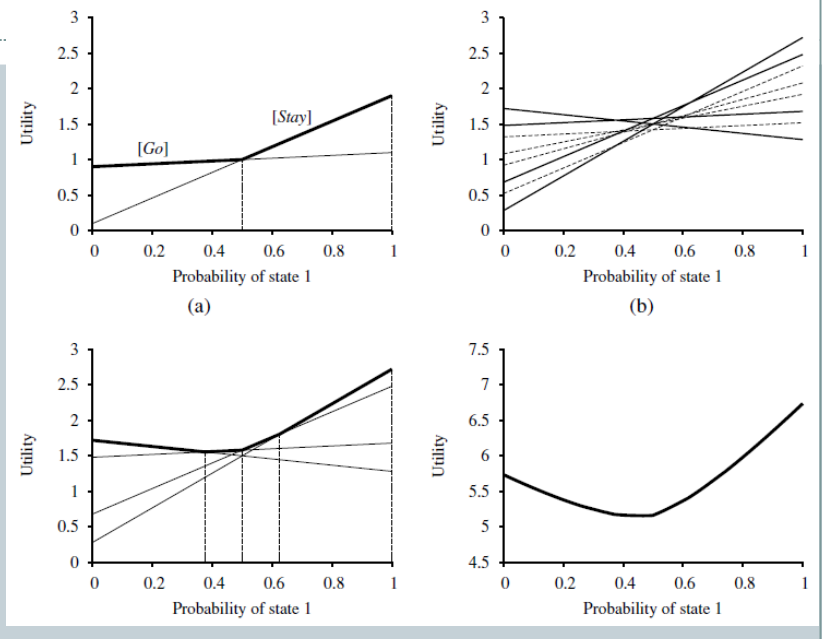

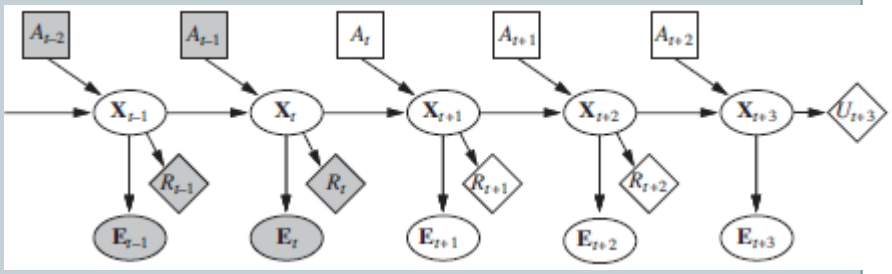

Questions?

Plan du cours

I. Introduction
II. Résolution de problèmes
III. Bases de connaissances et logique
IV. Incertitude et modèles probabilistes
V. Théorie des jeux
VI. Apprentissage
VII. Traitement du langage naturel
VIII. Présentation projets

Projets de groupe

- Moteur de recherche augmenté par le raisonnement et le langage naturel
  - Grammaire et sémantique des contenus et des requêtes. Lucene.Net, OpenNLP, SharpRDF, FOL
- Conception de bots de services sur réseaux sociaux
  - Chat Bots, AIML, Reddit et agents de service, NLP, RDF, APIs
- Conception d'un modèle d'inférence pour l'analyse de sentiment
  - Conception d'un modèle probabiliste, Infer.Net, démarche expérimentale, Reddit
- Création d'une plateforme sémantique LDP à partir d'un index structuré.
  - Structuration et ouverture des données = Linked Data. Lucene.Net, SharpRDF
- Résolution de Captchas par deep learning
  - Apprentissage via un Adapteur DNN, Réseaux de dernières génération. TensorFlow, CNTK, Encog
- Entrainement de stratégies de trading algorithmiques sur crypto monnaies.
  - Expérience DNN Bitcoin, Encog et machine learning
- Amélioration par l'apprentissage d'un agent joueur de Go simple
  - Le Go et l'IA, Récentes avancées. Go Traxx
- Evolution de vaisseaux spatiaux par algorithmes génétiques dans le jeu de la vie.
  - Approches évolutionnistes, automates cellulaires, Bac a sable. Golly, Encog
- Pilotage d'un cluster de cache distribué pour le portage d'applications dans le Cloud
  - Caches distribués, scaling, stratégies et clustering. Redis

Merci

JEAN-SYLVAIN BOIGE
JSBOIGE@MYIA.ORG