Incertitude et modèles probabilistes

Intelligence Artificielle - IV

Quantification de l'incertitude, Raisonnement probabiliste, Prise de décision

- Quantification de l'incertitude
- Raisonnement probabiliste
- Prise de décision

Plan du cours

- Introduction
- Résolution de problèmes
- Bases de connaissances et logique
- **Incertitude et modèles probabilistes** ← *vous êtes ici*
- Théorie des jeux
- Apprentissage
- Traitement du langage naturel
- Présentation projets

Sommaire

- **Quantification de l'incertitude**
  - Incertitude
  - Probabilités
  - Syntaxe et sémantique
  - Inférence
  - Indépendance et règle de Bayes
- **Raisonnement probabiliste**
  - Réseaux Bayésiens
  - Modèles de Markov Cachés (HMM)
  - Raisonnement probabiliste temporel
- **Théorie de la décision**
  - Prise de décision simple
  - Prise de décision complexe (MDP)

Incertitude

- **At = partir pour l'aéroport t minutes avant le vol**
  - Est-ce que At me permettra d'avoir mon vol?
- **Problèmes**
  - Observabilité partielle (état de la route, plans des autres etc.)
  - Capteurs bruités (Bison Futé)
  - Incertitude sur les résultats des actions (pneu crevé, etc.)
  - Complexité de la modélisation et la prévision du trafic
- **Une approche purement logique**
  - Risque d'être incorrecte (A25 devrait suffire…)
  - Conduira à des conclusions trop faibles pour la prise de décision
  - A25 suffira s'il n'y a pas d'accident sur le pont et il ne pleut pas et mes pneus ne crèvent pas etc. = problème de la qualification logique
  - A1500 conduira raisonnablement au but, mais il me faudra dormir à l'aéroport

Méthodes face à l'incertitude

- **Logique par défaut ou non monotone**
  - On suppose que ma voiture n'a pas de pneu crevé
  - On suppose que A25 fonctionne à moins d'une indication contradictoire
  - Problèmes:
    - Quelles sont les suppositions raisonnables?
    - Comment gérer la contradiction?
- **Règles avec facteurs vagues**
  - A25 |→0.3 devrait suffire
  - Arroseur |→ 0.99 Herbe Mouillée
  - Herbe Mouillée |→ 0.7 Pluie
  - Problèmes: combinaisons (e.g, l'arroseur cause la pluie?)
- **Probabilités**
  - Représente le degré de croyance de l'agent

Probabilité

- **Les assertions probabilistes résument les effets de:**
  - La paresse: on n'énumère pas toutes les exceptions, qualifications etc.
  - L'ignorance théorique et pratique: Il nous manque des faits pertinents, les conditions initiales etc.
- **Probabilités subjectives**
  - Elles concernent les propositions de l'état de connaissance de l'agent
  - P(A25 | pas d'incident rapporté) = 0.06
  - Ce ne sont pas des assertions sur le monde
  - Les probabilités des propositions changent avec de nouvelles observations
  - P(A25 | pas d'incident rapporté, 05h00) = 0.15

Prendre des décisions dans l'incertitude

- **Supposons que je crois:**
  - P(A25 j'arrive à temps | ...) = 0.04
  - P(A90 j'arrive à temps | ...) = 0.70
  - P(A120 j'arrive à temps | ...) = 0.95
  - P(A1440 j'arrive à temps | ...) = 0.9999
- **Quelles actions choisir?**
  - Dépend des préférences entre rater le vol et attendre
  - La théorie de l'utilité peut représenter et inférer les préférences
  - Théorie de la décision = probabilités + théorie de l'utilité

Syntaxe

- **Elément de base: La variable aléatoire**
  - Des mondes possibles leur donnent des assignations (cf logique propositionnelle)
- **Domaines:**
  - Variables aléatoires Booléennes:
    - E.g. Carie (est-ce que j'ai une carie?)
  - Variables discrètes:
    - E.g. Le Temps est un parmi <ensoleillé, nuageux, pluvieux, neigeux>
    - Valeurs des domaines exhaustives et mutuellement exclusives
- **Propositions:**
  - Proposition élémentaire construites par assignation
    - E.g. Temps = ensoleillé, Carie = faux (¬Carie)
  - Proposition complexe formée par élémentaires + connecteurs logiques
    - E.g. Temps = ensoleillé ∧ Carie = faux

Axiomes des probabilités

- **Pour toutes propositions A, B:**
  - $0 \leq P(A) \leq 1$
  - P(vrai) = 1 and P(faux) = 0
  - $P(A \vee B) = P(A) + P(B) - P(A \wedge B)$

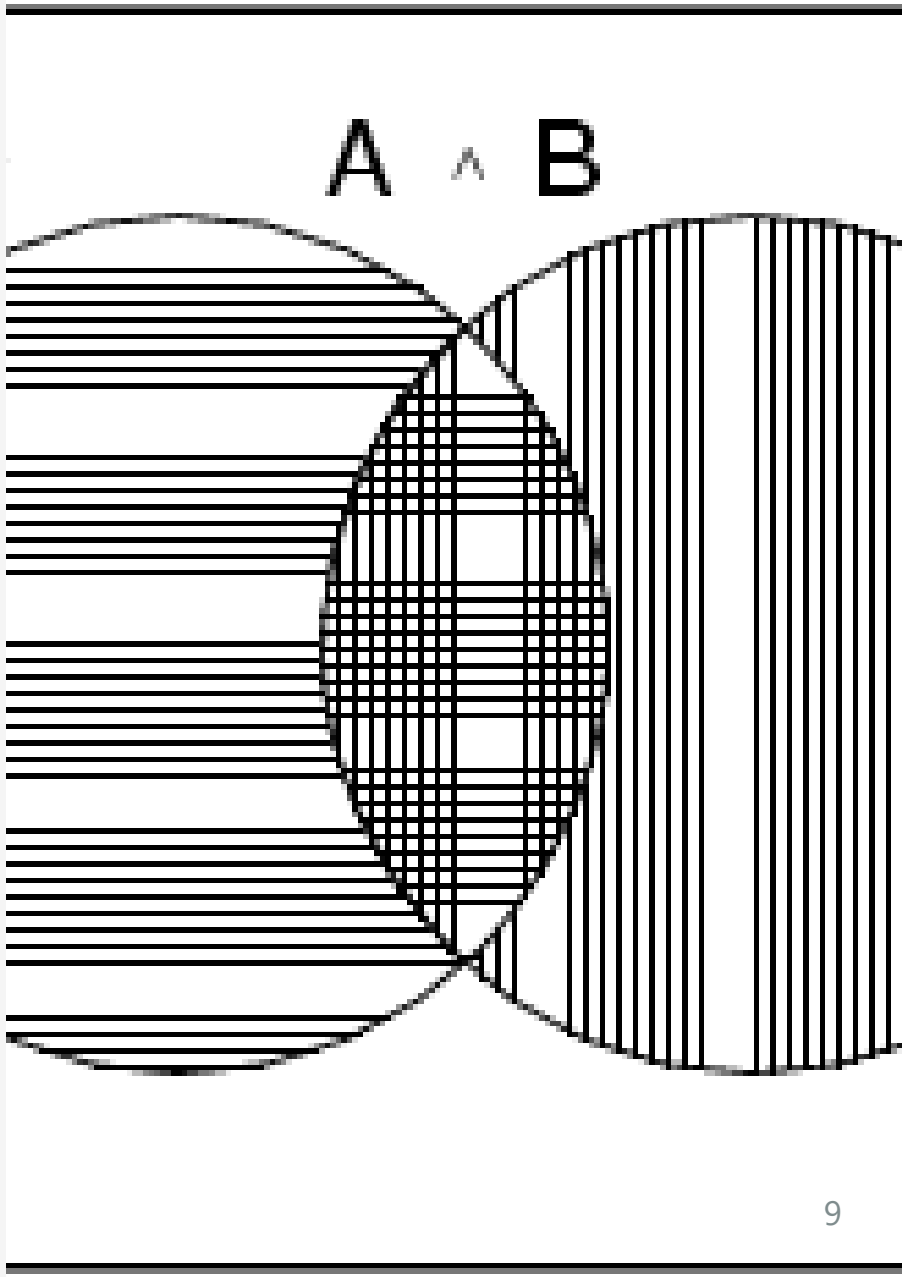

Probabilités a priori

- **Probabilités inconditionnelles ou a priori de propositions**
  - E.g. P(Carie = vrai) et P(Temps = ensoleillé) = 0.72
  - État de croyance a priori en l'absence d'observation
- **La distribution de probabilité donne les valeurs pour toutes les assignations:**
  - P(Temps) = <0.72, 0.1, 0.08, 0.1> (normalisées, i.e. la somme vaut 1)
- **Distribution de probabilités conjointe**
  - Pour des variables aléatoires, la probabilité de chacun de leurs évènements atomiques
  - P(Temps, Carie) = une matrice 4 x 2

Temps =	Soleil	Pluie	Nuages	Neige
Carie = true	0.144	0.02	0.016	0.02
Carie = false	0.576	0.08	0.064	0.08

- Chaque question sur un domaine peut être répondue par la distribution conjointe

Probabilités des variables continues

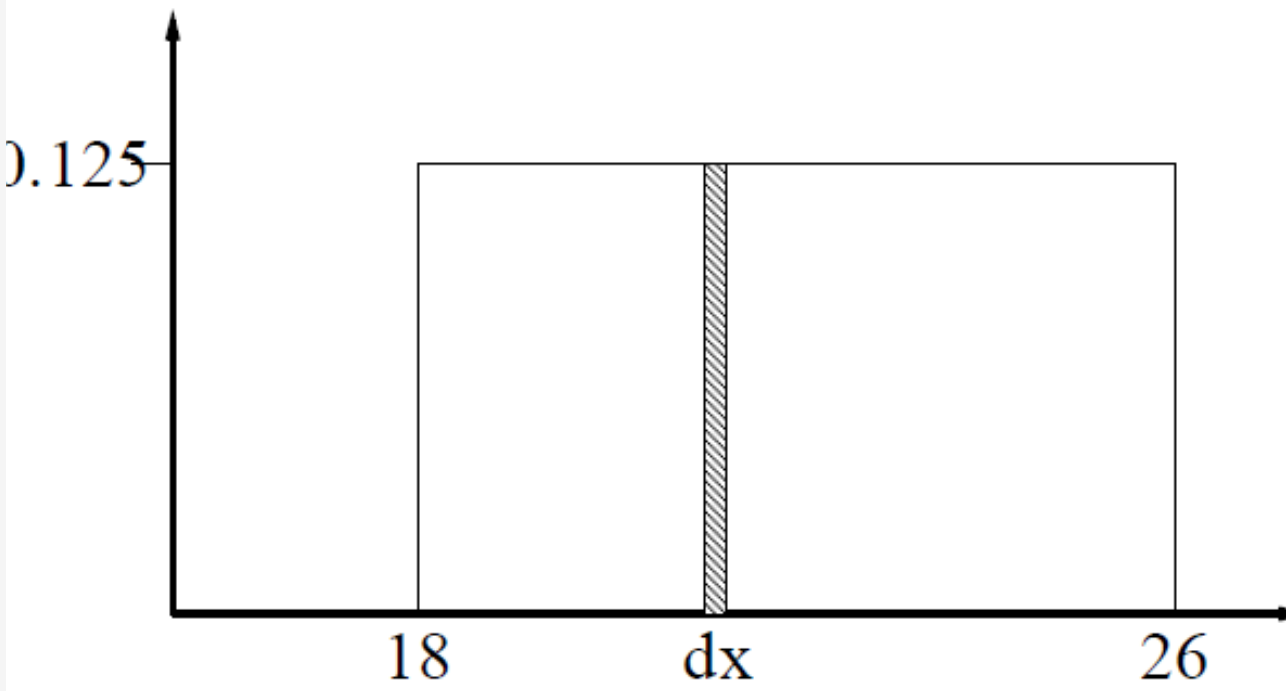

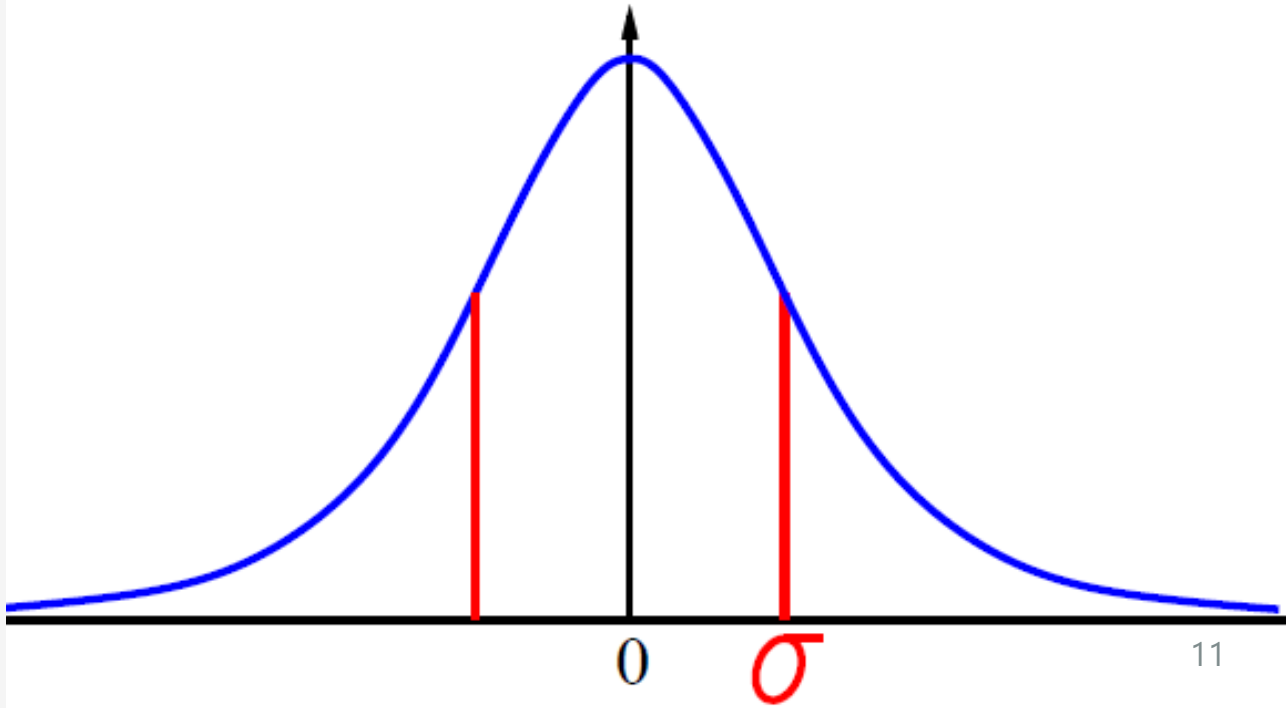

Probabilités conditionnelles

- **Probabilités conditionnelles ou a posteriori**
  - E.g. P(Carie | MalDeDent) = 0.8
  - i.e. "sachant uniquement" Mal De Dent
- **Notation pour distributions conditionnelles:**
  - P(Carie | MalDeDent) = vecteur à 2 elts de vecteurs à 2 elts
- **Si l'on sait plus**
  - P(Carie | MalDeDent, Carie) = 1
- **Des observations peuvent être non pertinentes**
  - Permettent la simplification
  - P(Carie | MalDeDent, ensoleillé) = P(Carie | MalDeDent) = 0.8

Règles de calcul probabiliste

- **Règle du produit**
  - $P(a \wedge b) = P(a \mid b)\, P(b) = P(b \mid a)\, P(a)$
  - Soit $P(a \mid b) = P(a \wedge b) / P(b)$ si $P(b) > 0$
  - $P(\text{Temps}, \text{Carie}) = P(\text{Temps} \mid \text{Carie})\, P(\text{Carie})$ produit terme à terme, pas matriciel
- **Règle de chaînage = dérivation successive**
  - $P(X_1, \ldots, X_n) = P(X_1, \ldots, X_{n-1})\, P(X_n \mid X_1, \ldots, X_{n-1})$
  - $= P(X_1)\, P(X_2 \mid X_1) \ldots P(X_{n-1} \mid X_1, \ldots, X_{n-2})\, P(X_n \mid X_1, \ldots, X_{n-1})$
  - $= \pi^n_{i=1}\, P(X_i \mid X_1, \ldots, X_{i-1})$

Inference par enumeration

- **Probabilités conjointes:**
  - Proposition φ → sommer les évts atomiques où elle est vraie
  - P(φ) = Σ_{ω:ω⊨φ} P(ω)
  - P(MalDeDents) = 0.108 + 0.012 + 0.016 + 0.064 = 0.2
- **Conditionnelles**
  - **P(Carie | MalDeDents)**
    - = P(Carie ∧ MalDeDents) / P(MalDeDents)
    - = (0.016 + 0.064) / (0.108 + 0.012 + 0.016 + 0.064)
    - = 0.4

toothache		¬ *to*
catch	¬ *catch*	*catch*
.108	.012	.072
.016	.064	.144

toothache		¬ *to*
catch	¬ *catch*	*catch*
.108	.012	.072
.016	.064	.144

Normalisation

- **Dénominateur = constante de normalisation α**
  - P(Carie | MalDeDents) = α P(Carie, MalDeDents), α = 1 / P(MalDeDents)
  - = α [P(Carie, MalDeDents, Croche) + P(Carie, MalDeDents, ¬Croche)]
  - = α [<0.108, 0.016> + <0.012, 0.064>]
  - = α <0.12, 0.08> = <0.6, 0.4>
- **Idée générale: calculer la distribution**
  - Sur la variable de requête Y
  - En fixant les variables d'observations E
  - En sommant sur les variables cachées H
  - Distribution a posteriori conjointe: $P(Y \mid E = e) = \alpha P(Y, E = e) = \alpha \Sigma_h P(Y, E = e, H = h)$
- **Problèmes:**
  - Complexité au pire en $O(d^n)$ où d est la plus grande arité (nb d'arguments)

	¬ catch	
	.012	
	.064	

Indépendance

- **A et B sont indépendants si et seulement si**
  - $P(A \mid B) = P(A)$ ou $P(B \mid A) = P(B)$ ou $P(A, B) = P(A)\,P(B)$
- **Exemple:**
  - P(MalDeDent, Croche, Carie, Temps) = P(MalDeDent, Croche, Carie) P(Temps)
- **Impact sur la complexité**
  - Pour n lancés de pièces indépendants: $O(2^n) \rightarrow O(n)$
  - Puissant mais rare
  - Ex du dentiste: des centaines de variables dépendantes

Indépendance conditionnelle

- **Croche est conditionnellement indépendant de Mal De Dents:**
  - (1) P(Croche | MalDeDent, Carie) = P(Croche | Carie)
  - (2) P(Croche | MalDeDent, ¬Carie) = P(Croche | ¬Carie)
  - P(Croche | MalDeDent, Carie) = P(Croche | Carie)
  - P(MalDeDent | Croche, Carie) = P(MalDeDent | Carie)
  - P(MalDeDent, Croche | Carie) = P(MalDeDent | Carie) P(Croche | Carie)
- **Utilisation de la règle de chaînage:**
  - P(MalDeDent, Croche, Carie) = P(MalDeDent | Carie) P(Croche | Carie) P(Carie)
- **Réduction de la complexité:**
  - Peut réduire depuis la distribution conjointe de $O(2^n)$ à $O(n)$
  - Notre connaissance la plus basique et robuste en environnement incertain

Règle de Bayes

- **Règle du produit:**
  - $P(a \wedge b) = P(a \mid b)\, P(b) = P(b \mid a)\, P(a)$
  - → Règle de Bayes
  - $P(a \mid b) = P(b \mid a)\, P(a) / P(b)$
- **Sous forme de distribution:**
  - $P(Y \mid X) = P(X \mid Y)\, P(Y) / P(X) = \alpha\, P(X \mid Y)\, P(Y)$
- **Utile pour déterminer les probabilités de diagnostic depuis les probabilités causales**
  - $P(\text{Cause} \mid \text{Effet}) = P(\text{Effet} \mid \text{Cause})\, P(\text{Cause}) / P(\text{Effet})$
- **Ex: méningite, nuque douloureuse:**
  - $P(m \mid s) = P(s \mid m)\, P(m) / P(s) = 0.8 \times 0.0001 / 0.1 = 0.0008$
  - La probabilité a posteriori est encore très faible

Bayes et indépendance conditionnelle

- **Exemple:**
  - $P(Carie \mid MalDeDents \wedge croche)$
  - $= \alpha\, P(MalDeDents \wedge croche \mid Carie)\, P(Carie)$
  - $= \alpha\, P(MalDeDent \mid Carie)\, P(Croche \mid Carie)\, P(Carie)$
- **C'est un exemple de modèle Bayesien naïf**
  - $P(Cause, Effet_1, \ldots, Effet_n) = P(Cause)\, \pi_i\, P(Effet_i \mid Cause)$
  - Le nombre de paramètres est linéaire en n

Résumé

- **Les probabilités sont un formalisme rigoureux pour la connaissance incertaine**
- **La distribution conjointe de probabilité spécifie la probabilité de chaque évènement atomique**
- **Les questions peuvent être répondues en sommant sur les évènements atomiques**
- **Pour des domaines non triviaux, on doit trouver un moyen de réduire la taille conjointe**
  - L'indépendance et l'indépendance conditionnelle fournissent de bons outils

Questions?

Sommaire

- Quantification de l'incertitude
- **Raisonnement probabiliste**
  - Réseaux Bayésiens
  - Domaines experts simples
- Raisonnement probabiliste temporel
- Prise de décision simple
- Prise de décision complexe

Réseaux Bayésiens

- **Une notation simple, graphique**
  - Pour les assertions d'indépendance conditionnelle
  - Et pour la spécification compacte d'une distribution conjointe complète
- **Syntaxe:**
  - Un ensemble de nœuds, un par variable
  - Un graphe dirigé acyclique (lien ≈ "influences directes")
  - Une distribution conditionnelle pour chaque nœud, étant donné ses parents:
    - $P(X_i \mid Parents(X_i))$
- **Dans le cas le plus simple:**
  - Une distribution conditionnelle est représentée par une table de probabilités conditionnelles (CPT)
  - Donnant la distribution en X_i pour chaque combinaison de valeur parente

Example

- **La topologie du réseau encode les assertions d'indépendance conditionnelle:**
  - Weather est indépendant des autres variables
  - Toothache et Catch sont conditionnellement indépendants, étant donné Cavity

Exemple

- **Mise en situation:**
  - "Au travail, mon voisin John m'appelle pour me prévenir que mon alarme sonne, mais ma voisine Marie n'appelle pas. Parfois elle est déclenchée par de petits tremblements de terre. Y a-t'il un voleur?"
- **Variables:**
  - Burglary, Earthquake, Alarm, JohnCalls, MaryCalls
- **La topologie de réseau reflète la connaissance "causale":**
  - A burglar can set the alarm off
  - An earthquake can set the alarm off
  - The alarm can cause Mary to call
  - The alarm can cause John to call

Example (suite)

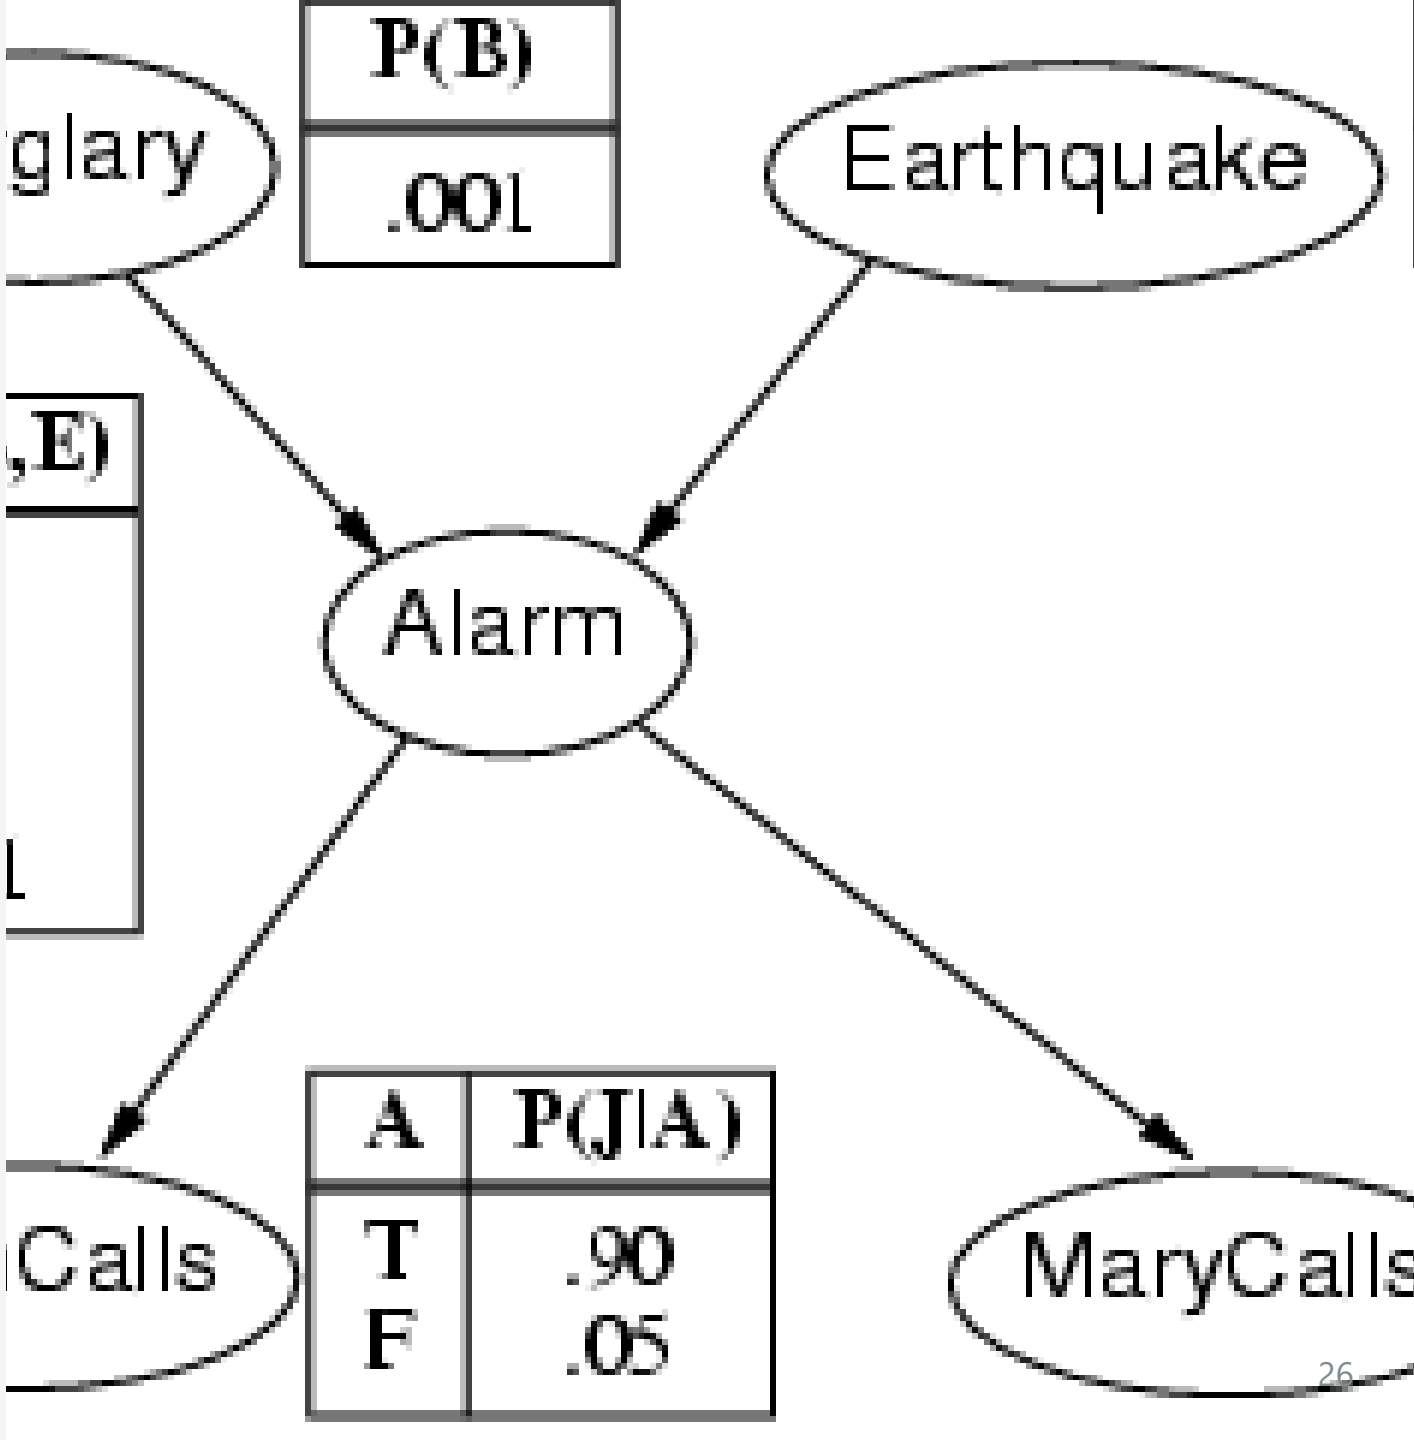

Compacité

- **Un CPT pour les booléens X_i avec k Booléens parents a 2^k lignes pour les combinaisons de valeurs parents**
  - Chaque ligne nécessite un nombre p pour X_i = true
  - (le nombre pour X_i = false est juste 1-p)
- **Si chaque variable n'a pas plus de k parents, le réseau complet nécessite $O(n \cdot 2^k)$ nombres**
  - I.e., croît linéairement en n, vs. $O(2^n)$ pour la distribution conjointe complète
- **Pour le réseau burglary:**
  - 1 + 1 + 4 + 2 + 2 = 10 nombres (vs. $2^5 - 1 = 31$)

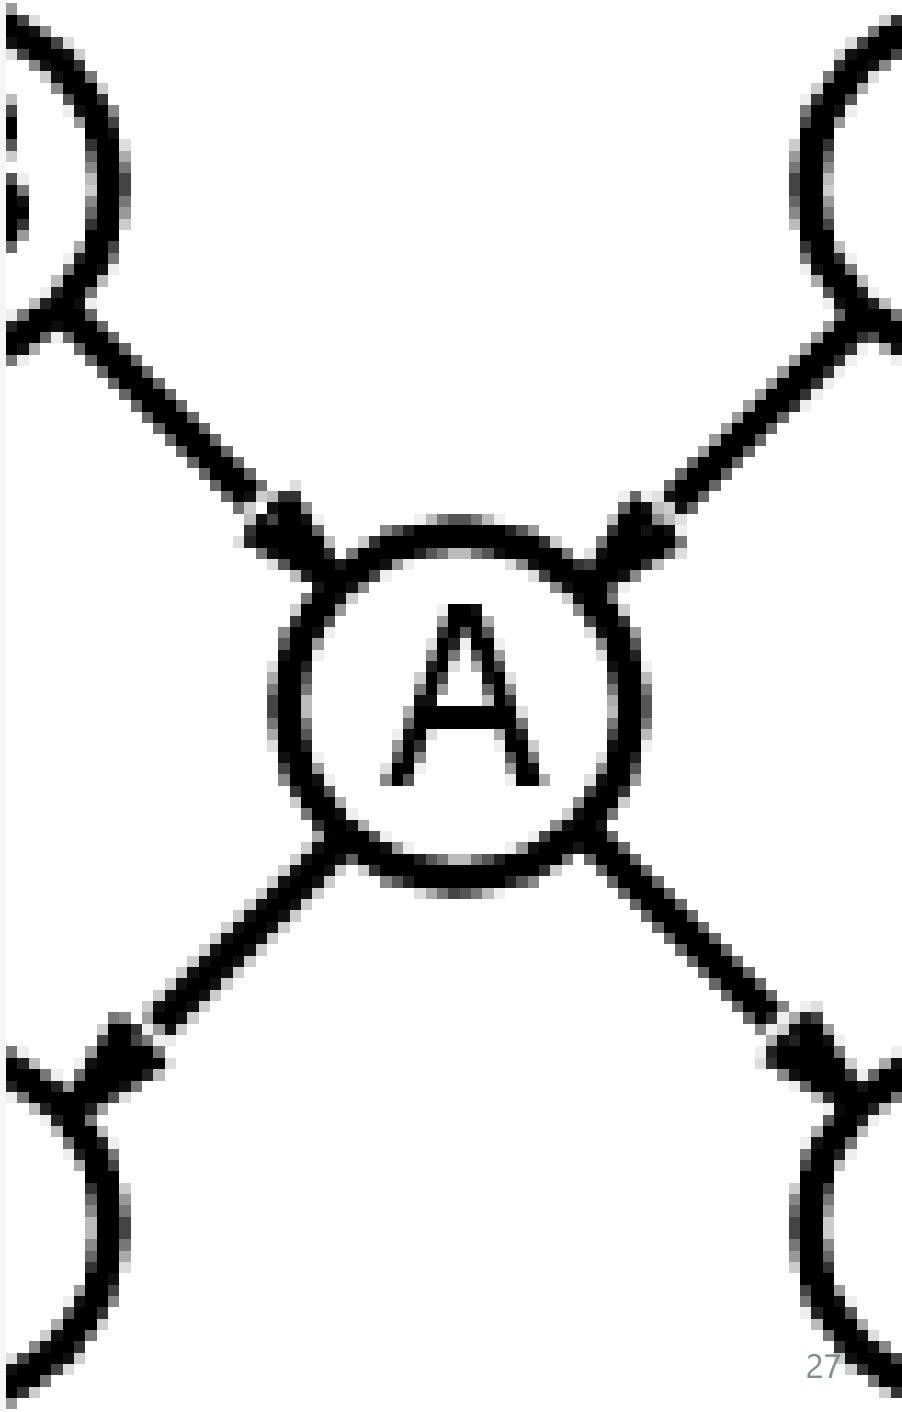

Sémantiques

- **La distribution conjointe complète est définie par le produit des distributions conditionnelles locales:**
  - $P(X_1, \ldots, X_n) = \pi^n_{i=1} P(X_i \mid Parents(X_i))$
- **Exemple:**
  - $P(j \wedge m \wedge a \wedge \neg b \wedge \neg e)$
  - $= P(j \mid a)\, P(m \mid a)\, P(a \mid \neg b, \neg e)\, P(\neg b)\, P(\neg e)$

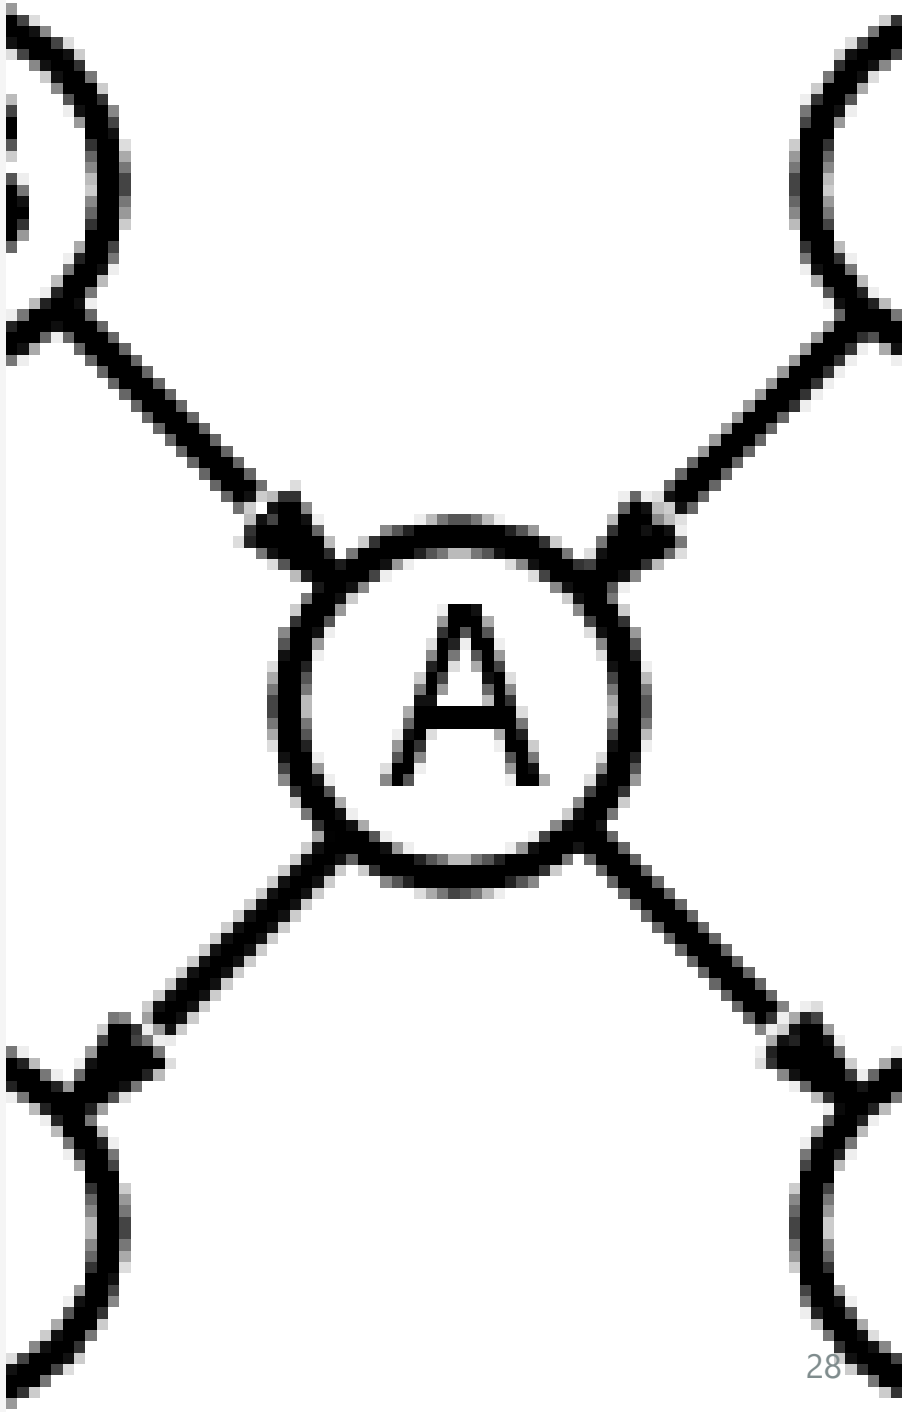

Construction de réseaux Bayésiens

- **1. On choisit un ordre de variables $X_1, \ldots, X_n$**
- **2. De i = 1 à n**
  - On ajoute X_i au réseau
  - On sélectionne les parents de $X_1, \ldots, X_{i-1}$ tels que
  - $P(X_i \mid Parents(X_i)) = P(X_i \mid X_1, \ldots, X_{i-1})$
- **Ce choix de parents garantit:**
  - $P(X_1, \ldots, X_n) = \pi^n_{i=1} P(X_i \mid X_1, \ldots, X_{i-1})$ (règle de chaîne)
  - $= \pi^n_{i=1} P(X_i \mid Parents(X_i))$ (par construction)

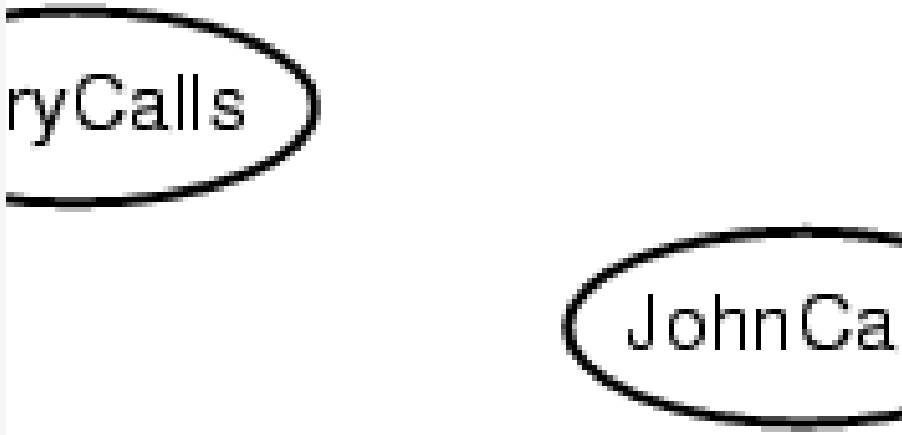

Exemple

- Supposons qu'on choisisse l'ordre M, J, A, B, E
  - P(J | M) = P(J)?

Exemple

- Supposons qu'on choisisse l'ordre M, J, A, B, E
  - P(J | M) = P(J)?
  - Non
  - P(A | J, M) = P(A | J)? P(A | J, M) = P(A)?

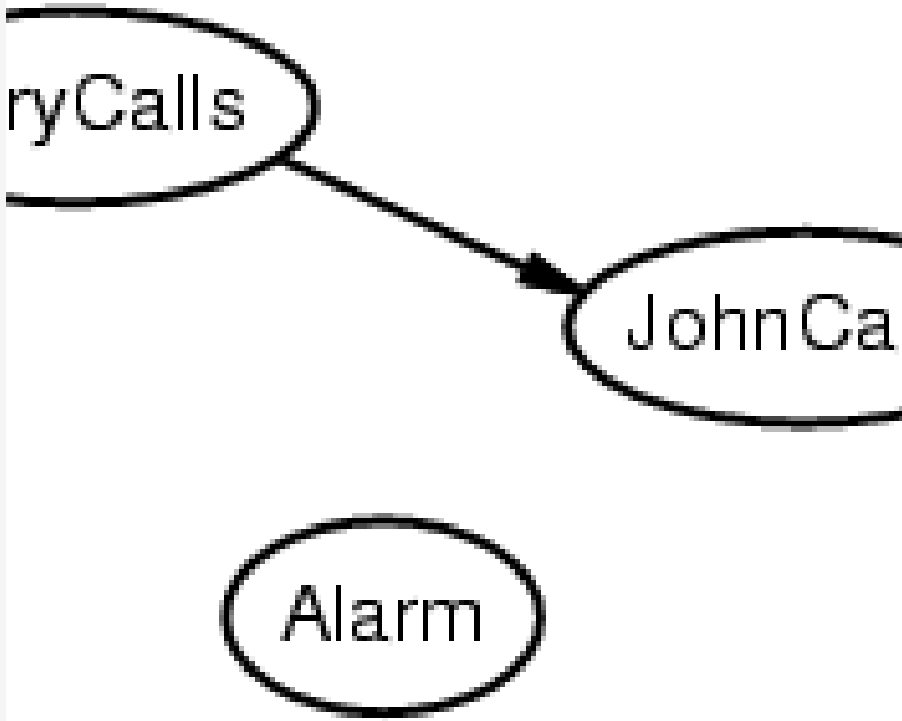

Exemple

- Supposons qu'on choisisse l'ordre M, J, A, B, E
  - P(J | M) = P(J)?
  - Non
  - P(A | J, M) = P(A | J)? P(A | J, M) = P(A)? Non
  - P(B | A, J, M) = P(B | A)?
  - P(B | A, J, M) = P(B)?

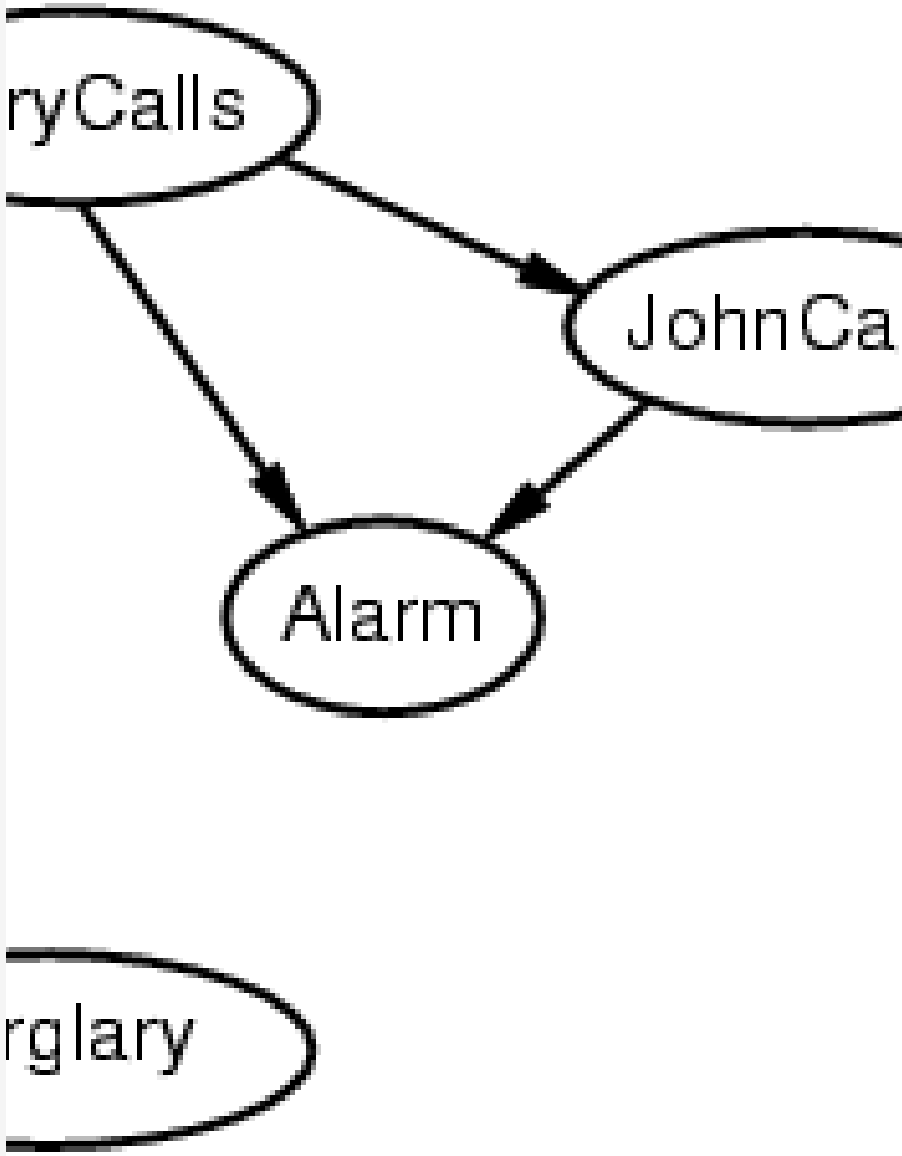

Exemple

- Supposons qu'on choisisse l'ordre M, J, A, B, E
  - P(J | M) = P(J)?
  - No
  - P(A | J, M) = P(A | J)? P(A | J, M) = P(A)? No
  - P(B | A, J, M) = P(B | A)? Yes
  - P(B | A, J, M) = P(B)? No
  - P(E | B, A, J, M) = P(E | A)?
  - P(E | B, A, J, M) = P(E | A, B)?

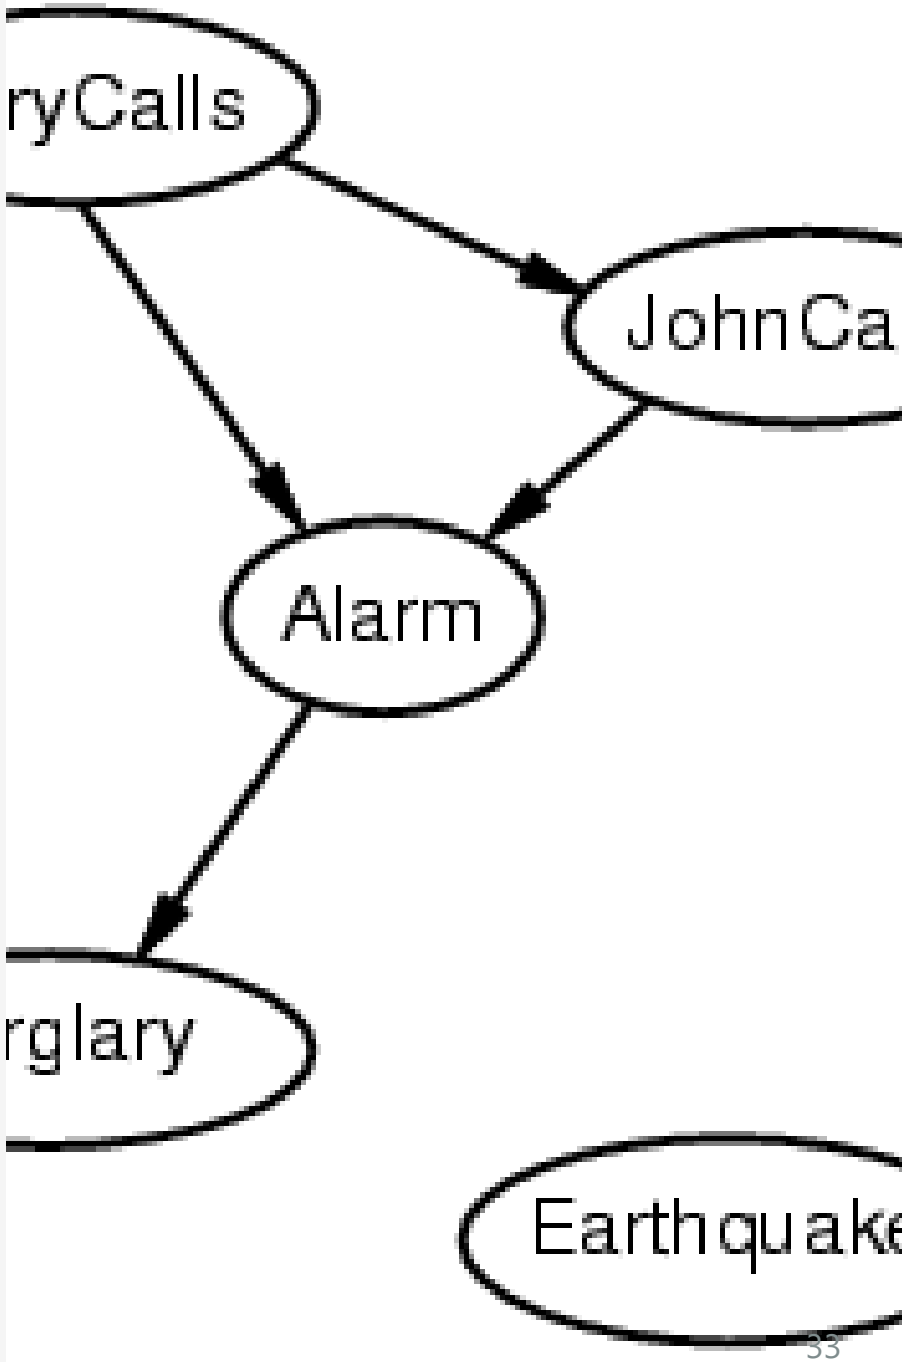

Exemple

- Supposons que nous choisissons l'ordre M, J, A, B, E
  - P(J | M) = P(J)?
  - No
  - P(A | J, M) = P(A | J)? P(A | J, M) = P(A)? No
  - P(B | A, J, M) = P(B | A)? Yes
  - P(B | A, J, M) = P(B)? No
  - P(E | B, A, J, M) = P(E | A)? No
  - P(E | B, A, J, M) = P(E | A, B)? Yes

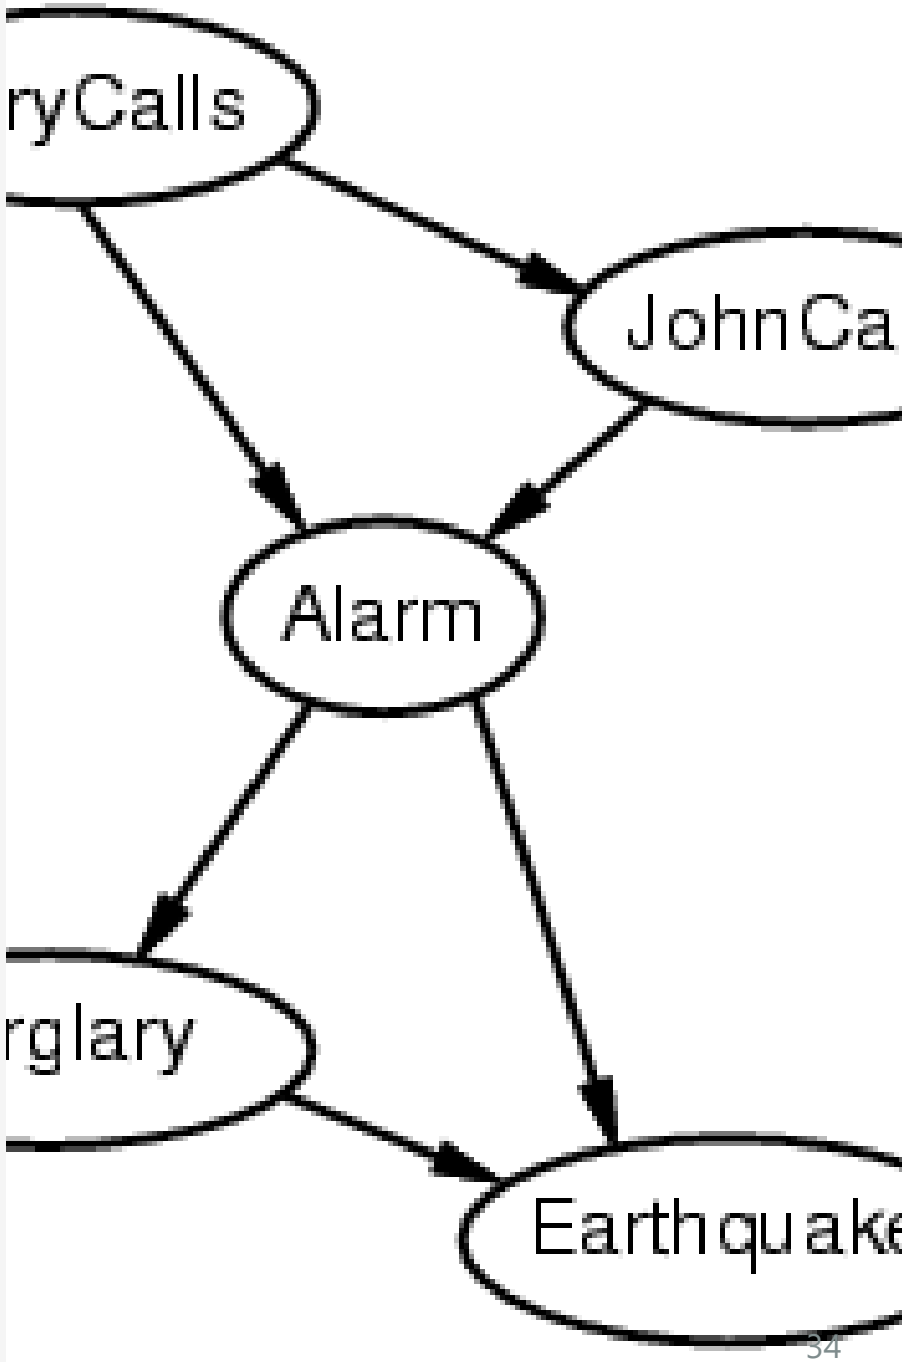

Exemple (suite)

- **Décider de l'indépendance conditionnelle est difficile dans les directions non causales**
  - (Les modèles causaux et d'indépendance conditionnelle semblent câblés pour les humains!)
- **Le réseau est moins compact:**
  - 1 + 2 + 4 + 2 + 4 = 13 nombres nécessaires

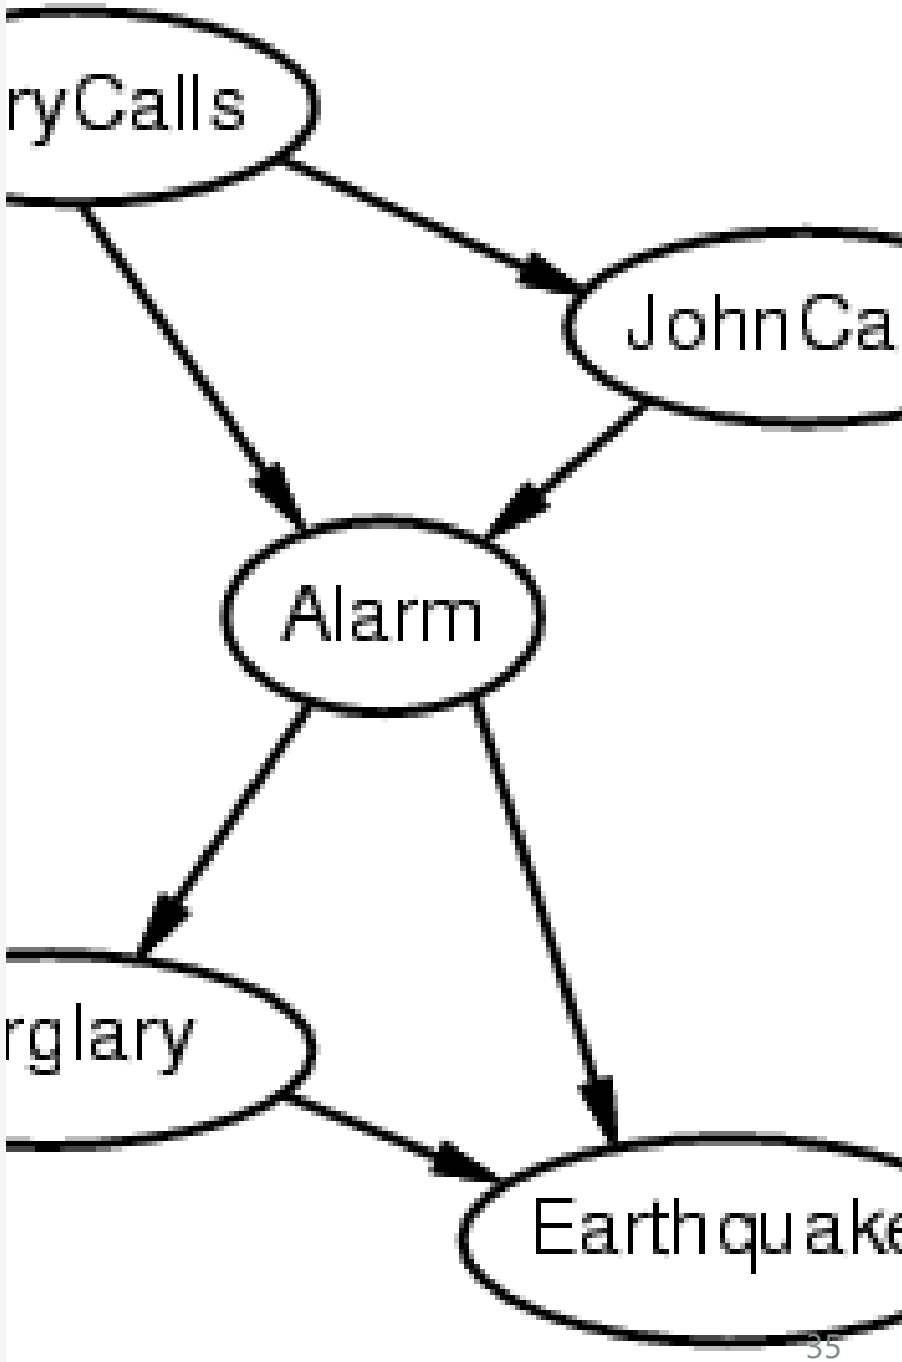

Représentation efficace

- **Relations d'indépendance conditionnelle**
  - Indépendante conditionnelle aux non-descendants, étant donné les parents (a)
  - Couverture de Markov: Indépendance au reste du réseau (b)
  - Etant données parents, enfants et parents des enfants
- **Distribution canonique**
  - Tables de probabilités conditionnelles fastidieux
  - O(2^k) nombres dans le cas pessimiste
  - → Schéma standard plus simple

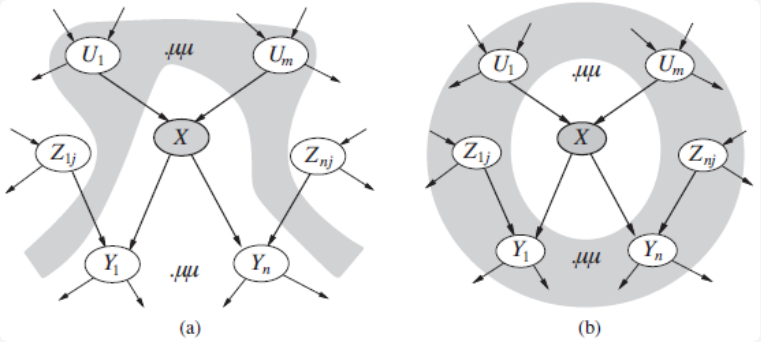

Cold	*Flu*	*Malaria*	$P(Fever)$	$P(\neg Fever)$
F	F	F	0.0	1.0
F	F	T	0.9	**0.1**
F	T	F	0.8	**0.2**
F	T	T	0.98	$0.02 = 0.2 \times 0.1$
T	F	F	0.4	**0.6**
T	F	T	0.94	$0.06 = 0.6 \times 0.1$
T	T	F	0.88	$0.12 = 0.6 \times 0.2$
T	T	T	0.988	$0.012 = 0.6 \times 0.2 \times 0.1$

$$P(x_i \mid parents(X_i)) = 1 - \prod_{\{j:X_j = true\}} q_j$$

Distributions canoniques (exemples)

- **Ex simple: Nœuds déterministes**
  - Enfants spécifiés par parents
  - Ex: Canadien vs US & Mexico → Nord Américain (disjonction)
  - Ex: Concessionnaires → Meilleur prix (Min)
  - Ex: débits entrant et sortant → Niveau d'un lac (différence)
- **Relation "OU-bruité"**
  - ○ Incertitude causale Parents/Enfants → Relation inhibée par un bruit
  - Couverture des clauses de la disjonction → ajout d'un nœud de fuite
  - Hypothèse d'indépendance causale des bruits
- **Formulation générale:**
  - Ex: Fièvre vs Maladies → 3 chiffres suffisent

Variables continues

- **Concerne de nombreux problèmes (hauteur, masse, devise, température etc.)**
- **1ère possibilité: Discrétisation → intervalles fixes**
  - Mais parfois peu précis
- **Meilleur: définition d'une distribution de probabilités**
  - Paramétrique: ex: Gaussienne → moyenne et variance
  - Non paramétrique: Définition implicite par l'exemple

$$P(c \mid h, subsidy) = N(a_t h + b_t, \sigma_t^2)(c) = \frac{1}{\sigma_t \sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{c-(a_t h + b_t)}{\sigma_t}\right)^2}$$

$$P(c \mid h, \neg subsidy) = N(a_f h + b_f, \sigma_f^2)(c) = \frac{1}{\sigma_f \sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{c-(a_f h + b_f)}{\sigma_f}\right)^2}$$

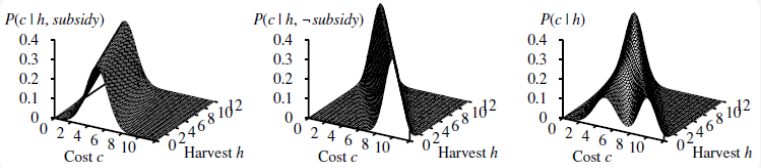

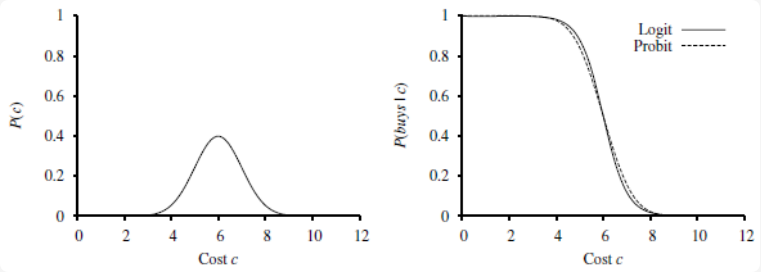

Réseau bayésien hybride

- **Paramètres discrets + continus**
- **Variables continues: Probabilité linéaire Gaussienne**
  - Ex: Coût → Q récolte (h) + subventions
  - 2 distributions sommées
  - Somme de distributions linéaires gaussienne
  - Distribution conjointe = Distribution gaussienne multivariée
  - Distribution a posteriori = distribution gaussienne conditionnelle
- **Variables discrètes avec parents continus**
  - Seuil doux: Ex: acheter / coût
  - Possibilité = intégrale de la distribution normale

$$p(\theta \mid x) = \frac{p(x \mid \theta)\, p(\theta)}{p(x)} = \frac{p(x \mid \theta)\, p(\theta)}{\int p(x \mid \theta')\, p(\theta')\, d\theta'}$$

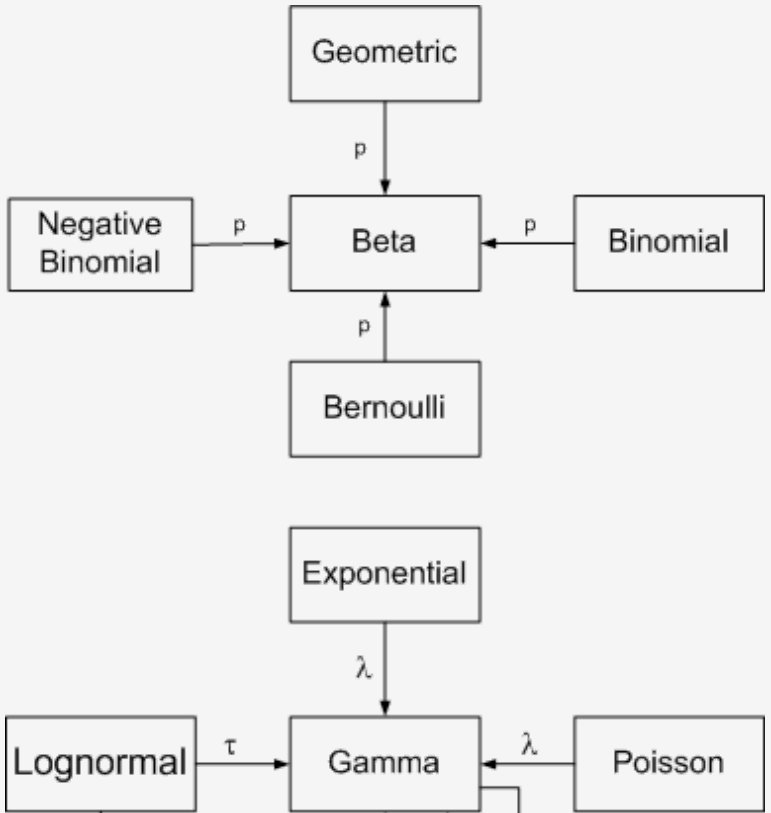

Distribution a priori conjuguée

- **Quelle distribution utiliser?**
  - Posterieur = même famille de distribution
- **Exemples:**
  - Gaussienne: moyenne → Gaussienne, précision → Gamma
  - https://en.wikipedia.org/wiki/Conjugate_prior

Inférence exacte dans les réseaux Bayésiens

- **Inférence exacte**
  - Énumération
  - Élimination de variables
  - Clustering

$$\mathbf{P}(B \mid j,m) = \alpha \underbrace{\mathbf{P}(B)}_{\mathbf{f}_1(B)} \sum_e \underbrace{P(e)}_{\mathbf{f}_2(E)} \sum_a \underbrace{\mathbf{P}(a \mid B,e)}_{\mathbf{f}_3(A,B,E)} \underbrace{P(j \mid a)}_{\mathbf{f}_4(A)} \underbrace{P(m \mid a)}_{\mathbf{f}_5(A)}$$

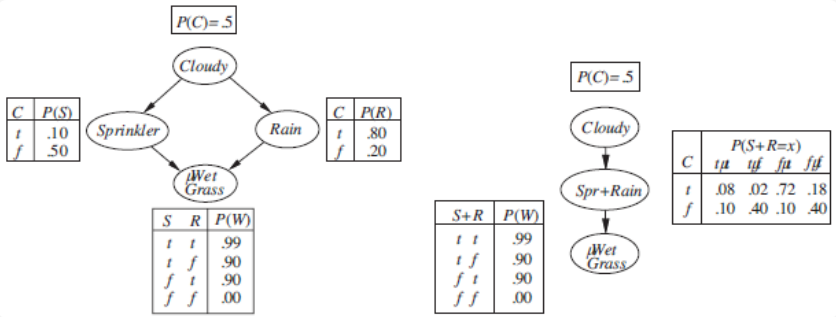

Inférence approchée dans les RB

- **Inférence approchée**
  - Échantillonnage a priori
  - Échantillonnage par rejet
  - Échantillonnage par vraisemblance
  - Méthodes de Monte-Carlo (Gibbs)

$$w(\mathbf{z}, \mathbf{e}) = \prod_{i=1}^{m} P(e_i \mid parents(E_i))$$

$$\pi(\mathbf{x})q(\mathbf{x} \rightarrow \mathbf{x}') = \pi(\mathbf{x}')q(\mathbf{x}' \rightarrow \mathbf{x})$$

Modèles relationnels du premier ordre

- **Modèles bayésiens = propositionnel**
- **FOL → relations entre objets**
  - Ex: évaluations livres: pb de partialité
  - → Impartial(c), Indulgent(c), Mérite(l) prédicats du premier ordre
- **Mondes possibles**
  - Assignations de variables → mondes possibles
  - Sémantique de base de données (limite la taille du problème)
- **Modèles probabilistes relationnels**
  - Syntaxe de FOL → Variables aléatoires = assignations possibles
  - Distributions et dépendances (Tables de Pr Cond.)
  - Indépendance contextuelle = branchement ex: si Impartial(c), si Fan(c, Auteur(l))

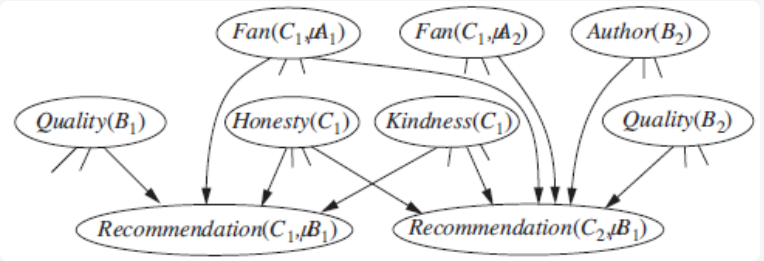

MPR: Inférence et univers ouverts

- **Inférence: ex dépliement → Assemblage complet**
  - Grand réseau + variables inconnues → nombreux nœuds parents: ex auteur?
  - Mais si sémantique de DB:
    - Mise en cache + indépendance contextuelle + techniques MCMC efficaces
    - = propositionnalisation → améliorée en FOL par lifting → De même lifting ici
- **Modèles relativistes en univers ouvert**
  - Sémantique standard → incertitude d'existence et d'identité des objets (e.g. IDs: Sibyl attacks)
  - → MPUOs
  - Ex: NbClient: Si honnête, exactement 1, sinon distribution LogNormal[6,9,2,3]

Résumé réseaux bayésiens

- **Les réseaux Bayésiens fournissent une représentation naturelle pour les indépendance conditionnelles (induites par causalité)**
- **Topologie + CPTs = représentation compacte d'une distribution jointe**
  - Généralement facile à construire pour un expert d'un domaine
- **Représentation efficace/compacte:**
  - Distributions canonique, distributions paramétriques (Gaussiennes etc.)
- **Inférence = calcul de variables de requêtes**
  - Exacte: énumération, élimination, clustering → Efficace dans les polyarbres
  - Approximée: Echantillonnage a priori, par rejet, par vraisemblance, Méthodes de Monte-Carlo (Gibbs)
- **Modèles relationnels**
  - Combinaison avec FOL = Modèles probabilistes relationnels (MPR)
  - Incertitude d'existence et d'identité = MP en Univers Ouvert

Questions?

Sommaire

- Quantification de l'incertitude
- Raisonnement probabiliste
- **Raisonnement probabiliste temporel**
  - Chaînes de Markov
  - Modèles de Markov Cachés
  - Réseaux Bayésiens dynamiques
  - Filtrage particulaire
- Prise de décision simple
- Prise de décision complexe

Raisonner dans le temps ou l'espace

- **Souvent, nous souhaitons raisonner à propos d'une séquence d'observations**
  - Reconnaissance de la parole
  - Localisation d'un robot
  - Attention d'un utilisateur
  - Monitoring médical
  - Suivi radar
- **Besoin d'introduire le temps (ou l'espace) dans nos modeles**
- Exemples modernes : vehicules autonomes (fusion capteurs), LLMs contextuels (attention temporelle)

Modèles de Markov

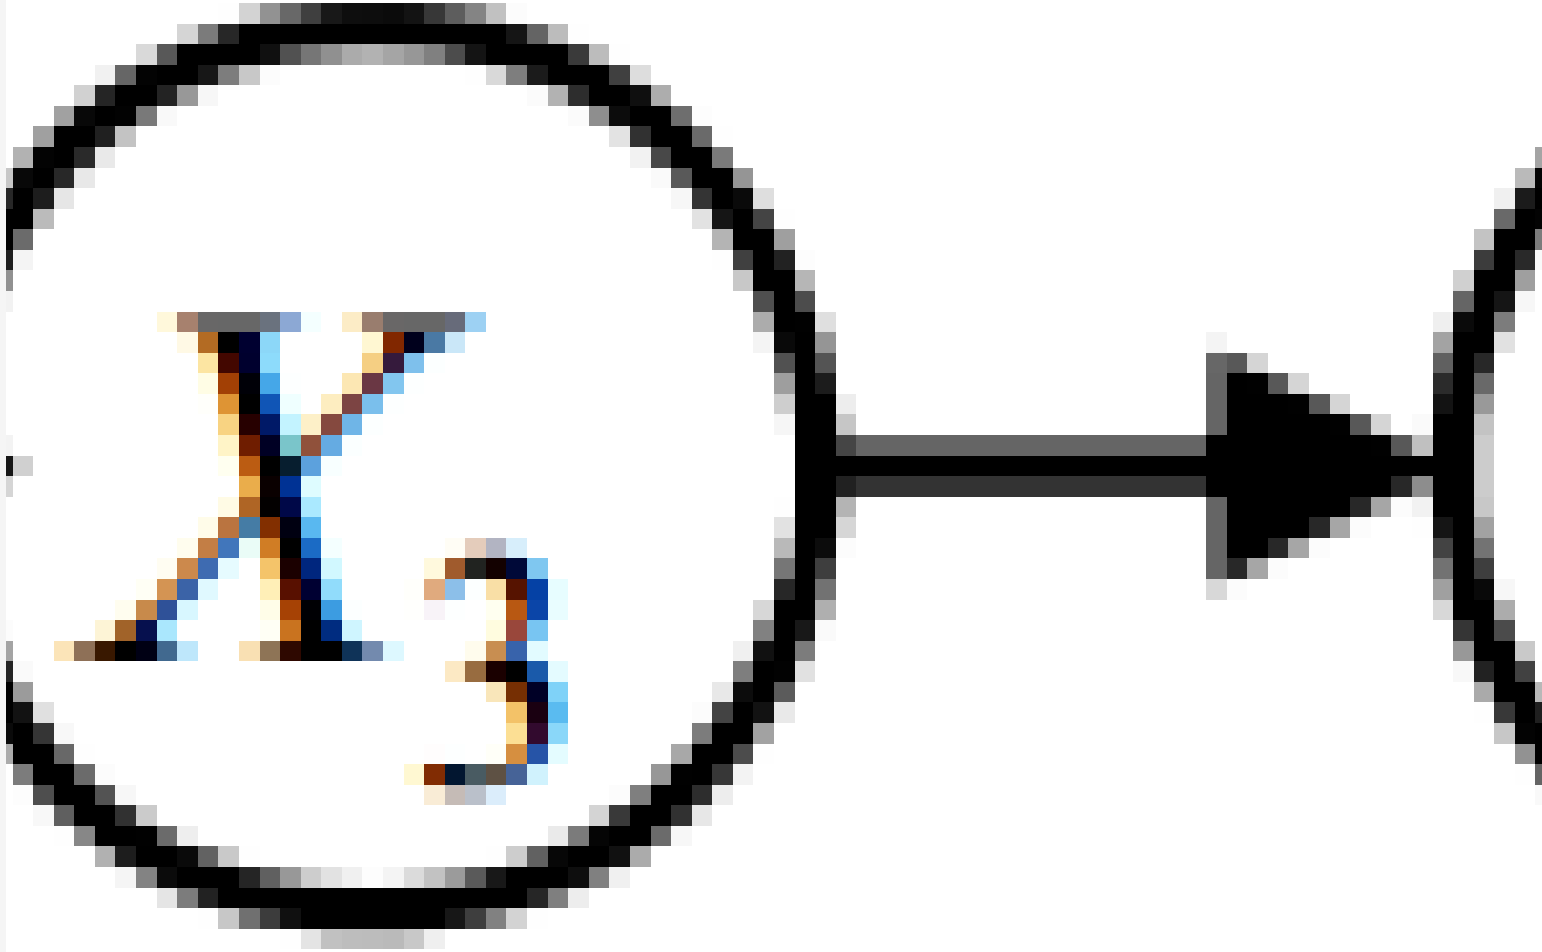

Distribution de probabilités

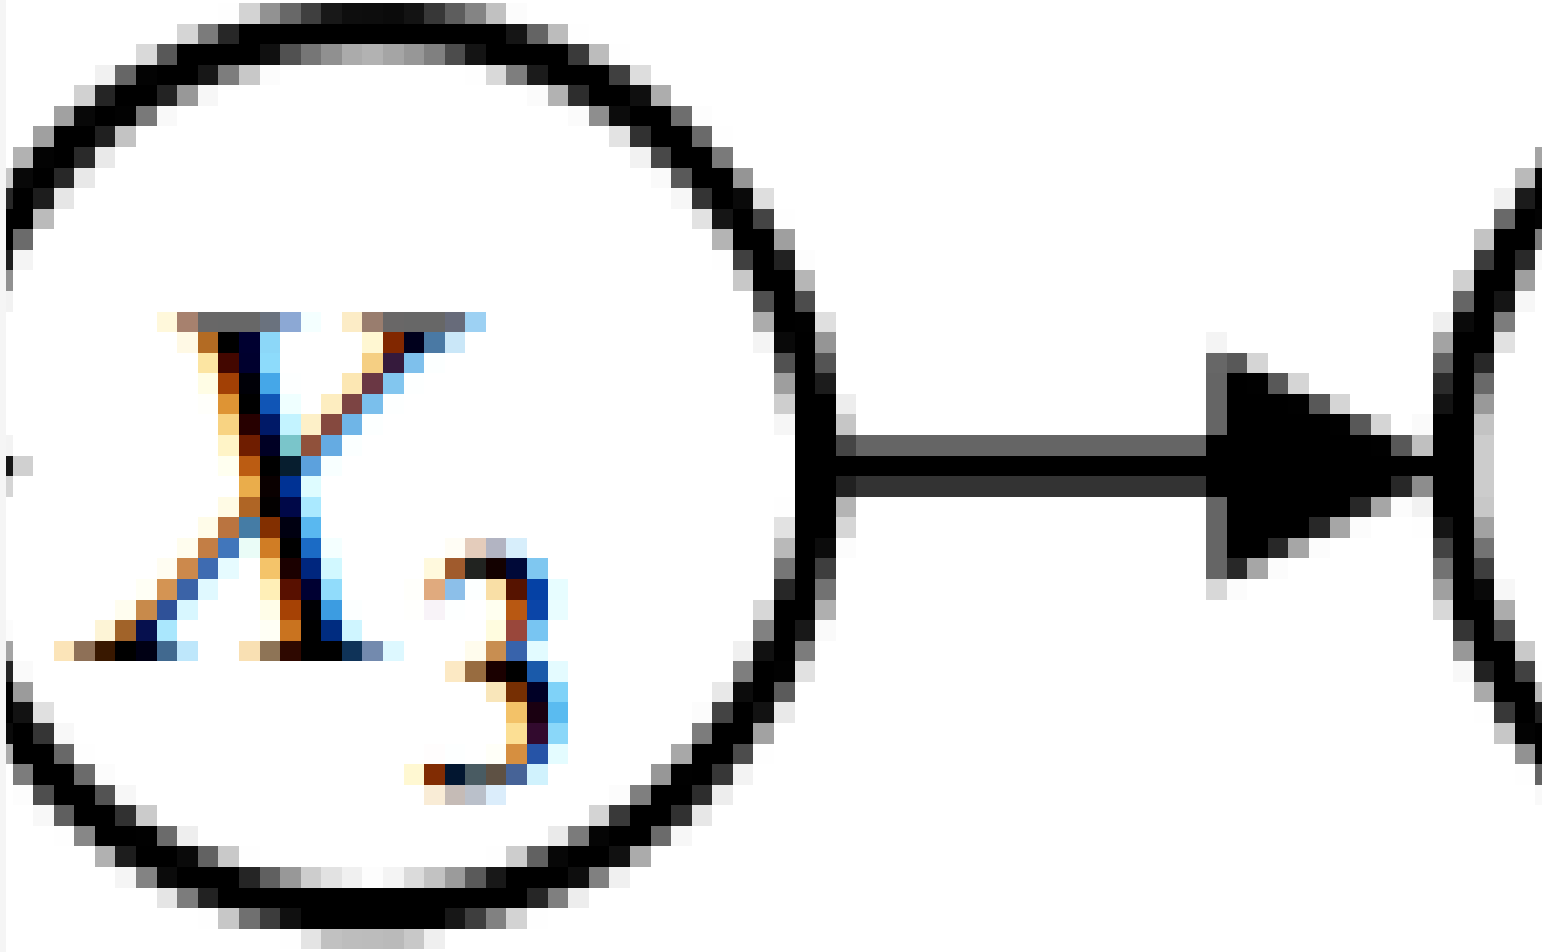

Indépendance conditionnelle

- **Indépendance conditionnelle basique:**
  - Passé et futur indépendants conditionnellement au présent
  - Chaque étape dépend uniquement de la précédente
  - On l'appelle la propriété de Markov (du premier ordre)
- **On note que la chaîne est simplement un Réseau bayésien (extensible):**
  - On peut toujours utiliser le raisonnement des RB classiques si on tronque la chaîne à une longueur donnée

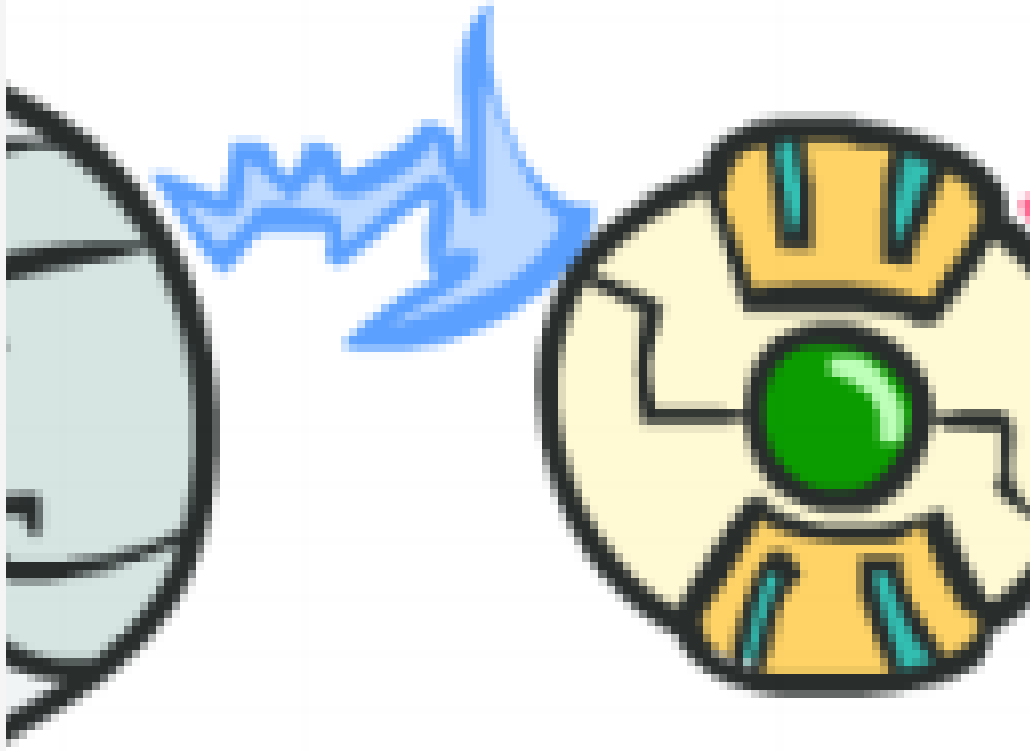

Exemple: Chaîne de Markov

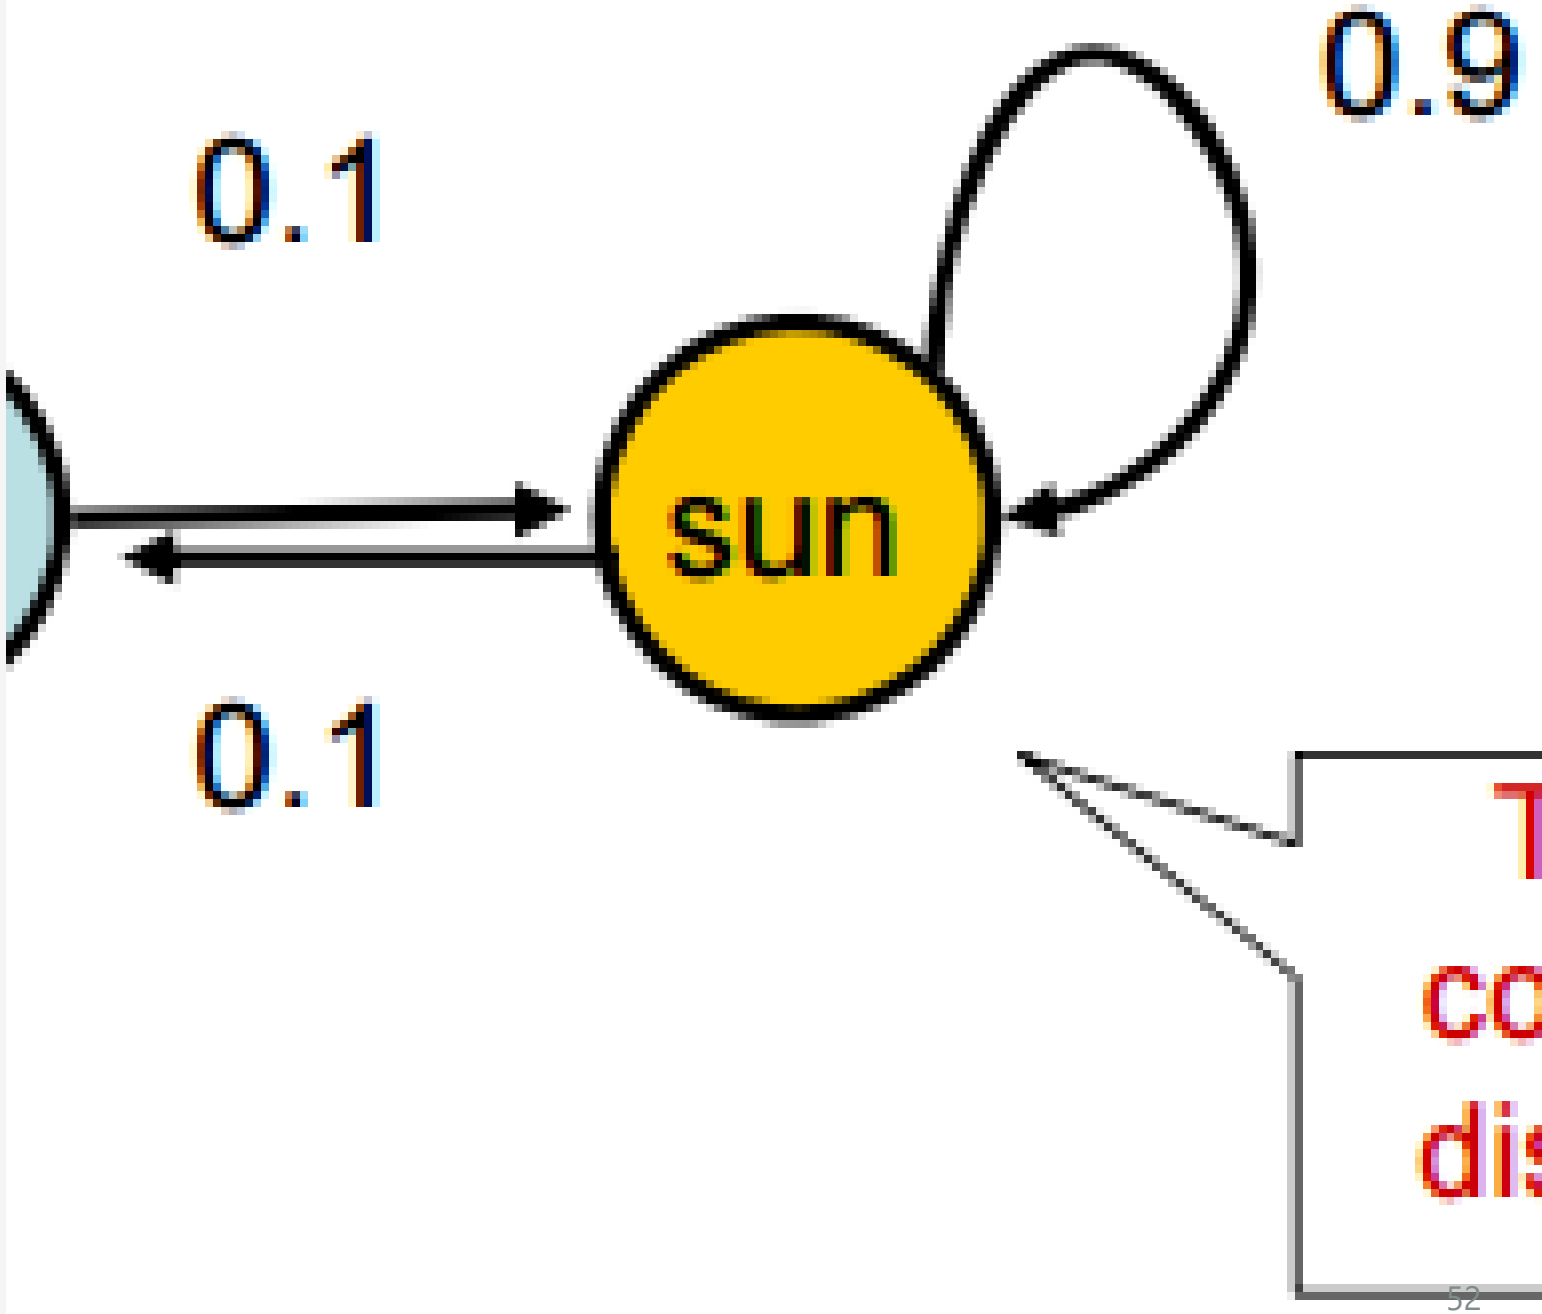

Inférence sur chaînes de Markov

$$sun)P(X_3 = sun|X$$

$$sun)P(X_3 = sun|X$$

$$\vdots$$

Distribution conjointe de modèle de Markov

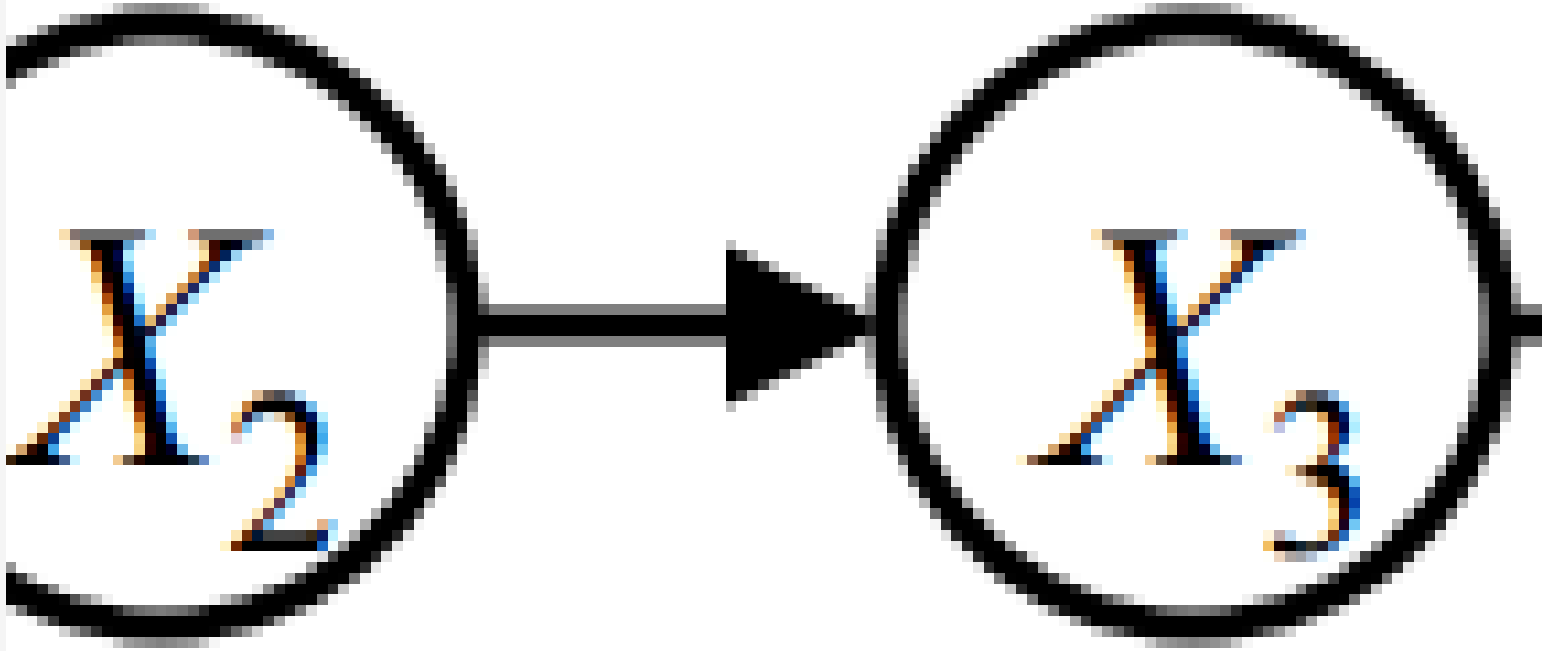

$$P(X_t|$$

Récapitulatif modèles de Markov

Algorithme Mini-Forward

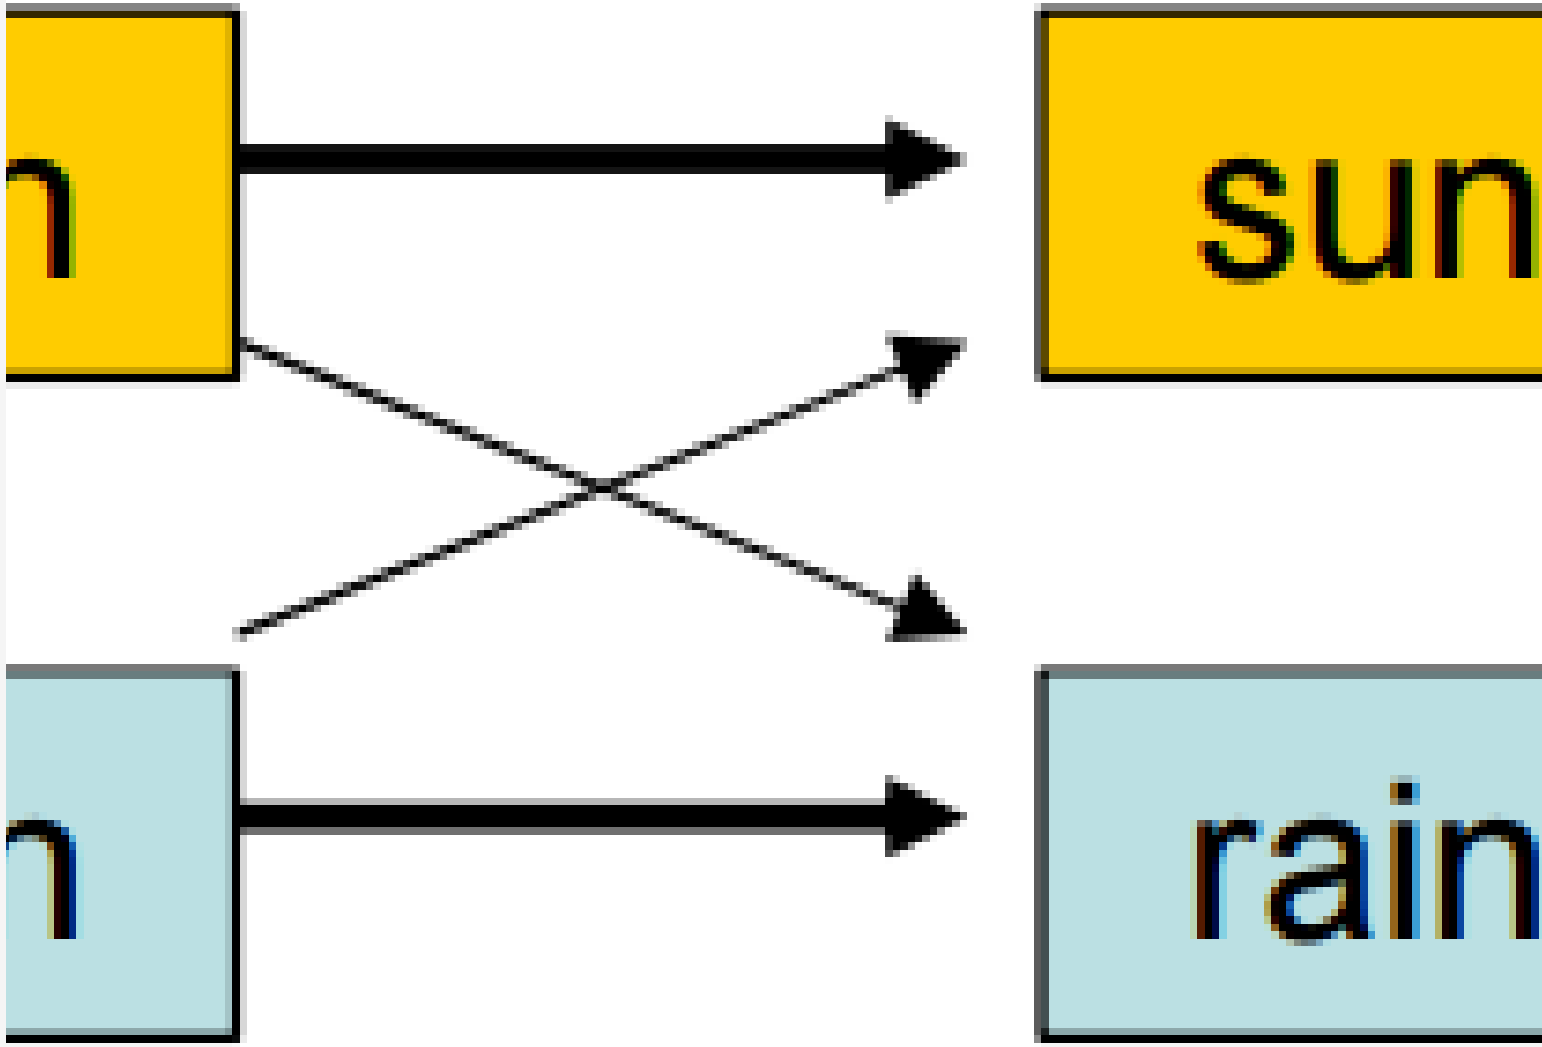

Exemple d'exécution Mini-Forward

- Depuis une observation initiale d'ensoleillement:
- Depuis une observation initiale de pluie:
- Depuis une autre distribution initiale $P(X_1)$:

$$\langle \begin{matrix} 0.84 \\ 0.16 \end{matrix} \rangle \quad \langle \begin{matrix} 0.804 \\ 0.196 \end{matrix} \rangle$$

$$P(X_3) \qquad P(X_4)$$

$$\langle \begin{matrix} 0.48 \\ 0.52 \end{matrix} \rangle \quad \langle \begin{matrix} 0.588 \\ 0.412 \end{matrix} \rangle$$

$$P(X_3) \qquad P(X_4)$$

...

Distributions stationnaires

Exemple: distribution stationnaire

- Question: Quel est P(X) au temps t = infini?

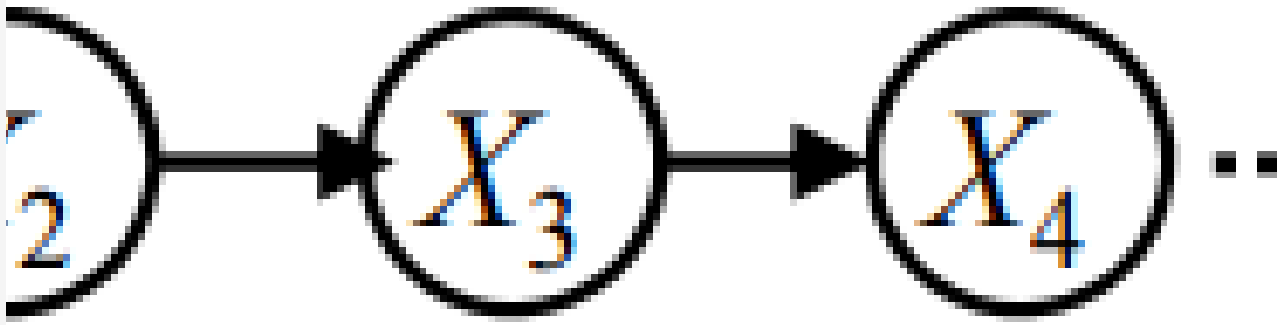

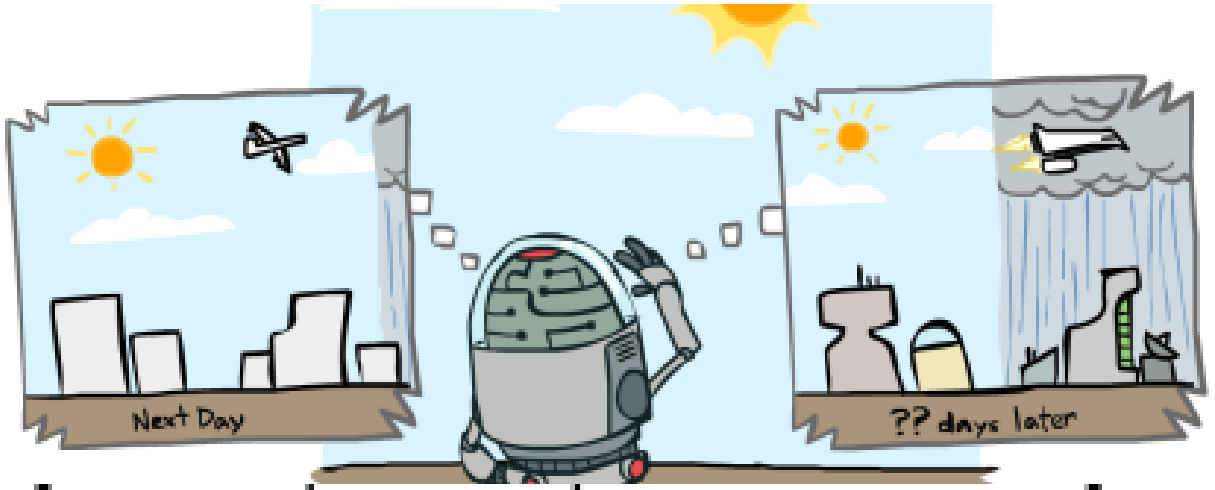

sun	sun	0.9
sun	rain	0.1
rain	sun	0.3

Application: Analyse des liens web

- **PageRank sur un graphe du web**
  - Chaque page est un état
  - Distribution initiale: uniforme sur les pages
- **Transitions:**
  - Avec la prob. c, saut uniforme vers une page aléatoire (lignes pointillées)
  - Avec prob. 1-c, suivre un lien sortant aléatoire (lignes pleines)
- **Distribution stationnaire:**
  - On passera plus de temps sur les pages hautement accessibles
  - E.g. Plein de façon d'arriver sur la page de téléchargement d'Acrobat Reader

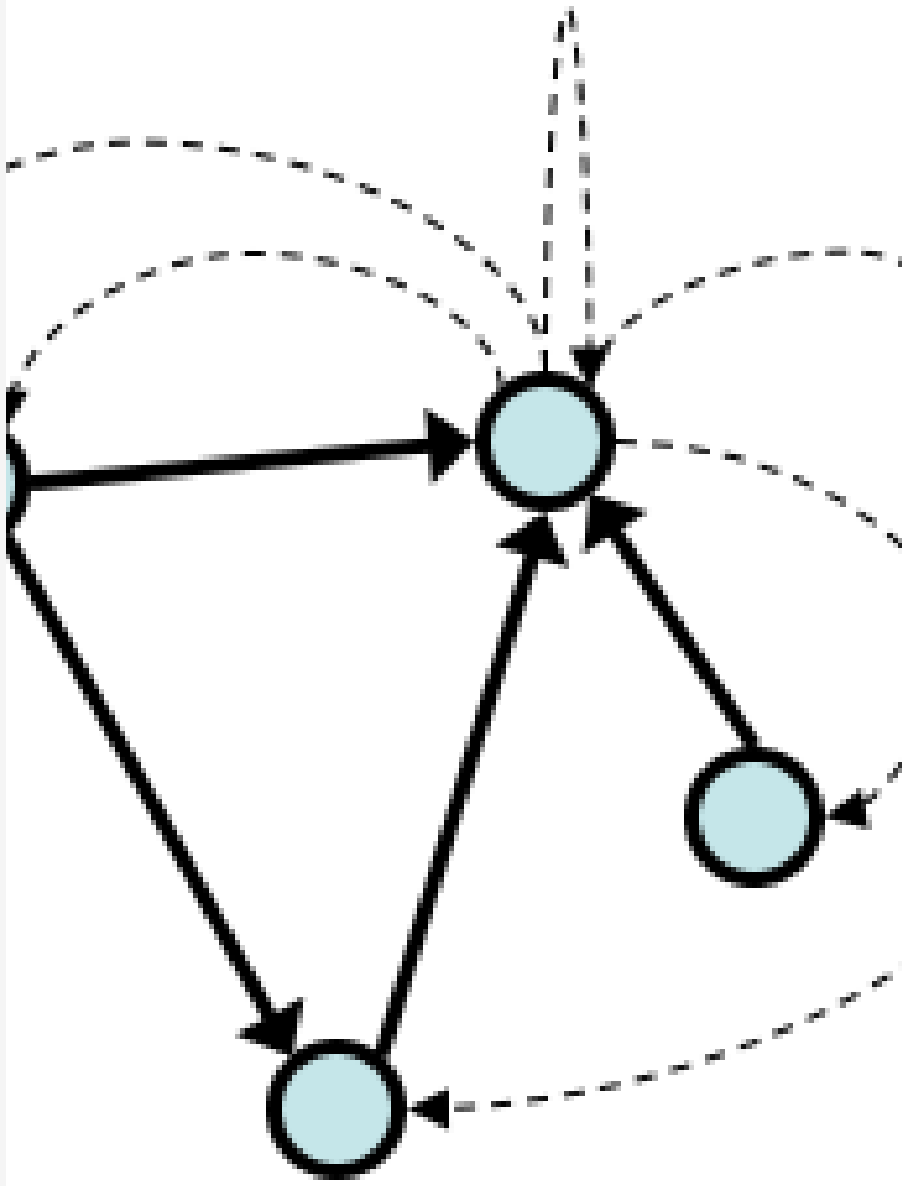

Hidden Markov Models

- **Markov chains not so useful for most agents**
  - Eventually you don't know anything anymore
  - Need observations to update your beliefs
- **Hidden Markov models (HMMs)**
  - Underlying Markov chain over states S
  - You observe outputs (effects) at each time step
- **As a Bayes' net:**

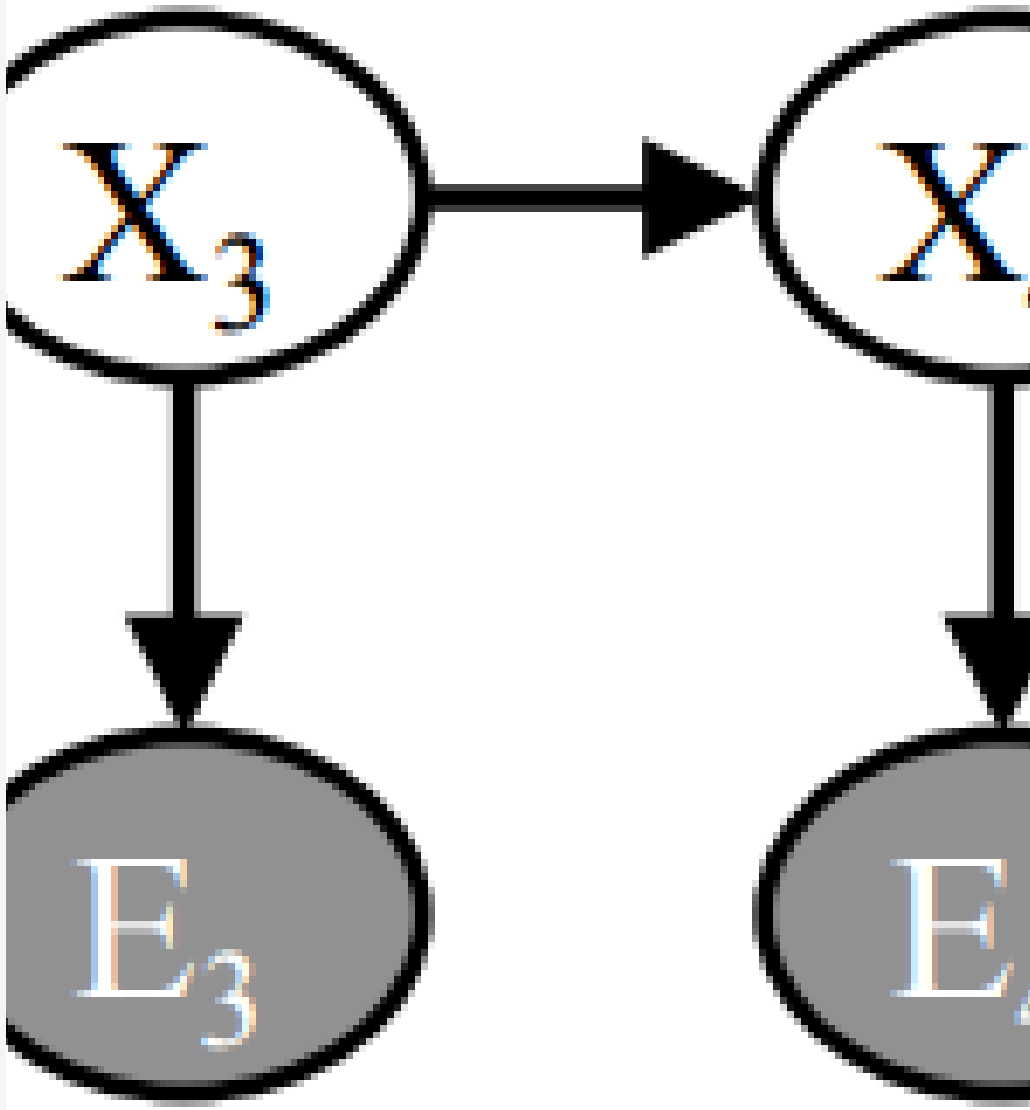

Example

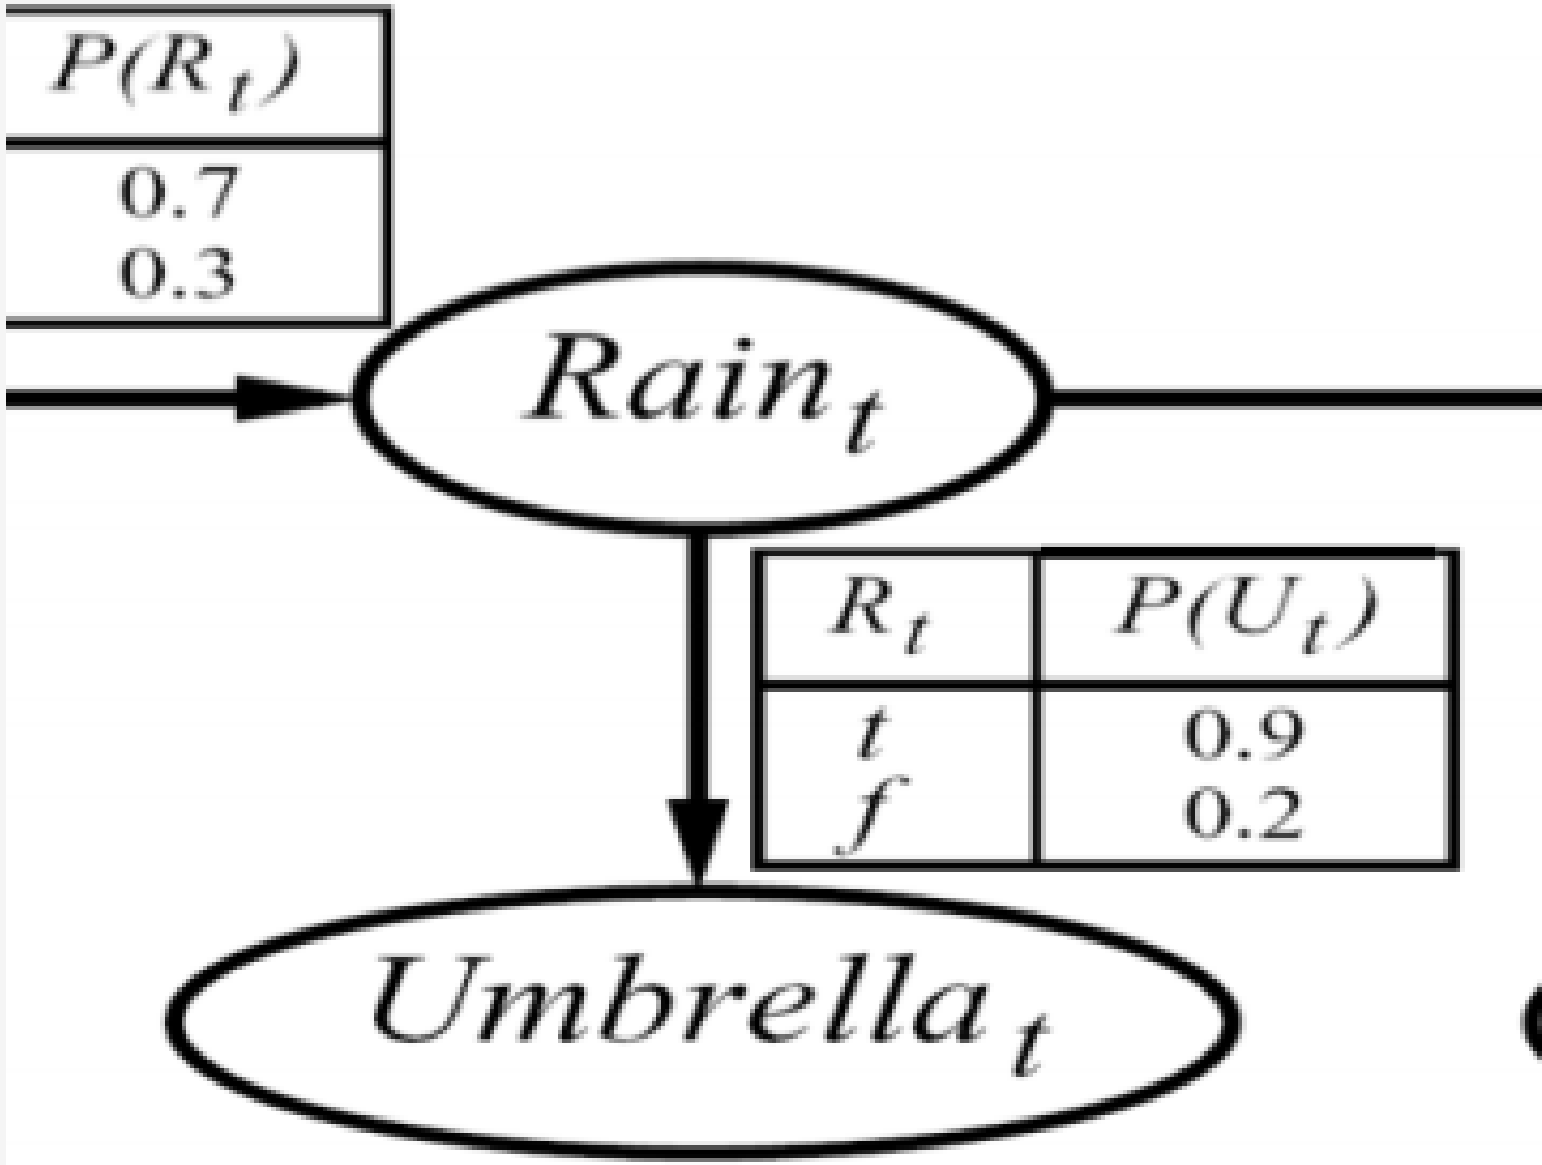

Hidden Markov Models

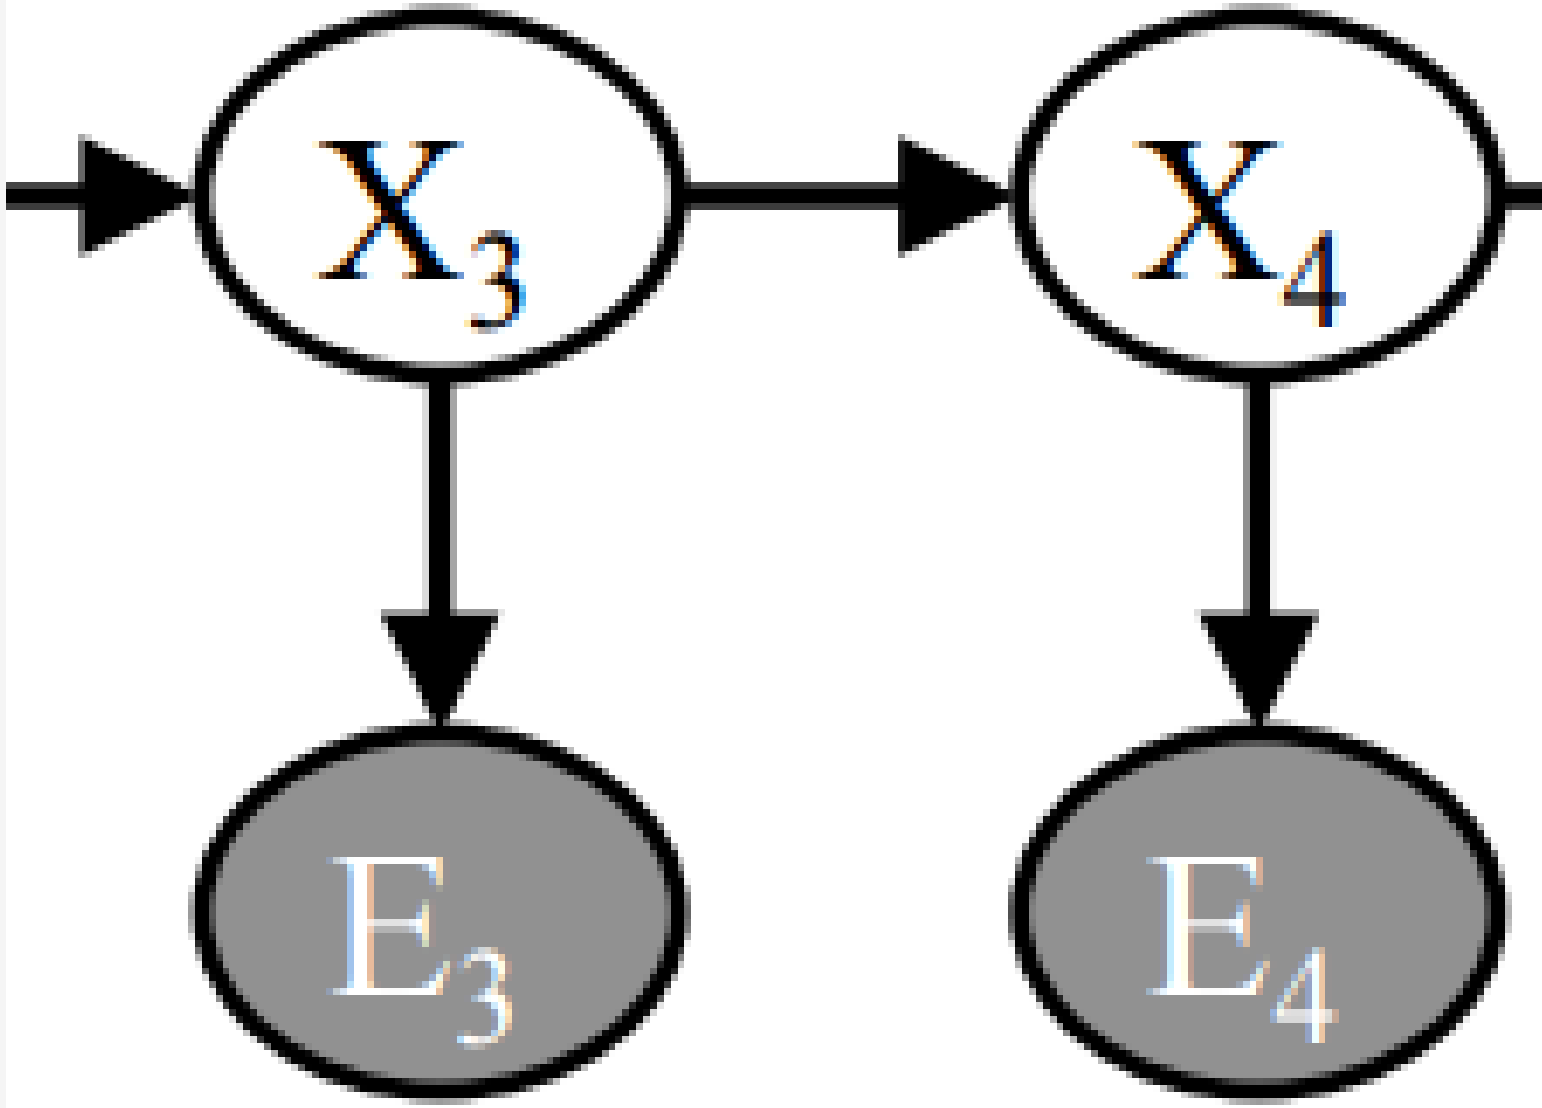

HMM Computations

- **Given**
  - Parameters
  - Evidence $E_{1:n} = e_{1:n}$
- **Inference problems include:**
  - Filtering, find $P(X_t \mid e_{1:t})$ for all t
  - Smoothing, find $P(X_t \mid e_{1:n})$ for all t
  - Most probable explanation, find $x^*_{1:n} = \text{argmax}_\{x_{1:n}\}\ P(x_{1:n} \mid e_{1:n})$

Real HMM Examples

- **Speech recognition HMMs:**
  - Observations are acoustic signals (continuous valued)
  - States are specific positions in specific words (so, tens of thousands)

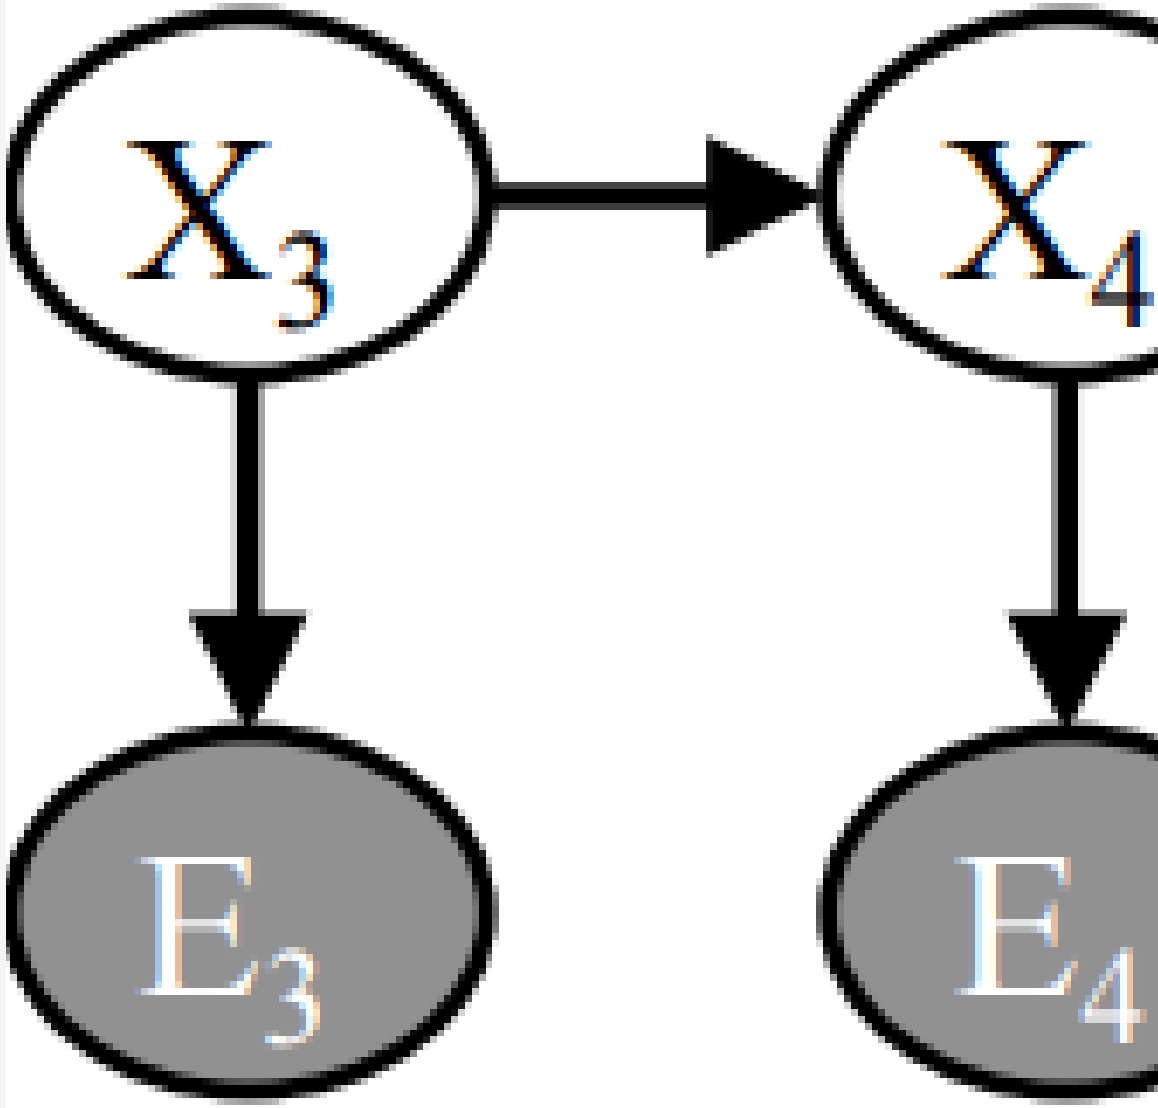

Real HMM Examples

- **Machine translation HMMs:**
  - Observations are words (tens of thousands)
  - States are translation options

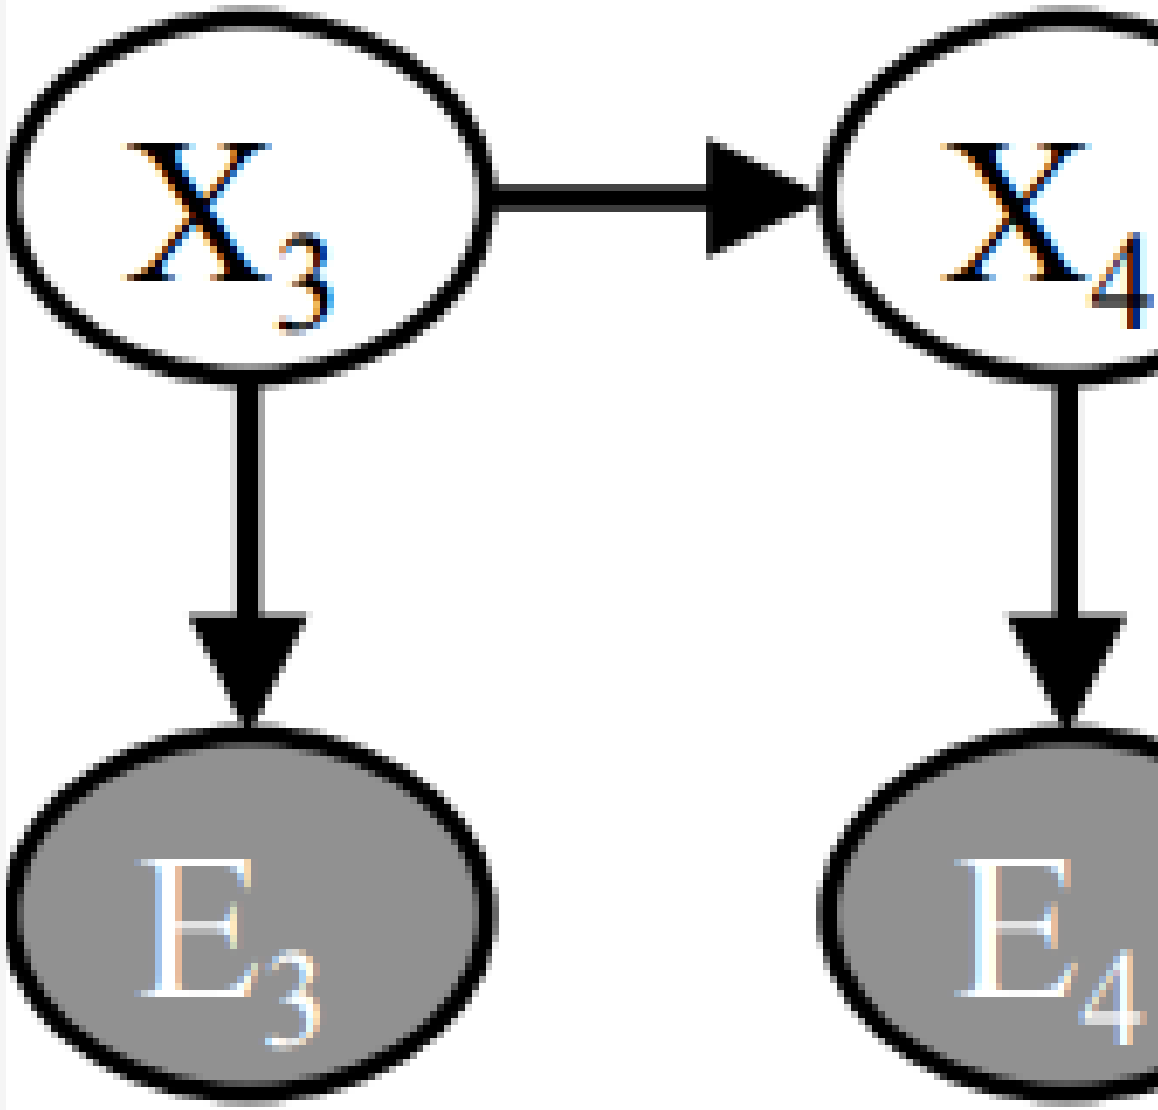

Real HMM Examples

- **Robot tracking:**
  - Observations are range readings (continuous)
  - States are positions on a map (continuous)

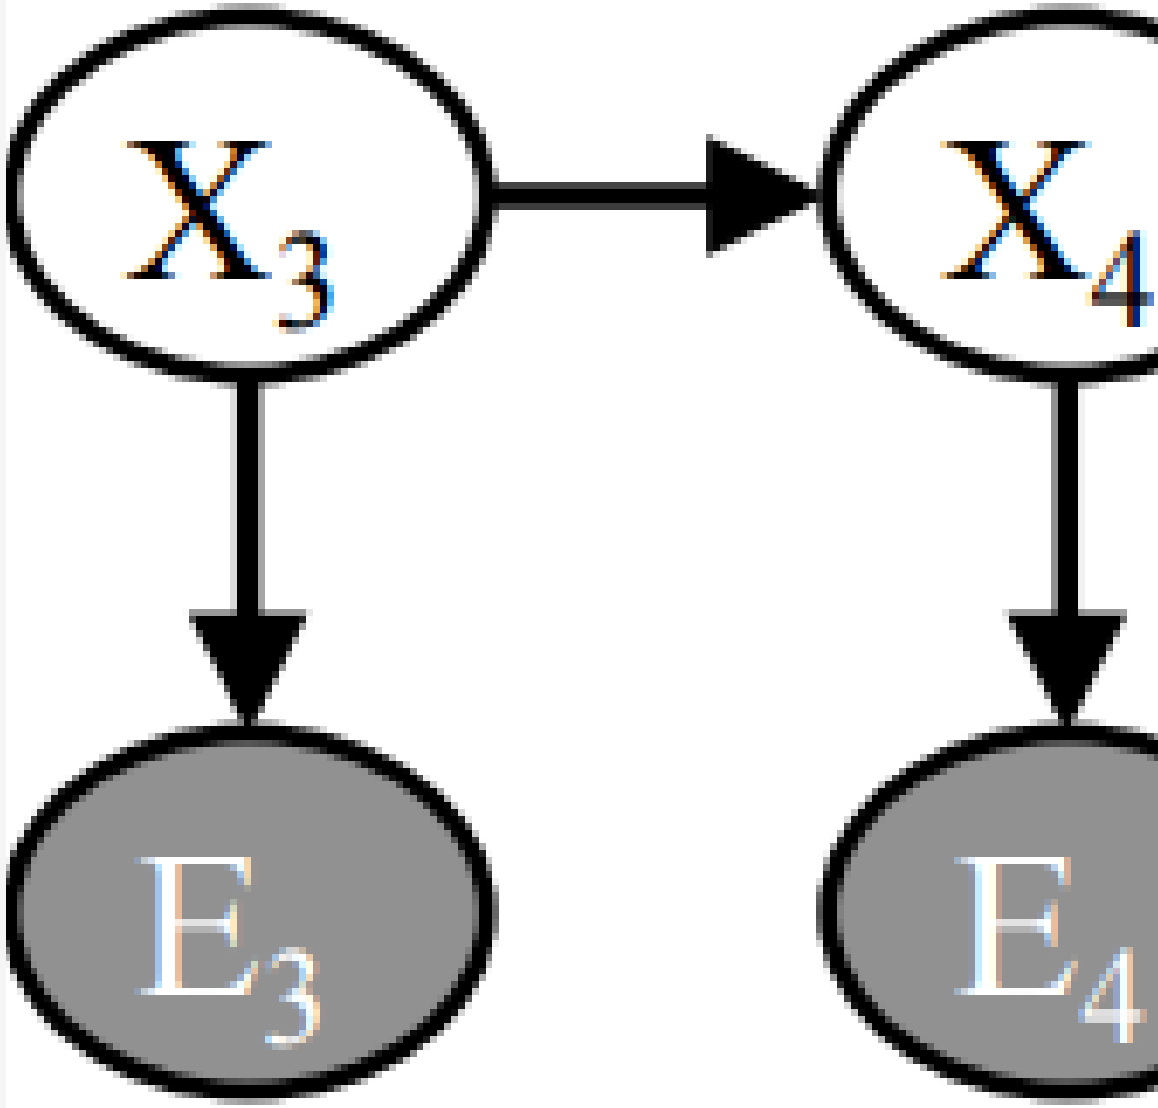

Conditional Independence

- **HMMs have two important independence properties:**
  - Markov hidden process, future depends on past via the present

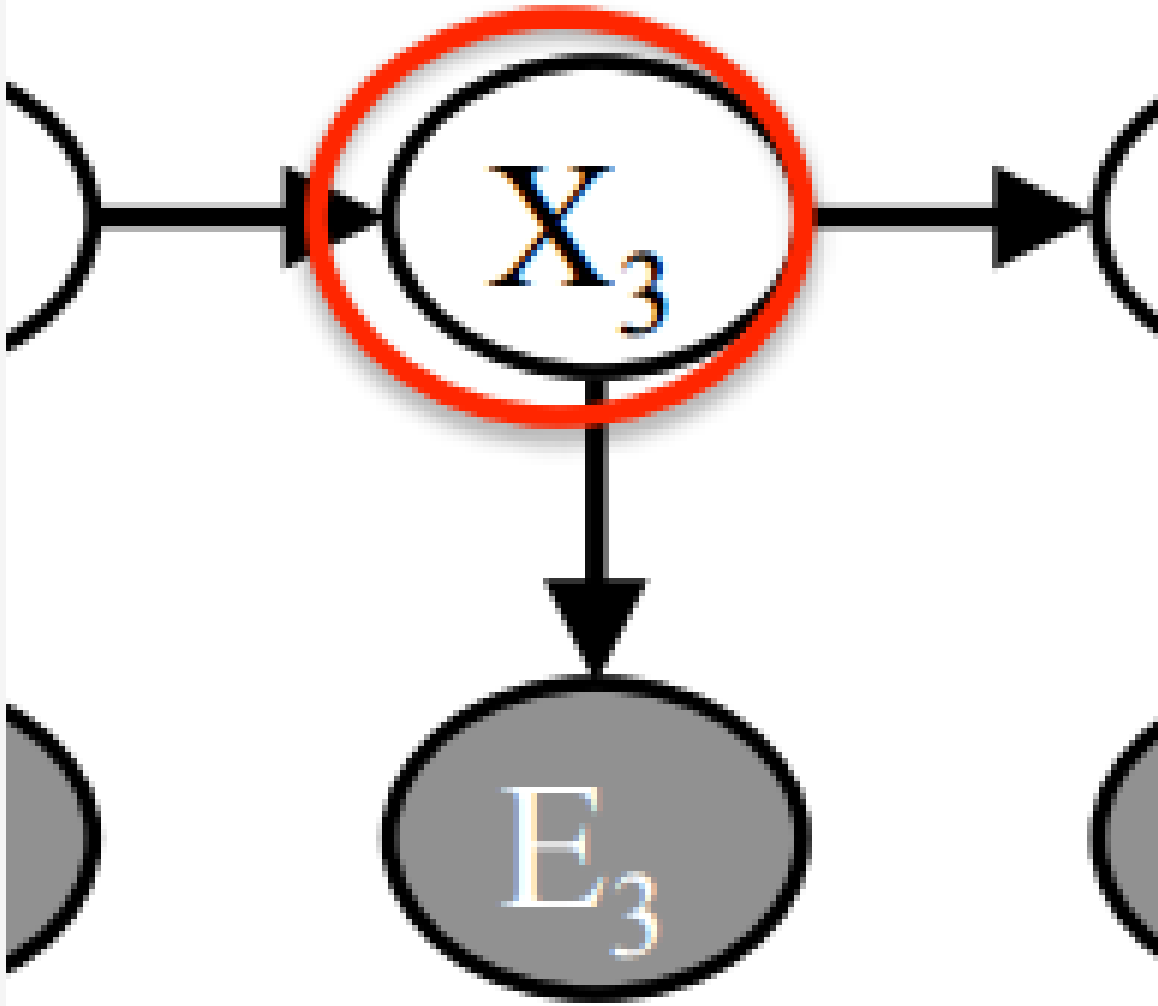

Conditional Independence

- **HMMs have two important independence properties:**
  - Markov hidden process, future depends on past via the present
  - Current observation independent of all else given current state

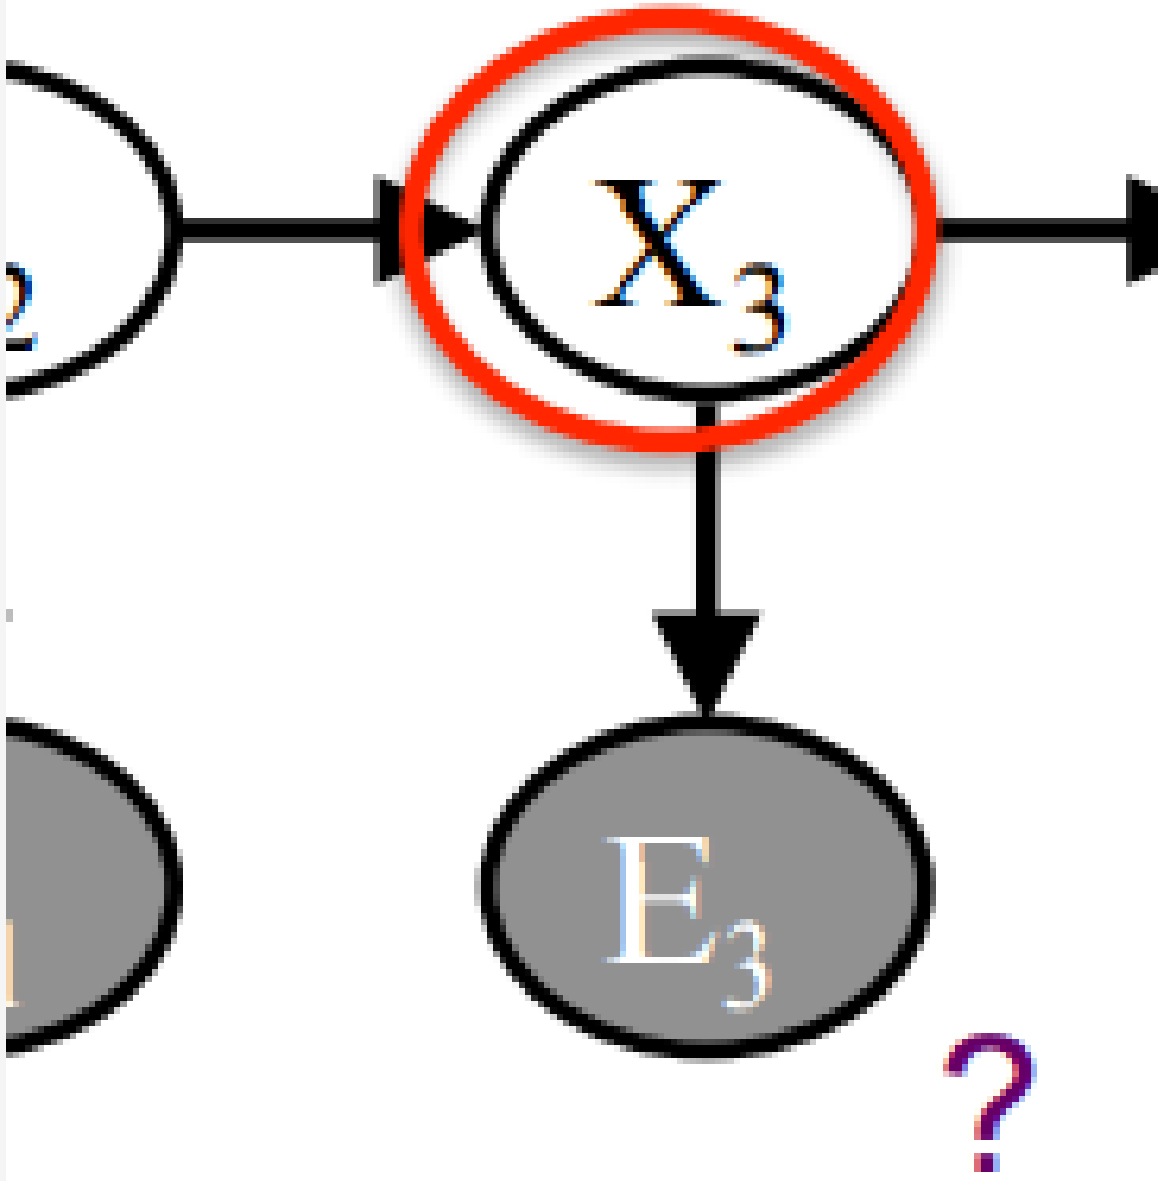

Conditional Independence

- **HMMs have two important independence properties:**
  - Markov hidden process, future depends on past via the present
  - Current observation independent of all else given current state
- **Quiz: does this mean that observations are independent given no evidence?**

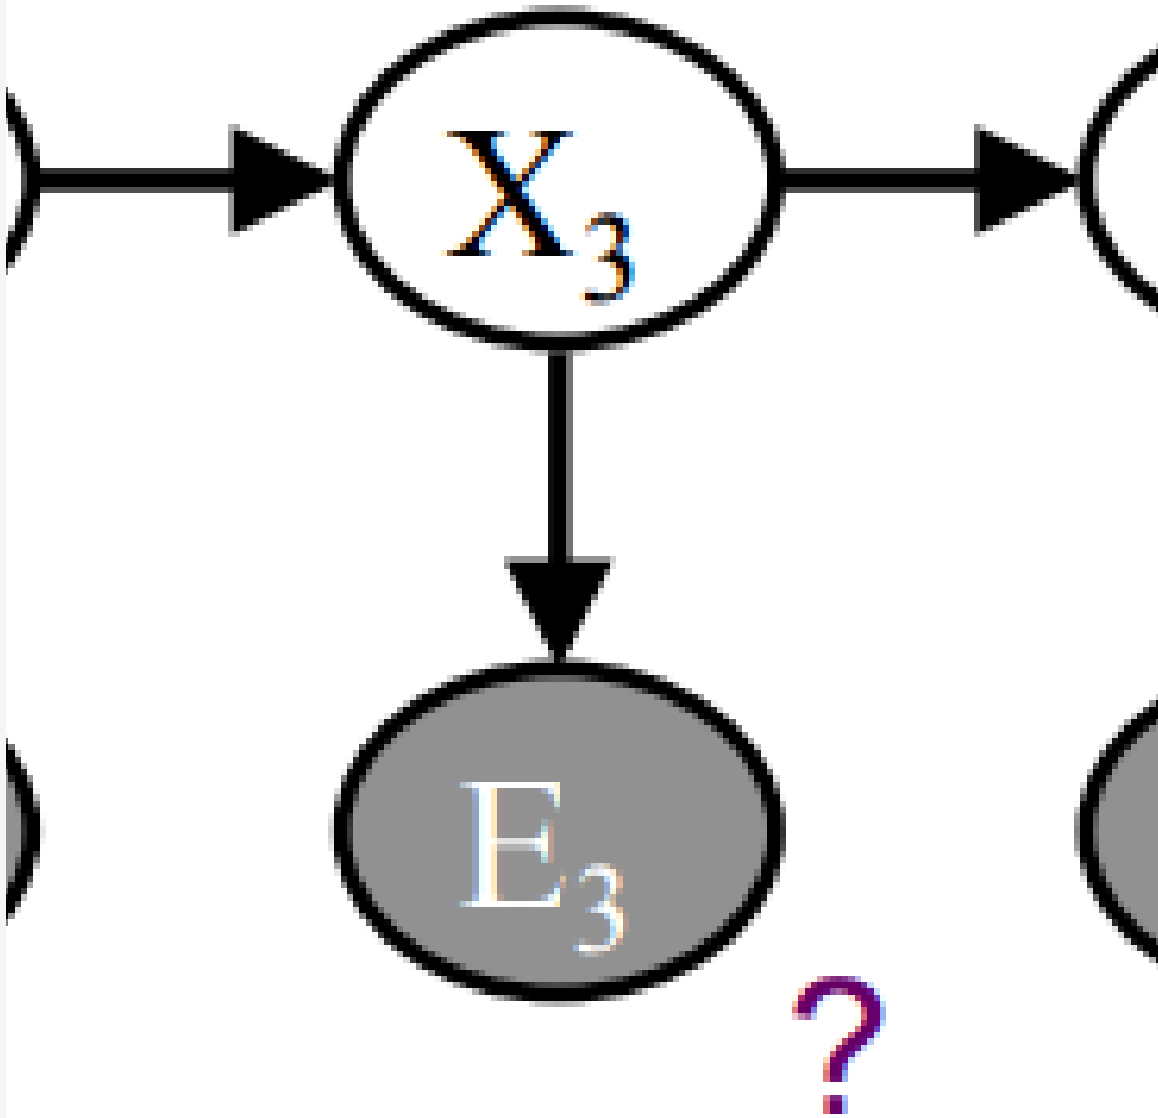

HMM Notation

HMM Problem 1: Evaluation

- **Evaluation**
  - Consider the problem where we have a number of HMMs (that is, a set of (π, A, B) triples) describing different systems, and a sequence of observations
  - We may want to know which HMM most probably generated the given sequence
- **Solution: Forward Algorithm**

HMM Problem 2: Decoding

- **Decoding: Finding the most probable sequence of hidden states given some observations**
  - Find the hidden states that generated the observed output
  - In many cases we are interested in the hidden states of the model since they represent something of value that is not directly observable
- **Solution:**
  - Backward Algorithm
  - or Viterbi Algorithm

HMM Problem 3: Learning

- Learning: Generating a HMM from a sequence of observations
- Solution: Forward-Backward Algorithm

KWARD(**ev**, *prior*) **returns** a vector o
evidence values for steps $1, \ldots, t$
distribution on the initial state, $\mathbf{P}(\mathbf{X}_0$
ector of forward messages for steps 0,
presentation of the backward message
ector of smoothed estimates for steps

$\mathbf{fv}[i-1], \mathbf{ev}[i])$

$\mathrm{E}(\mathbf{fv}[i] \times \mathbf{b})$
$, \mathbf{ev}[i])$

Exhaustive Search Solution

- Sequence of observations for seaweed state:
  - Dry
  - Damp
  - Soggy

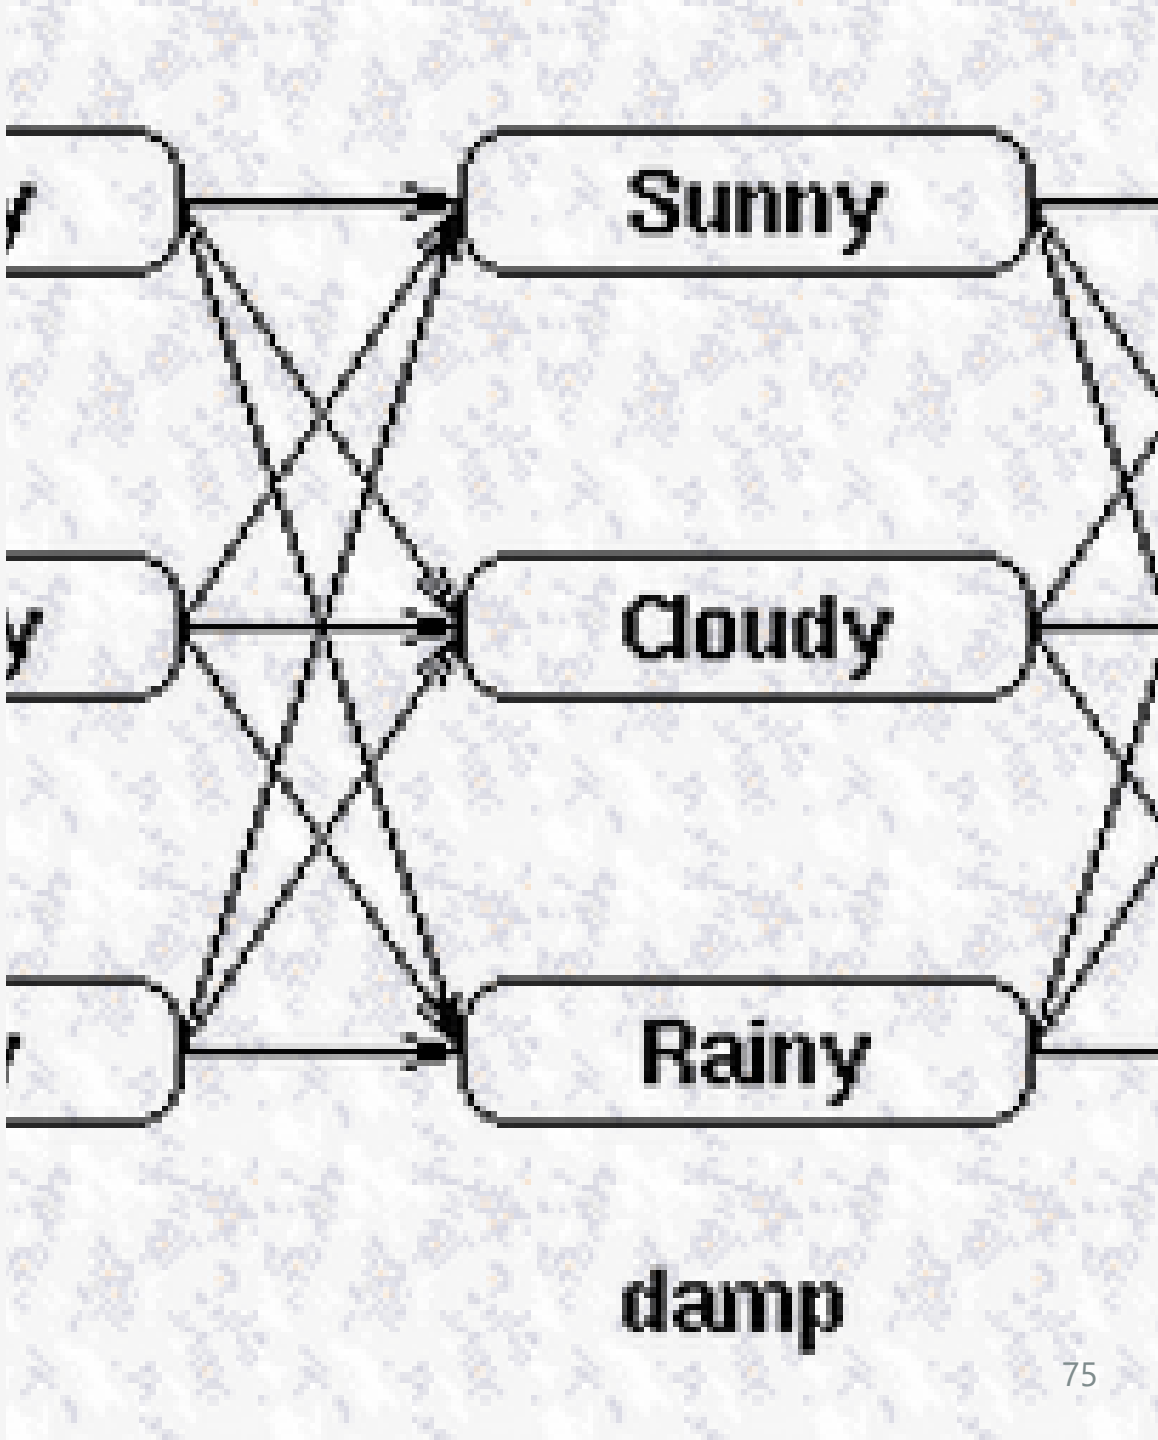

Exhaustive Search Solution

- **Pr(dry, damp, soggy | HMM) =**
  - Pr(dry, damp, soggy | sunny, sunny, sunny)
  - Pr(dry, damp, soggy | sunny, sunny, cloudy)
  - Pr(dry, damp, soggy | sunny, sunny, rainy)
  - …
  - Pr(dry, damp, soggy | rainy, rainy, rainy)

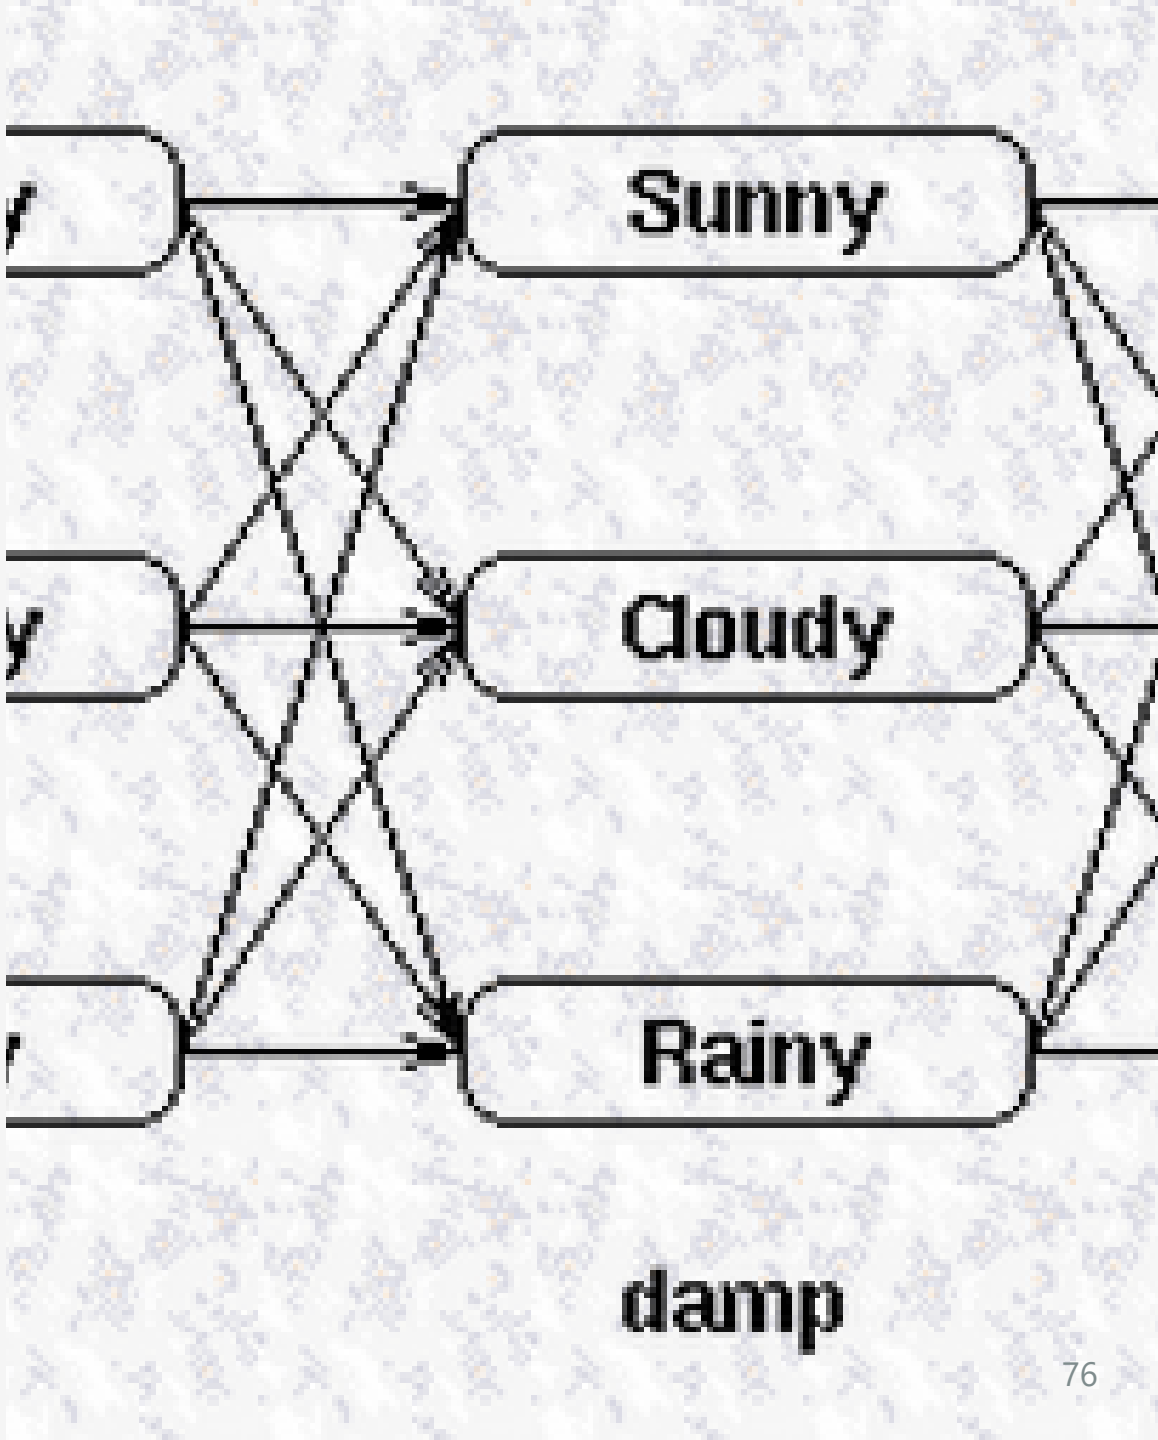

A better solution: dynamic programming

- We can calculate the probability of reaching an intermediate state in the trellis as the sum of all possible paths to that state

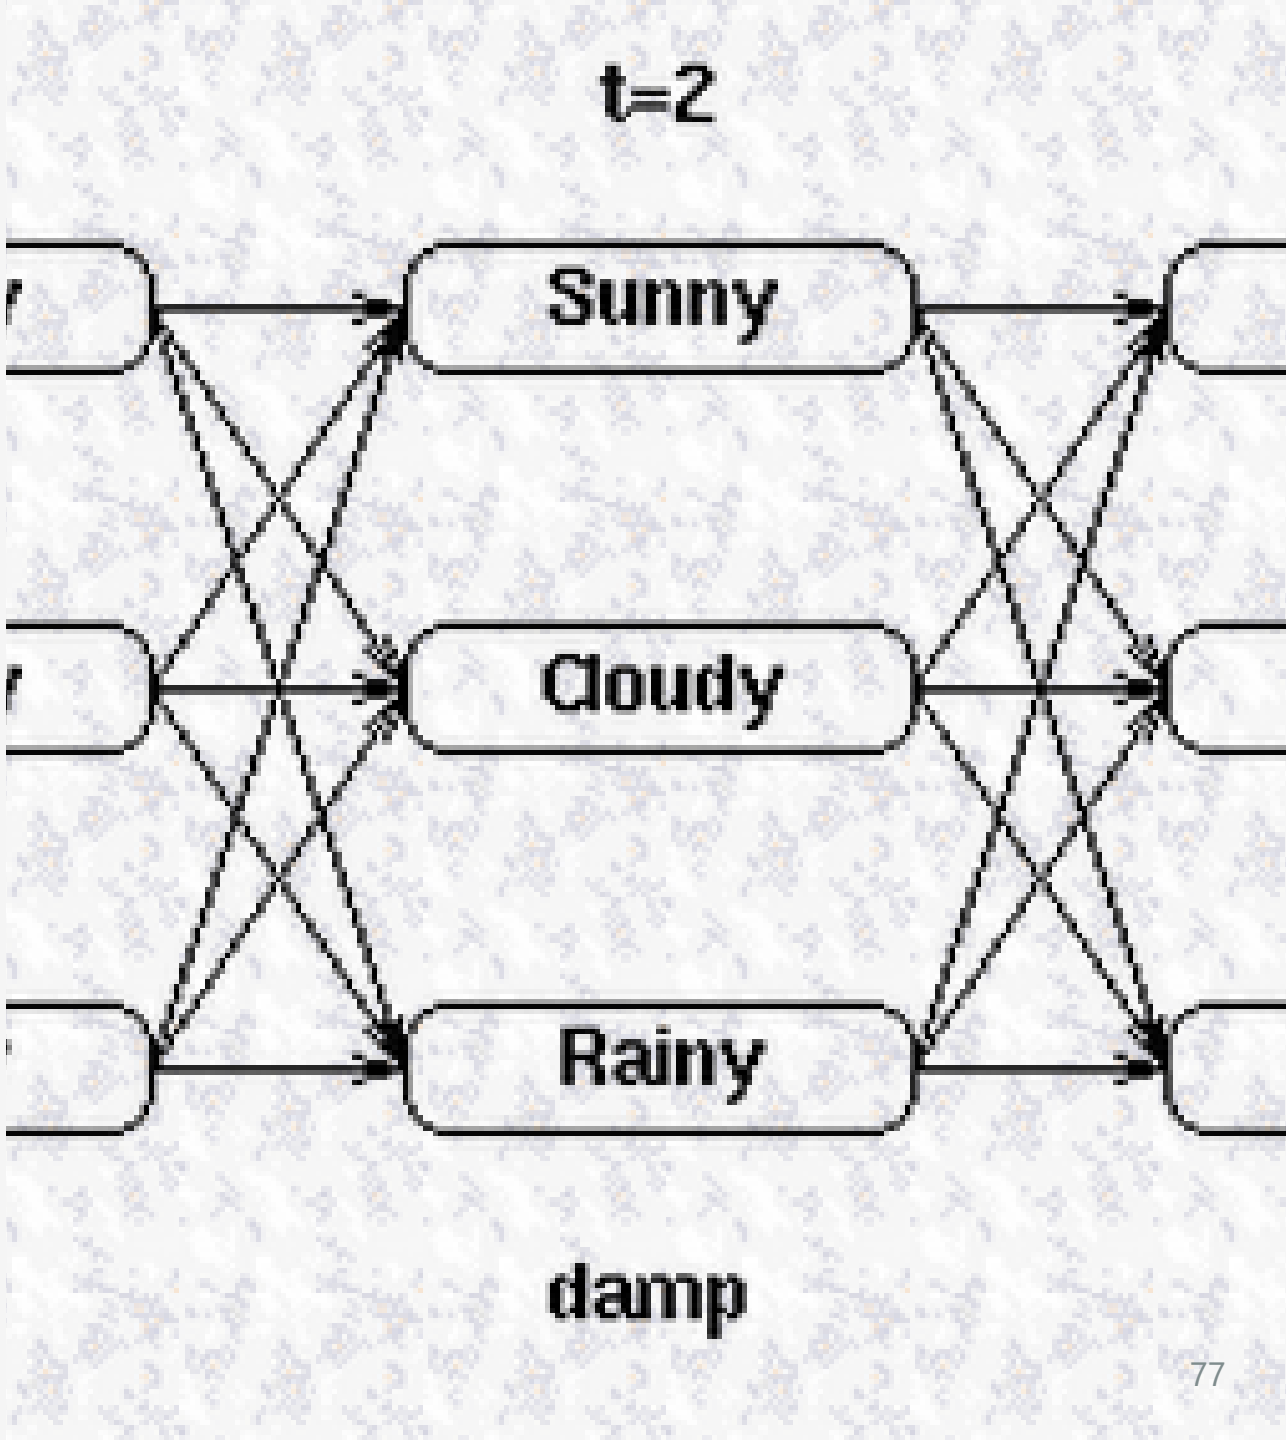

A better solution: dynamic programming

- $\alpha_t(j)$ = Pr(observation | hidden state is j) × Pr(all paths to state j at time t)

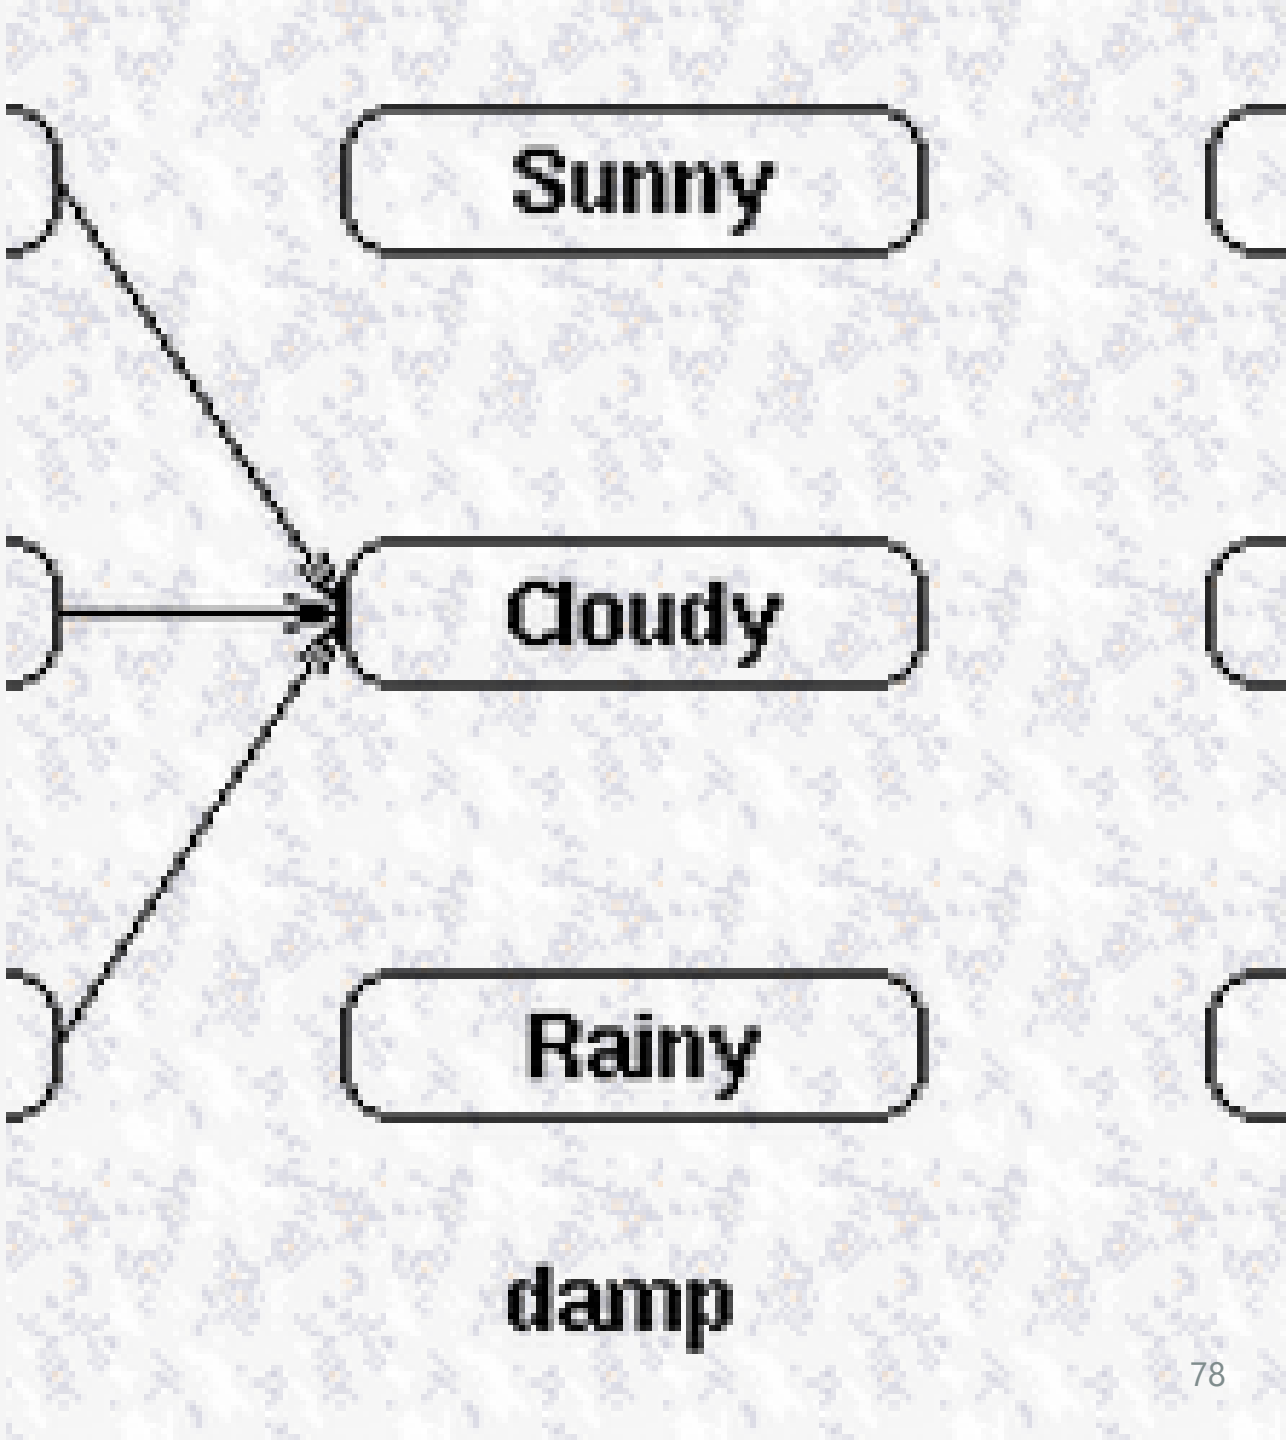

A better solution: dynamic programming

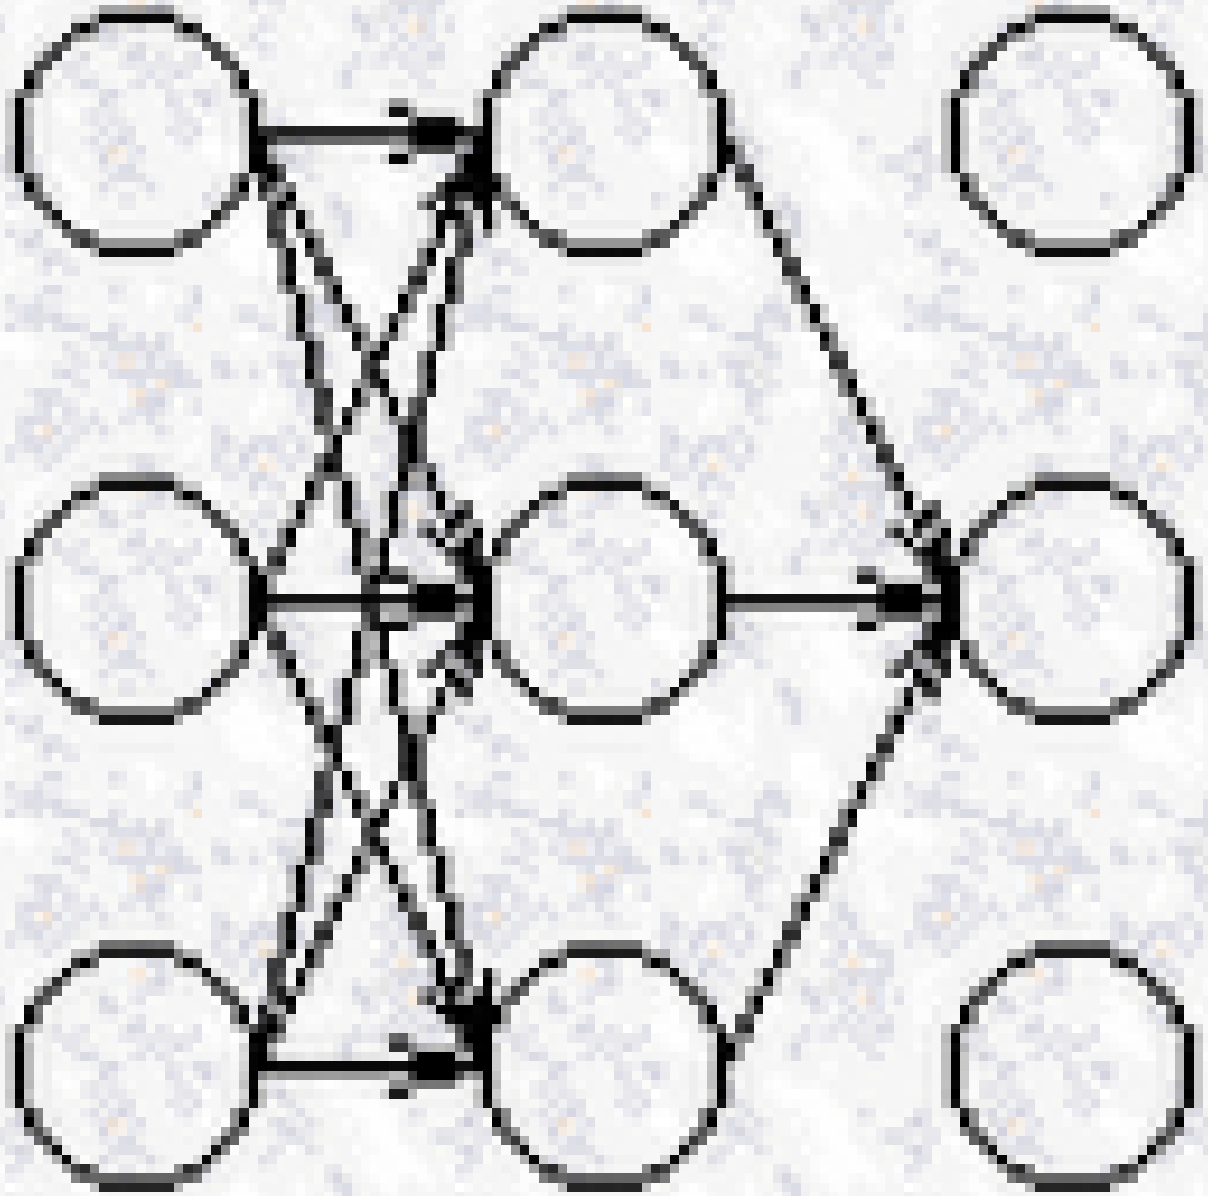

A better solution: dynamic programming

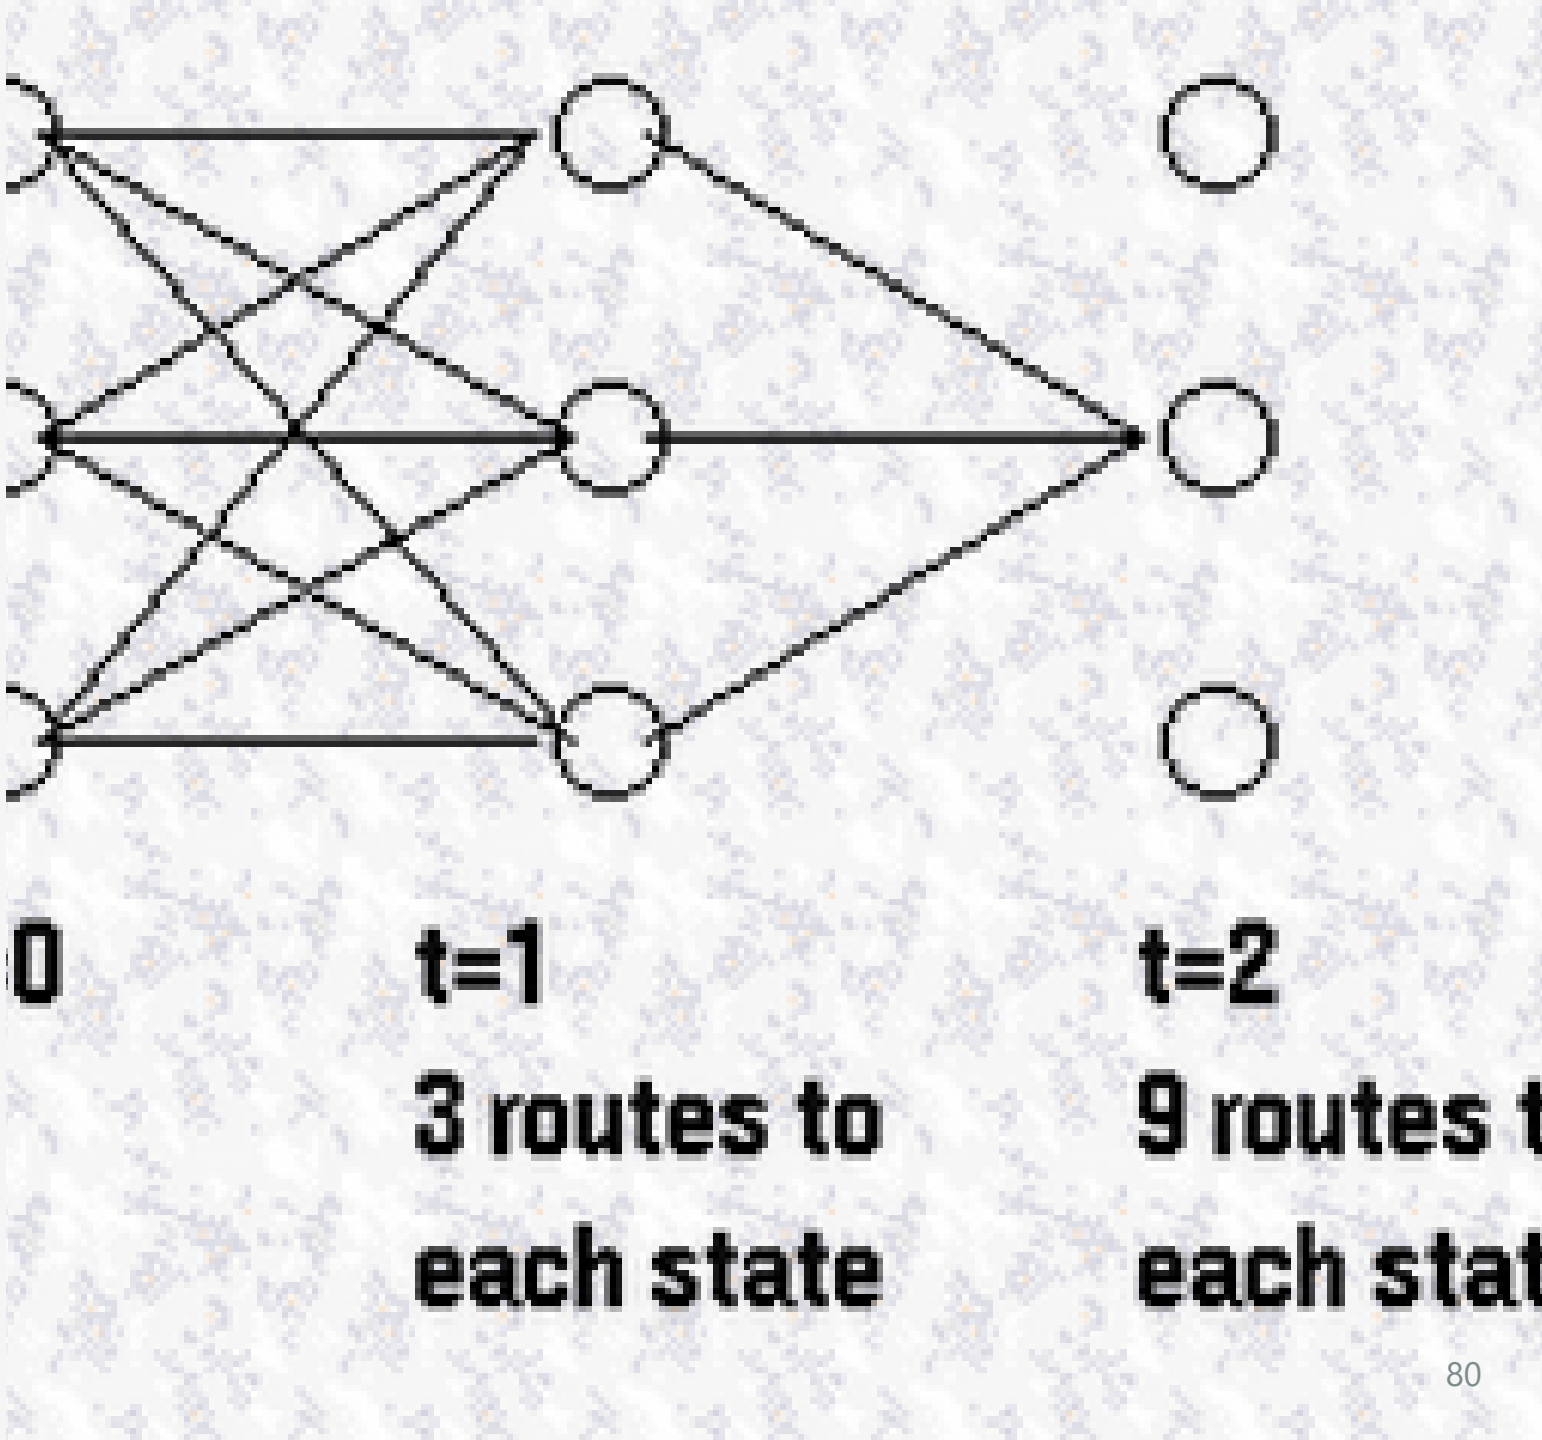

Filtres de Kalman

- **Filtres de Kalman**
  - Estimation récursive de l'état
  - Modèle linéaire gaussien
  - Prédiction + mise à jour

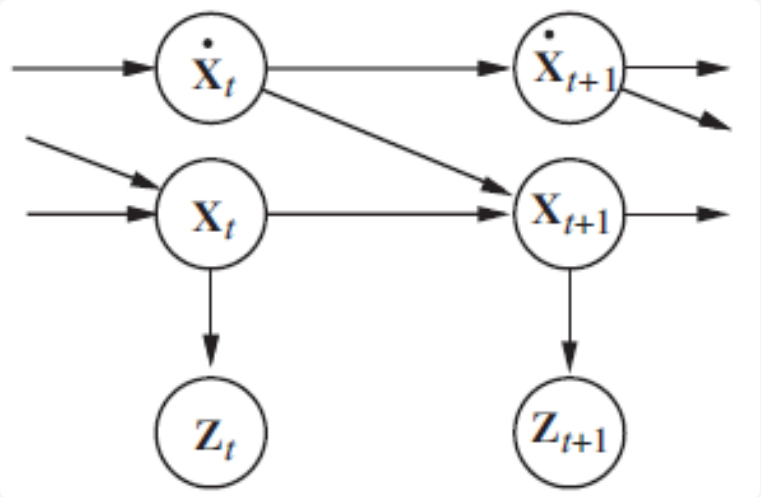

$$\mathbf{P}(\mathbf{X}_{t+1} \mid \mathbf{e}_{1:t}) = \int_{\mathbf{x}_t} \mathbf{P}(\mathbf{X}_{t+1} \mid \mathbf{x}_t) P(\mathbf{x}_t \mid \mathbf{e}_{1:t})\, d\mathbf{x}_t$$

$$\mathbf{P}(\mathbf{X}_{t+1} \mid \mathbf{e}_{1:t+1}) = \alpha\, \mathbf{P}(\mathbf{e}_{t+1} \mid \mathbf{X}_{t+1}) \mathbf{P}(\mathbf{X}_{t+1} \mid \mathbf{e}_{1:t})$$

Filtres de Kalman (suite)

- **Equations du filtre de Kalman**
  - État prédit: $\hat{x}_{k-} = A\,\hat{x}_{k-1} + B\,u_k$
  - Covariance prédite: $P_{k-} = A\,P_{k-1}\,A^T + Q$
  - Gain de Kalman: $K_k = P_{k-}\,H^T\,(H\,P_{k-}\,H^T + R)^{-1}$
  - État mis à jour: $\hat{x}_k = \hat{x}_{k-} + K_k\,(z_k - H\,\hat{x}_{k-})$

$$P(x_0) = \alpha\, e^{-\frac{1}{2}\left(\frac{(x_0-\mu_0)^2}{\sigma_0^2}\right)}$$

$$P(x_{t+1} \mid x_t) = \alpha\, e^{-\frac{1}{2}\left(\frac{(x_{t+1}-x_t)^2}{\sigma_x^2}\right)}$$

$$P(z_t \mid x_t) = \alpha\, e^{-\frac{1}{2}\left(\frac{(z_t-x_t)^2}{\sigma_z^2}\right)}$$

Filtres de Kalman (suite)

- **Applications des filtres de Kalman**
  - Navigation GPS
  - Suivi de véhicules
  - Robotique mobile
  - Traitement du signal

$$\mu_{t+1} = \frac{(\sigma_t^2 + \sigma_x^2) z_{t+1} + \sigma_z^2 \mu_t}{\sigma_t^2 + \sigma_x^2 + \sigma_z^2} \quad \text{and} \quad \sigma_{t+1}^2 = \frac{(\sigma_t^2 + \sigma_x^2)\sigma_z^2}{\sigma_t^2 + \sigma_x^2 + \sigma_z^2}$$

$$N(\boldsymbol{\mu}, \boldsymbol{\Sigma})(\mathbf{x}) = \alpha\, e^{-\frac{1}{2}\left((\mathbf{x}-\boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x}-\boldsymbol{\mu})\right)}$$

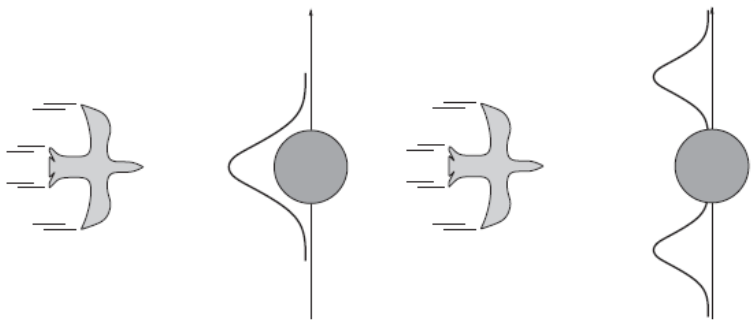

Réseaux bayésiens dynamiques

- **Généralisation HMM, Kalman etc.**
- **Modèle probabiliste temporel**
  - Variables X_t d'état et E_t d'observations, dans des coupes arbitraires
  - Cf transformation HMM RBD (vecteur multidimensionnel)
  - Modèle (beaucoup) plus parcimonieux
- **Construction d'un RBD**
  - Distribution a priori, modèle de transition, de capteur
  - Ex: Robot: jauge de batterie
    - → Modèle de défaillance temporaire
    - → Modèle de défaillance persistante → "Jauge cassée"

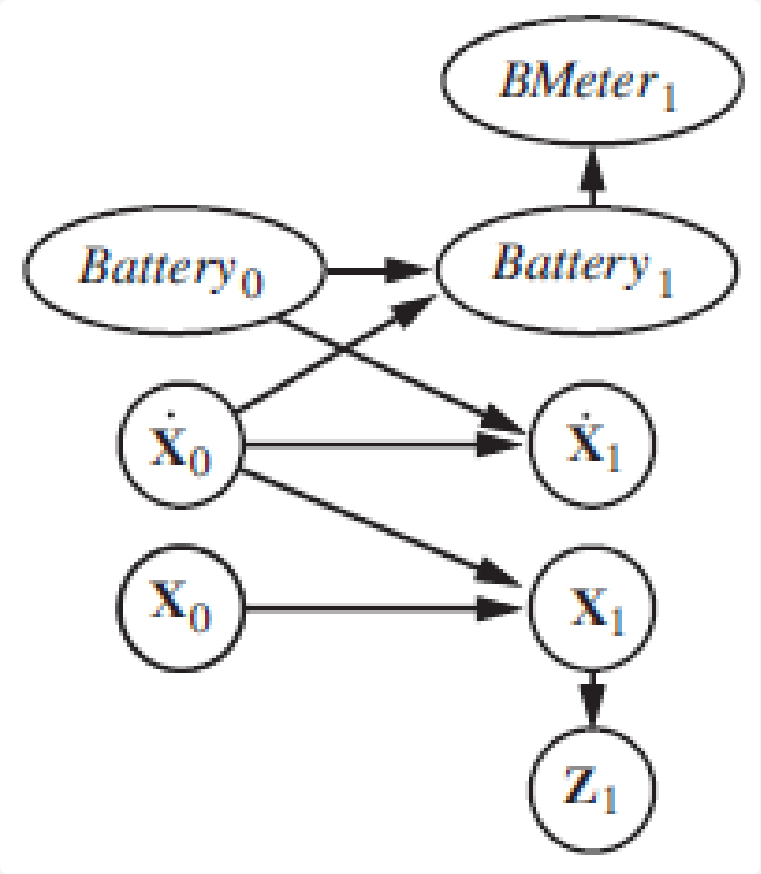

$$P(BMeter_t = 0 \mid Battery_t = 5) = 0.03$$

RBD: Inférence

- **Inférence exacte**
  - Possibilité: dépliement de suffisamment de coupes
  - Puis élimination, clustering
  - Utilité du fonctionnement récursif (sommations partielles)
  - Mais résultat pas factorisable
  - → Souvent, méthodes approximatives uniquement
- **Inférence approchée**
  - Pondération par vraisemblance et méthodes MCMC adaptables
  - Ex: Filtrage particulaire: on rejette les échantillons trop faibles et on duplique les autres parmi N
- **Suivre de nombreux objets (jusqu'ici: une trajectoire)**
  - Incertitude d'identité → pb d'association des données → Méthodes approximatives
  - Ex: plus proche voisin, max. de la probabilité des

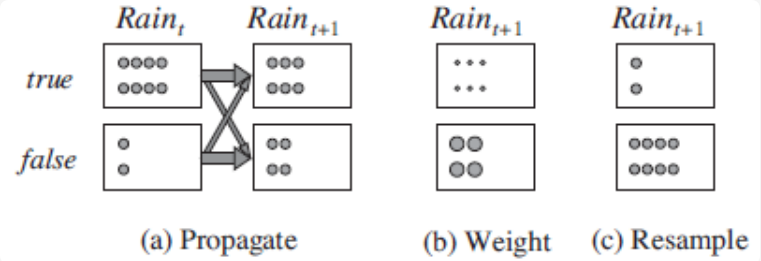

Résumé raisonnement temporel

- **Variables aléatoires temporelles**
  - Propriété de Markov, stationnarité
  - Modèles de transition, de capteur
- **Inférence**
  - Filtrage (forward), prédiction, lissage (backward), explication vraisemblance
- **Familles de modèles temporels**
  - Modèles de Markov cachés, filtres de Kalman, Réseaux bayésiens dynamiques
  - Inférence exacte souvent difficile mais méthodes approchées efficaces
- **Filtrage particulaire**
  - ○ Problème de l'association des données

Questions?

Programmation probabiliste

- **Principales librairies**
  - Infer.Net (C# / .NET)
  - Pyro (Python / PyTorch)
  - Tensorflow Probability (Python / TensorFlow)
  - PyMC (Python / Aesara, Jax)
  - Stan (C++ / Wrappers)
- **Tutoriels Infer.Net**
  - Prise en main (en français)
  - Tutoriels (en anglais)
  - Guide utilisateur

Sommaire

- Quantification de l'incertitude
- Raisonnement probabiliste
- Raisonnement probabiliste temporel
- **Prise de décision simple**
  - Théorie de l'utilité
  - Réseaux de décision
  - Systèmes experts
- Prise de décision complexe
- Théorie des jeux

Agent fondé sur l'utilité

- **Alternatives?**
  - Niveau de succès
  - Quantitatif
  - Fonction U: Etat → R
  - Arbitrages
- **Chance de succès**
  - Important
  - Urgent
  - …

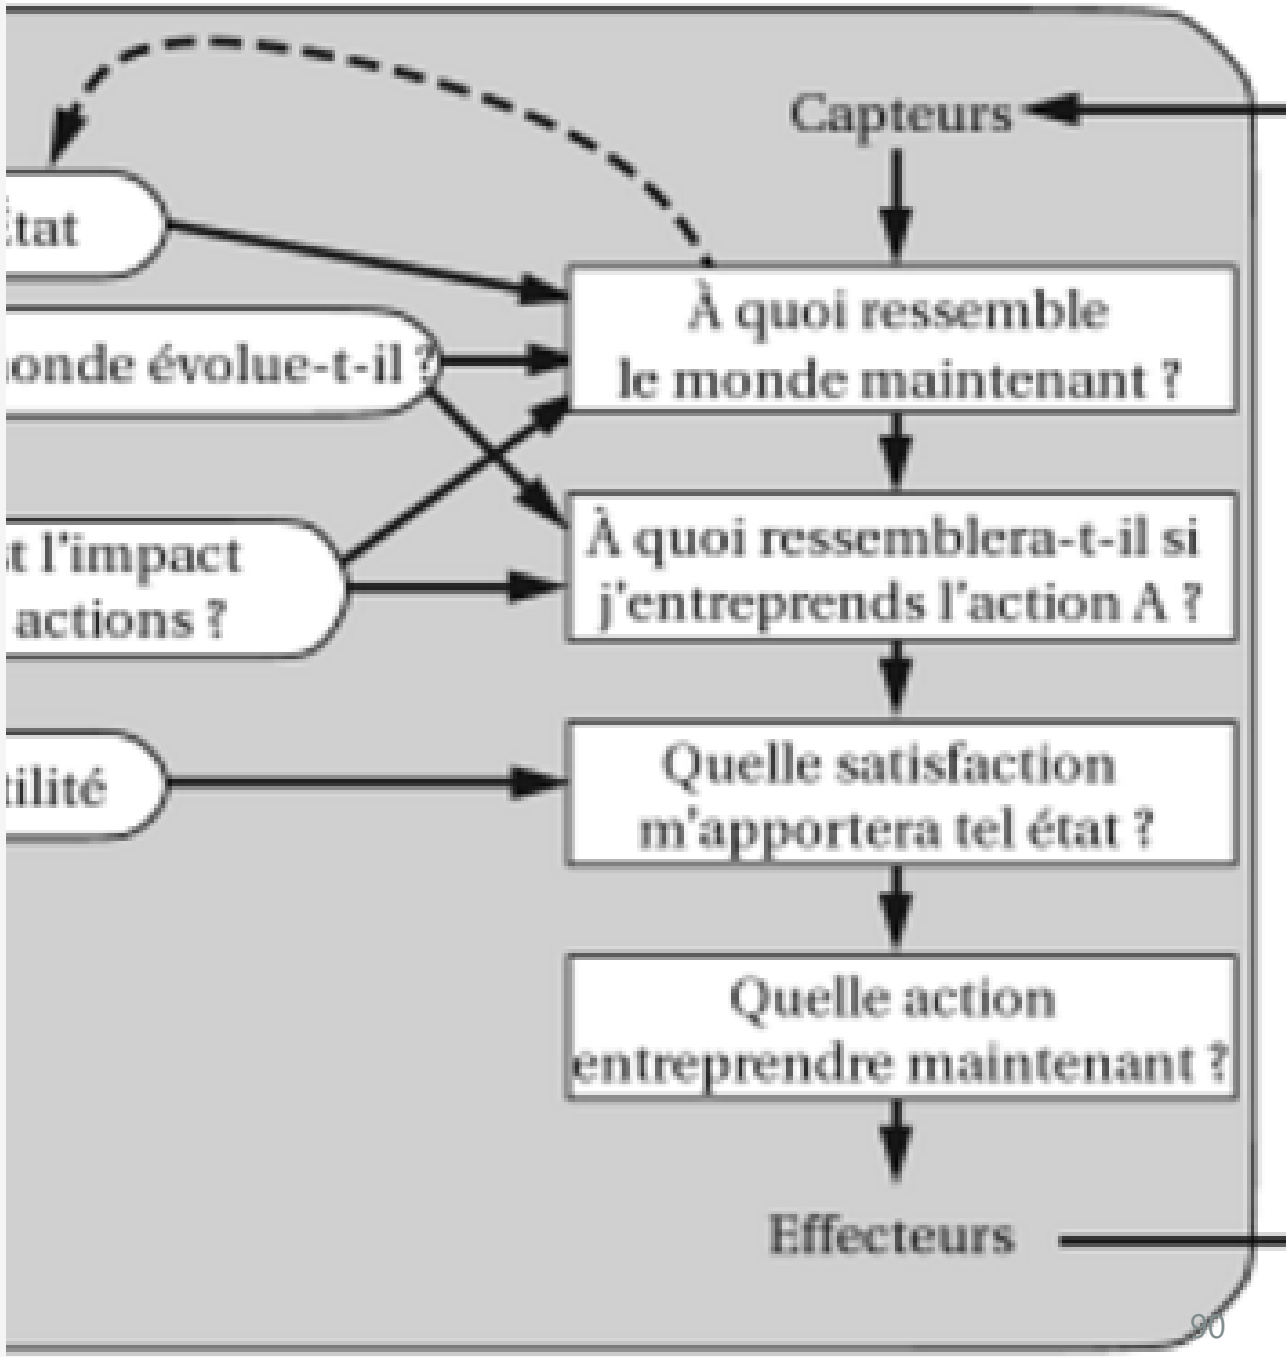

Prise de décision

- **Théorie des probabilités**
  - Ce qu'un agent devrait croire en s'appuyant sur l'observation
- **Théorie de l'utilité**
  - Ce que l'agent veut
- **→ Théorie de la décision synthétise les deux**
  - Ce que l'agent devrait faire
  - Considérer toutes les actions possibles
  - Viser le meilleur résultat: maximiser l'utilité espérée
  - → Agent rationnel
- **Préférence entre les loteries:**
  - $L = [p_1, S_1; p_2, S_2; \ldots p_n, S_n]$

$$EU(a|\mathbf{e}) = \sum_{s'} P(\textsc{Result}(a) = s' \mid a, \mathbf{e})\, U(s')$$

$$action = \underset{a}{\operatorname{argmax}}\, EU(a|\mathbf{e})$$

Théorie de l'utilité

- **Fonction d'utilité**
  - Représentation des préférences
  - Axiomes de rationalité
  - Utilité espérée

$$A \succ B \succ C \;\Rightarrow\; \exists p \;\; [p, A;\; 1-p, C] \sim B$$

$$A \succ B \;\Rightarrow\; (p > q \;\Leftrightarrow\; [p, A;\; 1-p, B] \succ [q, A;\; 1-q, B])$$

$$A \sim B \;\Rightarrow\; [p, A;\; 1-p, C] \sim [p, B; 1-p, C]$$

Théorie de l'utilité (suite)

- **Utilité monétaire**
  - Relation entre argent et utilité
  - Aversion au risque
  - Prime de risque

$$[p, A;\ 1-p, [q, B;\ 1-q, C]] \sim [p, A;\ (1-p)q, B;\ (1-p)(1-q), C]$$

$$U([p_1, S_1; \ldots; p_n, S_n]) = \sum_i p_i U(S_i)$$

$$U'(S) = aU(S) + b$$

Fonctions d'utilité

- **Types de fonctions d'utilité**
  - Linéaire: neutre au risque
  - Concave: aversion au risque
  - Convexe: goût pour le risque

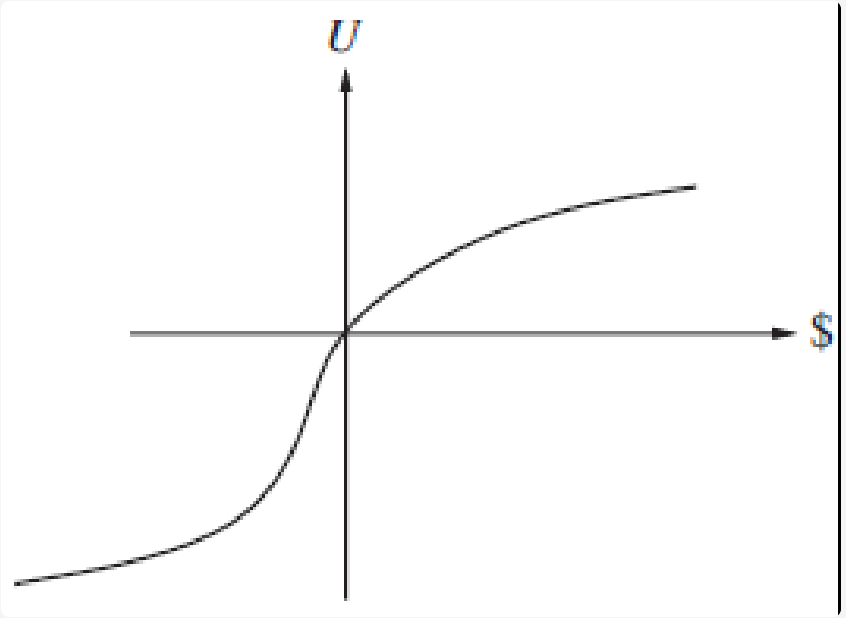

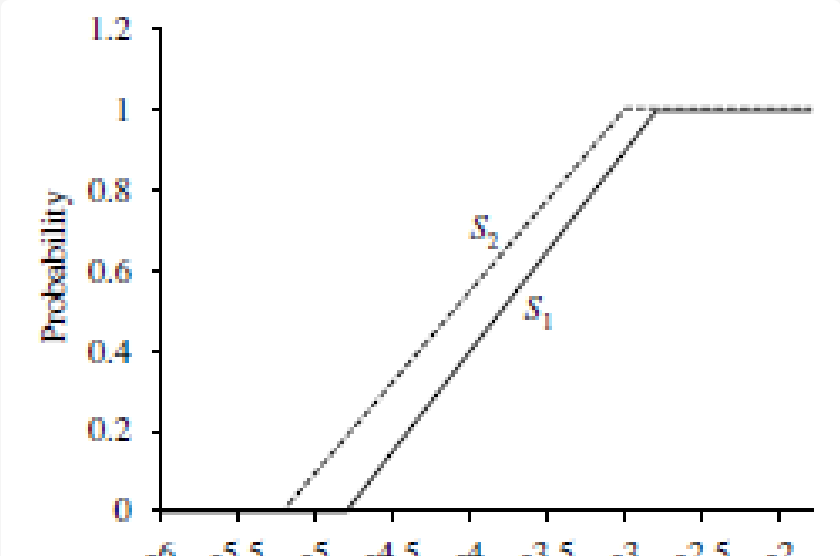

Fonctions d'utilité (suite)

- **Exemples d'applications**
  - Assurance
  - Investissement
  - Jeux de hasard

$$V(x_1, \ldots, x_n) = \sum_i V_i(x_i)$$

$$U = k_1U_1 + k_2U_2 + k_3U_3 + k_1k_2U_1U_2 + k_2k_3U_2U_3 + k_3k_1U_3U_1 + k_1k_2k_3U_1U_2U_3 \,.$$

Réseaux de décision

- **Réseaux de décision**
  - Combinaison de RB et noeuds de décision
  - Noeuds de décision: actions
  - Noeuds d'utilité: récompenses
  - Inférence: meilleure action

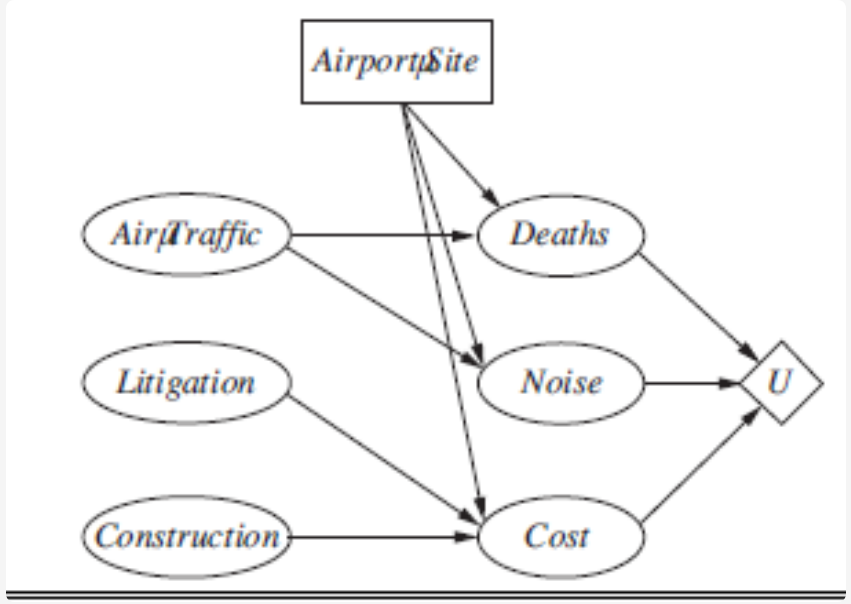

$$\frac{1}{n} \times \frac{(n-1)C}{n} + \frac{n-1}{n} \times \frac{C}{n(n-1)} = C/n$$

Réseaux de décision (suite)

- **Valeur espérée de l'information**
  - Valeur de l'information parfaite
  - Valeur de l'imparfaite
  - Coût vs bénéfice

$$VPI_{\mathbf{e}}(E_j) = \left(\sum_k P(E_j = e_{jk}|\mathbf{e})\ EU(\alpha_{e_{jk}}|\mathbf{e}, E_j = e_{jk}) \right) - EU(\alpha|\mathbf{e})$$

```
function INFORMATION-GATHERING-AGENT(percept) returns an action
  persistent: D, a decision network

  integrate percept into D
  j ← the value that maximizes VPI(E_j) / Cost(E_j)
  if VPI(E_j) > Cost(E_j)
     return REQUEST(E_j)
  else return the best action from D
```

Système expert

Questions?

Sommaire

- Quantification de l'incertitude
- Raisonnement probabiliste
- Raisonnement probabiliste temporel
- Prise de décision simple
- **Prise de décision complexe**
  - Politiques, Processus de décision de Markov
  - Théorie de jeux
  - Design de mécanismes
  - Jeux différentiels

Prise de décision complexe

- **Problèmes de décision séquentiels**
  - Planification = cas particulier
  - Entièrement observables
- **Processus de décision de Markov (MDP)**
  - Etats s, Actions(s)
  - Modèle de transition P(s' | s, a)
  - Récompense R(s)
  - Ex: +1; -1 (terminal); -0,04 (vitesse)
- *Solution = Politique optimale (π)**
  - Fournit l'utilité espérée maximale
  - $EU_h([s_0, s_1, \ldots, s_n])$

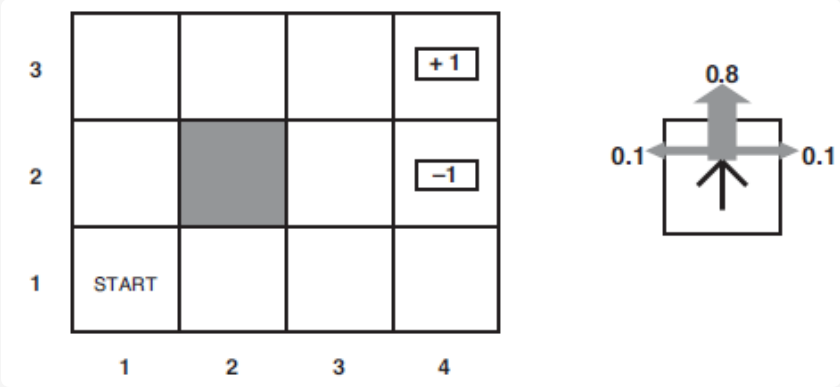

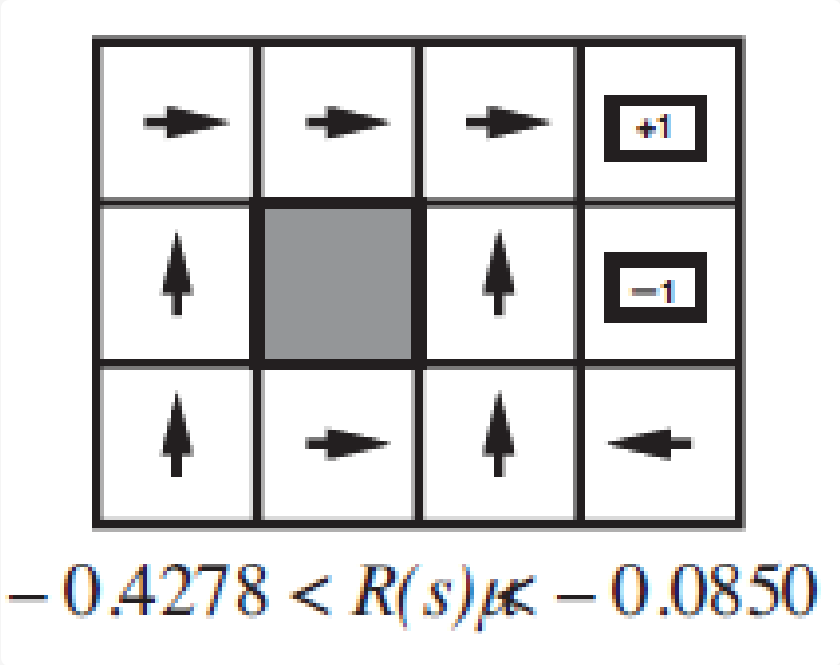

Horizons et préférences

- *Horizon fini → π non-stationnaire**
- **Préférences Stationnaires → récompenses**
  - Additives: $U_h([s_0, s_1, s_2, ...]) = R(s_0) + R(s_1) + R(s_2) + ...$
  - Besoin d'une politique appropriée (garantie de finir)
  - Ou escomptées: $U_h([s_0, s_1, s_2, ...]) = R(s_0) + \gamma R(s_1) + \gamma^2 R(s_2)$
  - → U bornée, Empirique, monétaire, incertitude, stationnarité
  - Sinon, récompense moyenne

$$U_h([s_0, s_1, s_2, \ldots]) = \sum_{t=0}^{\infty} \gamma^t R(s_t) \leq \sum_{t=0}^{\infty} \gamma^t R_{\max} = R_{\max}/(1-\gamma)$$

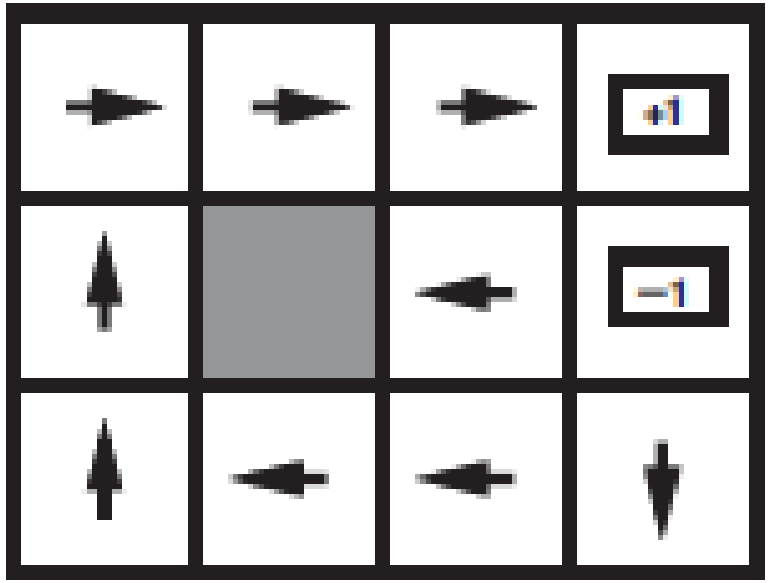

$$-0.0221 < R(s) < 0$$

Evaluation des politiques

- **Evaluation d'une politique π**
  - Utilité espérée
  - Valeur de chaque état

3	0.812	0.868	0.918	+1
2	0.762		0.660	−1
1	0.705	0.655	0.611	0.388
	1	2	3	4

$$\pi^*(s) = \underset{a \in A(s)}{\operatorname{argmax}} \sum_{s'} P(s' \mid s, a)[R(s, a, s') + \gamma U(s')]$$

Evaluation des politiques (suite)

- **Equations de Bellman**
  - Valeur d'état
  - Relation de récurrence

$$U(s) = \max_{a \in A(s)} \sum_{s'} P(s' \mid s,a)[R(s,a,s') + \gamma U(s')]$$

$$\begin{aligned} Q(s,a) &= \sum_{s'} P(s' \mid s,a)[R(s,a,s') + \gamma U(s')] \\ &= \sum_{s'} P(s' \mid s,a)[R(s,a,s') + \gamma \max_{a'} Q(s',a')] \end{aligned}$$

$$R'(s,a,s') = R(s,a,s') + \gamma \Phi(s') - \Phi(s)$$

Méthodes itératives

- **Value Iteration**
  - Mise à jour itérative
  - Convergence vers π*

$$U_{i+1}(s) \leftarrow \max_{a \in A(s)} \sum_{s'} P(s' \mid s, a)[R(s, a, s') + \gamma U_i(s')]$$

$$U_i(s) = \sum_{s'} P(s' \mid s, \pi_i(s))[R(s, \pi_i(s), s') + \gamma U_i(s')]$$

Méthodes itératives (suite)

- **Policy Iteration**
  - Evaluation de politique
  - Amélioration de politique

$$U_{i+1}(s) \leftarrow \sum_{s'} P(s' \mid s, \pi_i(s))[R(s, \pi_i(s), s') + \gamma U_i(s')]$$

Autres méthodes

$$U(s) \geq \sum_{s'} P(s' \mid s,a)[R(s,a,s') + \gamma U(s')]$$

- **Programmation linéaire**
  - Bellman → sommes et max → problème d'optimisation
  - Minimisation U(s) avec contraintes
  - Mais souvent complexité mauvaise (nombreux états/actions)
- **Algorithmes itératifs en ligne**
  - Méthodes offline souvent impraticables (cf. jeux)
  - Ex: Expectiminimax: Arbre minimax + nœuds de chance
  - Profondeur bornée (via γ) ainsi que branchement (via sampling)
  - Programmation dynamique en temps réel (RTDP)
  - (décomposition en sous problèmes → Graphe = sous-MPD)

Méthodes de Monte-Carlo et bandits

- **Grands espaces → méthodes de Monte-Carlo**
- **Problèmes de bandits manchots**
  - Machines à sous à n bras aux probabilités de gains distinctes (MAP ≈ MDP)
  - → Compromis Exploration/Exploitation
  - Ex: traitements covid-19
- **Coefficient de Gittins**
  - Une seule machine à sous: Comparaison avec récompense stationnaire λ
  - → stopping time T
  - Calcul: Cas simple: utilisation d'un Restart MDP (indifférence à T)
  - Approximations (MDP tronqué)

$$\lambda = \max_{T>0} \frac{E\left(\sum_{t=0}^{T-1} \gamma^t R_t\right)}{E\left(\sum_{t=0}^{T-1} \gamma^t\right)}$$

PDMPOs / POMDPs

- **Partially Observable MDPs**
  - États partiellement observables
  - Croyances sur l'état
  - Inférence sur les croyances

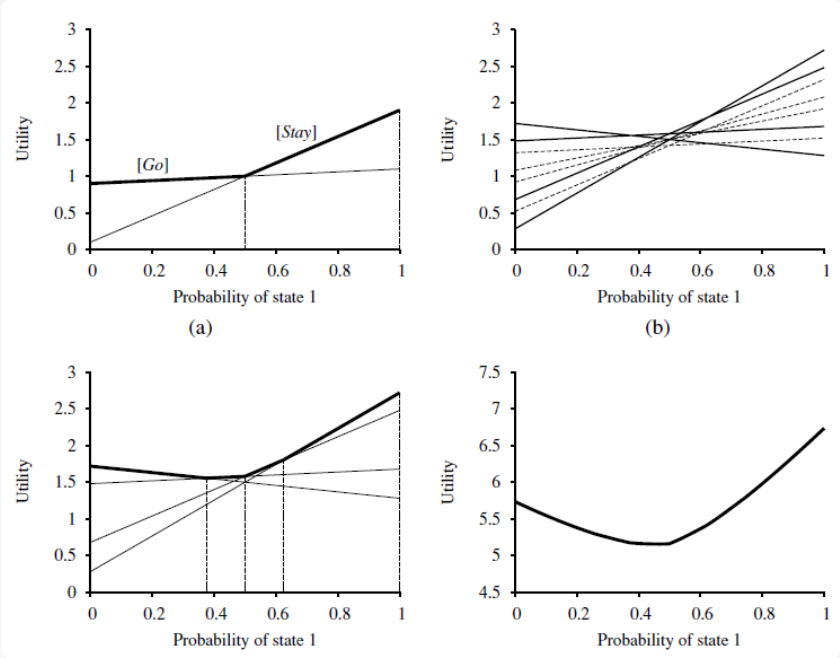

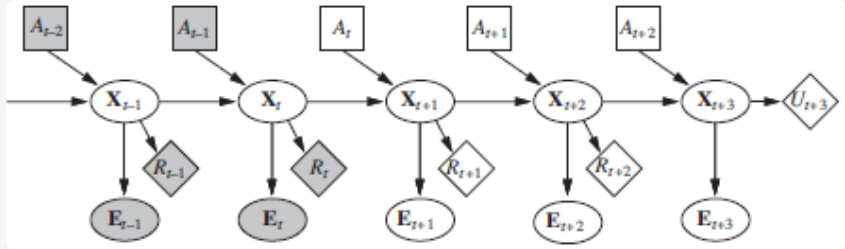

PDMPOs / POMDPs (suite)

- **Résolution des POMDPs**
  - Arbre de croyances
  - Points de croyance
  - Méthodes approximatives

$$b'(s') = \alpha\, P(e \mid s') \sum_{s} P(s' \mid s, a) b(s)$$

Questions?

Plan du cours

- Introduction
- Résolution de problèmes
- Bases de connaissances et logique
- Incertitude et modèles probabilistes
- Théorie des jeux
- Apprentissage
- Traitement du langage naturel
- Présentation projets

Projets de groupe

- **Moteur de recherche augmenté par le raisonnement et le langage naturel**
  - Grammaire et sémantique des contenus et des requêtes. Lucene.Net, OpenNLP, SharpRDF, FOL
- **Conception de bots de services sur réseaux sociaux**
  - Chat Bots, AIML, Reddit et agents de service, NLP, RDF, APIs
- **Conception d'un modèle d'inférence pour l'analyse de sentiment**
  - Conception d'un modèle probabiliste, Infer.Net, démarche expérimentale, Reddit
- **Création d'une plateforme sémantique LDP à partir d'un index structuré**
  - Structuration et ouverture des données = Linked Data. Lucene.Net, SharpRDF
- **Résolution de Captchas par deep learning**
  - Apprentissage via un Adapteur DNN, Réseaux de dernières génération. TensorFlow, CNTK, Encog

Projets de groupe (suite)

- **Entraînement de stratégies de trading algorithmiques sur crypto monnaies**
  - Expérience DNN Bitcoin, Encog et machine learning
- **Amélioration par l'apprentissage d'un agent joueur de Go simple**
  - Le Go et l'IA, Récentes avancées. Go Traxx
- **Evolution de vaisseaux spatiaux par algorithmes génétiques dans le jeu de la vie**
  - Approches évolutionnistes, automates cellulaires, Bac à sable. Golly, Encog
- **Pilotage d'un cluster de cache distribué pour le portage d'applications dans le Cloud**
  - Caches distribués, scaling, stratégies et clustering. Redis

Pour aller plus loin: Notebooks

- **Infer.NET 101**: `Probas/Infer-101.ipynb` - introduction probabilités
- **Réseaux bayésiens**: `Probas/Infer/Infer-3-Factor-Graphs.ipynb`, `Infer-4-Bayes-Nets.ipynb`
- **Inférence**: `Probas/Infer/Infer-5-Inference.ipynb`, `Infer-7-Variable-Elimination.ipynb`
- **HMM**: `Probas/Infer/Infer-6-HMM.ipynb`, `Infer-8-Temporal.ipynb`
- **Décision et utilité**: `Probas/Infer/Infer-12-Decision.ipynb`, `Infer-14-Decision-Utility.ipynb`
- **MDP et RL**: `GameTheory/GameTheory-2b-MDP.ipynb`, `GameTheory-14b-RL-Basics.ipynb`

Merci

Jean-Sylvain Boige
jsboige@myia.org